

Analyse de données



Description bidimensionnelle et mesure de liaison entre variables

Couples de variables aléatoires

Soit 2 variables aléatoires X et Y (dans le cas discret) définies sur un espace probabilisé $(\Omega, \mathcal{C}, \mathbb{P})$

- Ω Univers (l'ensemble des éléments élémentaires)
- \mathcal{C} attribut tel que \mathcal{C} inclu dans $P(\Omega)$ (== "toutes les parties de Omega")
- \mathbb{P} probabilité

Exemple :

Un évènement $A = \{(i, j) / i\} + j \geq 10,$
 $\mathcal{C} \in P$

$X(\omega) = \{X_i / i \in I\}$ l'ensemble des valeurs de X

$Y(\omega) = \{Y_j / j \in J\}$ l'ensemble des valeurs de Y

Loi conjointe (X, Y)

Définition :

On appelle loi conjointe du couple (X, Y) l'ensemble des couples $((X_i, Y_j), P_{i,j})$ avec $\forall x_i \in X_\omega, \forall y_j \in Y_\omega$

$$P_{i,j} = \mathbb{P}((X = x_i) \cap (Y = y_j))$$

$$P_{i,j} \geq 0 \text{ et } \sum_{i,j} P_{i,j} = 1$$

Remarque :

$$I = \llbracket 1, r \rrbracket, J = \llbracket 1, s \rrbracket$$

$$\left[\begin{array}{cccccc} & y_1 & \dots & y_j & \dots & y_s & \text{Loi de X} \\ x_1 & P_{1,1} & & \vdots & & P_{1,s} & P_{1,\cdot} \\ \vdots & & & \vdots & & & \vdots \\ x_i & \dots & \dots & \boxed{P_{i,j}} & & & P_{i,\cdot} \\ \vdots & & & & & & \vdots \\ x_r & P_{r,1} & & & & P_{r,s} & P_{r,\cdot} \\ \hline \text{Loi de Y} & P_{\cdot,1} & \dots & P_{\cdot,j} & \dots & P_{\cdot,s} & 1 \end{array} \right]$$

Lois marginales

Les V.A. X, Y sont appelees variables marginales des couples (X, Y)

Loi marginale de X :

$$\mathbb{P}[X = x_i] = P_{i,\cdot} = \sum_{j \in J} P_{i,j}$$

Loi marginale de Y :

$$\mathbb{P}[Y = y_j] = P_{\cdot,j} = \sum_{i \in I} P_{i,j}$$

Exemple :

$$\left[\begin{array}{cccccc} & 1 & 2 & 3 & 4 & \text{Loi de X} \\ 1 & \frac{1}{16} & \frac{1}{16} & \frac{1}{16} & \frac{1}{16} & \frac{1}{4} \\ 2 & 0 & \frac{2}{16} & \frac{1}{16} & \frac{1}{16} & \frac{1}{4} \\ 3 & 0 & 0 & \frac{3}{16} & \frac{1}{16} & \frac{1}{4} \\ 4 & 0 & 0 & 0 & \frac{4}{16} & \frac{1}{4} \\ \text{Loi de Y} & \frac{1}{16} & \frac{3}{16} & \frac{5}{16} & \frac{7}{16} & 1 \end{array} \right]$$

Lois conditionnelles

On appelle loi conditionnelle de $X = x_i$ sachant que $Y = y_j$:

$$\mathbb{P}(X = x_i | Y = y_j) = \frac{\mathbb{P}((X = x_i) \cap (Y = y_j))}{\mathbb{P}(Y = y_j)} = \frac{\mathbb{P}_{ij}}{\mathbb{P}_{.j}}$$

avec $\mathbb{P}(Y = y_j) \neq 0$

$$\mathbb{P}(X = x_i | Y = y_j) = \frac{\mathbb{P}_{i,j}}{\mathbb{P}_{.j}}$$

$$\mathbb{P}(Y = y_j | X = x_i) = \frac{\mathbb{P}_{i,j}}{\mathbb{P}_{i.}}$$

Exemple : (matrice précédente)

$\mathbb{P}(X = x_i | Y = 3)$

X_i	1	2	3	4
$\mathbb{P}(X = x_i Y = 3)$	$\frac{1}{5}$	$\frac{1}{5}$	$\frac{3}{5}$	0

$$\mathbb{P}(X = 1 | Y = 3) = \frac{\mathbb{P}((X = 1) \cap (Y = 3))}{\mathbb{P}(Y = 3)} = \frac{\frac{1}{16}}{\frac{5}{16}} = \frac{1}{5}$$

Définition : [Indépendance]

X et Y sont indépendantes ssi

$$\mathbb{P}((X = x_i) \cap (Y = y_j)) = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$$

$\forall x_i \in X(\omega), \forall y_j \in Y(\omega)$

Equivalent à :

$$\mathbb{P}_{i,j} = \mathbb{P}_{i.} \cdot \mathbb{P}_{.j}$$

Loi d'une fonction de 2 variables

Soit $g : \mathbb{R}^2 \longrightarrow \mathbb{R}$ et Z la variable aléatoire $Z = g(X, Y)$ avec (X, Y) couple de valeurs aléatoires,

g est une fonction quelconque.

Les valeurs prises par $Z : g(x_i, y_j), x_i \in X(\omega), y_j \in Y(\omega)$

$$Z(\omega) = \{Z_k / k \in K\}_{K \subset \mathbb{N} \text{ ou } \mathbb{Z}}$$

$$\underbrace{[Z = z_k]}_{\text{événement}} = \bigcup_{(i,j)} ([X = x_i] \cap [Y = y_j])$$

Evènements incompatibles : leur intersection est vide.

Soit

$$A_{i,j} \cap A_{i',j'} = \emptyset$$

$$(i,j) \neq (i',j')$$

$$\mathbb{P}(Z = z_k) = \sum_{(i,j) / g(X)_{ij}=Z_k} \mathbb{P}((X = x_i) \cap (Y = y_j))$$

Remarque :

En particulier $Z = X + Y$

$$\mathbb{P}(Z = x + y) = \sum_{x+y=Z} \mathbb{P}((X = x) \cap (Y = y))$$

Si $Z = X \cdot Y$

$$\mathbb{P}(Z = x \cdot y) = \sum_{xy=Z} \mathbb{P}((X = x) \cap (Y = y))$$

Exemple :

$X \backslash Y$	1	2	3	4
1	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$
2	0	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{16}$
3	0	0	$\frac{3}{16}$	$\frac{1}{16}$
4	0	0	0	$\frac{4}{16}$

1 Déterminer la loi de $S = X + Y$

2 Déterminer la loi de $P = X \cdot Y$

$$S(\omega) = \{2, 3, 4, 5, 6, 7, 8\}$$

S_i	2	3	4	5	6	7	8
$P_i = P(S = S_i)$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{3}{16}$	$\frac{2}{16}$	$\frac{4}{16}$	$\frac{1}{16}$	$\frac{4}{16}$

$P = X \cdot Y$ (produits)

$$p(\omega) = \{1, 2, 3, 4, 6, 8, 9, 12, 16\}$$

P_i	1	2	3	4	6	8	9	12	16
$\mathbb{P}(P = P_i)$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{3}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{3}{16}$	$\frac{1}{16}$	$\frac{4}{16}$

Definition :

Soit $Z = g(X, Y)$

On appelle esperance de Z

$$E(Z) = \sum_{\substack{i \in I \\ j \in J}} (g(x_i, y_j) \cdot \mathbb{P}((X = x_i) \cap (Y = y_j)))$$

Remarque :

$$E(XY) = \sum_i \sum_j x_i y_j \mathbb{P}_{i,j}$$

Si 2 V.A. X et Y sont indépendantes alors

$$E(XY) = E(X)E(Y)$$

- Reciproque est fausse en général
- Condition suffisante non necessaire

Contre-exemple :

$X \backslash Y$	0	1	2	Loi de X
0	$\frac{1}{20}$	$\frac{1}{4}$	0	$\frac{3}{10}$
1	$\frac{17}{60}$	$\frac{1}{4}$	$\frac{1}{6}$	$\frac{7}{10}$
Loi de Y	$\frac{1}{3}$	$\frac{1}{2}$	$\frac{1}{6}$	1

$$E(X \cdot Y) = \sum_{i=0}^1 \sum_{j=0}^2 x_i \cdot y_j P_{i,j} = \frac{1}{4} \times 1 + \frac{1}{6} \times 2$$

$$E(X) = \sum_{i=0}^1 x_i P_i = \frac{7}{10}$$

$$E(Y) = \sum_{j=0}^2 j P_j = \frac{1}{2} + \frac{2}{6} = \frac{5}{6}$$

$$E(X)E(Y) = \frac{35}{60} = \frac{7}{12} \neq E(XY)$$

$$E(X \cdot Y) \neq E(X)E(Y)$$

Mais X et Y sont dépendantes car

$$\mathbb{P}((X = 0) \cap (Y = 2)) = 0 \neq \mathbb{P}((X = 0))\mathbb{P}((Y = 2)) = \frac{1}{20}$$

Définition : [Covariance]

Soit 2 V.A. X, Y discrètes

On appelle covariance de x, y l'espérance de xy - le produit des espérances respectives.

$$Cov(X, Y) = E(XY) - E(X)E(Y)$$

$$V(X + Y) = V(X) + V(Y) + 2Cov(XY)$$

Si X et Y sont indépendantes $\implies Cov(X, Y) = 0$

$$\boxed{V(X + Y) = V(X) + V(Y)}$$

Corrélation linéaire**Définition :**

On appelle coefficient de corrélation entre X et Y ,

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

$$\underbrace{\sigma_X}_{\text{écart-type}} = \sqrt{V(X)}, \sigma_Y = \sqrt{V(Y)}$$

Remarque :

- $\sigma_x = \|X - E(X)\|$, $\sigma_y = \|Y - E(Y)\|$
- $\underbrace{\langle X - E(X), Y - E(Y) \rangle}_{\text{produit scalaire}} = Cov(X, Y)$
- $\rho(X, Y) = \frac{\langle X - E(X), Y - E(Y) \rangle}{\|X - E(X)\| \|Y - E(Y)\|}$
- $\cos \theta = \frac{\langle u, v \rangle}{\|u\| \|v\|}$
- $|\rho(X, Y)| \leq 1$
- $|\rho(X, Y)| = 1 \implies X, Y$ colinéaire
- $|\rho(X, Y)| = 0 \implies X, Y$ perpendiculaire

Exercice d'application :

"À préparer pour la prochaine fois" :

X_i	-2	-1	0	1	2
$\mathbb{P}(X = X_i)$	$\frac{1}{6}$	$\frac{1}{4}$	$\frac{1}{6}$	$\frac{1}{4}$	$\frac{1}{6}$

Soit $Y = X^2$.

1. Donner la loi conjointe de (X, Y)
2. Loi marginale de Y
3. Indépendance?
4. Calculer $Cov(X, Y)$

La loi conjointe de (X, Y)

- $P_{i,j} = \mathbb{P}((X = i) \cap (Y = j)) = 0$ si $j \neq i^2$
- $P_{i,j} = \mathbb{P}(\underbrace{(X = i) \cap (Y = i^2)}_{\{X=i\} \subset \{Y=i^2\}}) = \mathbb{P}(X = i)$ si $j = i^2$

$X \backslash Y$	0	1	4	Loi de X
-2	0	0	$\frac{1}{6}$	$\frac{1}{6}$
-1	0	$\frac{1}{4}$	0	$\frac{1}{4}$
0	$\frac{1}{6}$	0	0	$\frac{1}{6}$
1	0	$\frac{1}{4}$	0	$\frac{1}{4}$
2	0	0	$\frac{1}{6}$	$\frac{1}{6}$
Loi de Y	$\frac{1}{6}$	$\frac{1}{2}$	$\frac{1}{3}$	1

Loi marginale de Y

D'après le tableau de la loi conjointe

i	0	1	4
$\mathbb{P}(Y = Y_i)$	$\frac{1}{6}$	$\frac{1}{2}$	$\frac{1}{3}$

Indépendance

$$P_{ij} = \mathbb{P}((X = x_i) \cap (Y = y_j)) \stackrel{?}{=} \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j) \quad \forall (i, j)$$

$$\text{Or } P_{ij} = \mathbb{P}((X = 0) \cap (Y = 1)) = 0 \neq \mathbb{P}(X = 0) \cdot \mathbb{P}(Y = 1) = \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{12}$$

$\Rightarrow X$ et Y ne sont pas indépendants

La covariance

$$Cov(X, Y) = E(X \cdot Y) - E(X)E(Y)$$

$$E(X \cdot Y) = \sum_{i,j} x_i y_j \mathbb{P}_{i,j} = \sum_i x_i \sum_j y_j \mathbb{P}_{i,j}$$

avec $\mathbb{P}_{i,j} = \mathbb{P}((X = x_i) \cap (Y = y_j))$

$$E(XY) = -\frac{8}{6} - \frac{1}{4} + \frac{1}{4} + \frac{8}{6} = 0$$

$$E(Y) = \sum y_i \mathbb{P}(Y = y_i) = \frac{1}{2} + \frac{4}{3} = \frac{11}{6}$$

$$E(X) = \sum x_i \mathbb{P}(X = x_i) = -\frac{1}{3} - \frac{1}{4} + \frac{1}{4} + \frac{1}{3} = 0$$

$$Cov(X, Y) = 0$$

On peut noter que lorsque **X** et **Y** sont indépendante la covariance est nulle. Cependant la réciproque n'est pas vrai.

La preuve dans cet exercice **X** et **Y** sont dépendante et leur covariance est nulle.

Exercice 2

On a n boîtes numérotées de 1 à n

La boîte n° k contient k boules numérotées de 1 à k .

On choisit au hasard une boîte puis une boule dans cette boîte.

X V.A le numéro de la boîte

Y V.A le numéro de la boule

1. Déterminer la loi conjointe
2. Calculer $\mathbb{P}(X = Y)$
3. Déterminer la loi marginale de Y
4. Calculer $E(Y)$

$$X(\omega) = \{1, 2, \dots, n\}$$

$$Y(\omega) = \{1, 2, \dots, n\}$$

Loi de couple (X, Y) ?

$$\mathbb{P}((X = i) \cap (Y = j))$$

$$\forall i \in \llbracket 1, n \rrbracket$$

$$\forall j \in \llbracket 1, n \rrbracket$$

Loi conjointe

Soit $j > i$

$$P_{ij} = \mathbb{P}((X = x_i) \cap (Y = y_j)) = 0$$

Soit $j \leq i$

$$P_{ij} = \mathbb{P}((X = x_i) \cap (Y = y_j))$$

$$= \mathbb{P}(Y = y_j | X = x_i) \cdot \mathbb{P}(X = x_i)$$

$$= \frac{1}{i} \cdot \frac{1}{n}$$

$$\mathbb{P}(X = Y)$$

$$(X = Y) = \bigcup_{i=1}^n (X = x_i) \cap (Y = y_i)$$

événements indépendants donc

$$\mathbb{P}(X = Y) = \sum_{i=1}^n P_{ii} = \sum_{i=1}^n \frac{1}{i} \cdot \frac{1}{n} = \frac{1}{n} \cdot \sum_{i=1}^n \frac{1}{i}$$

Loi marginale de Y

$$\mathbb{P}(Y = j) = \sum_i^n ((X = x_i) \cap (Y = y_j))$$

$$= \sum_{i=j}^n \frac{1}{i \cdot n} = \frac{1}{n} \sum_{i=j}^n \frac{1}{i}$$

Espérance de Y

$$E(Y) = \sum_{j=1}^n j \cdot \mathbb{P}(Y = y_j)$$

$$E(Y) = \sum_{j=1}^n j \cdot \frac{1}{n} \sum_{i=j}^n \frac{1}{i}$$

$$E(Y) = \frac{1}{n} \sum_{j=1}^n j \sum_{i=j}^n \frac{1}{i}$$

$$E(Y) = \frac{1}{n} \sum_{i=1}^n \frac{1}{i} \sum_{j=1}^i j$$

$$E(Y) = \frac{1}{n} \sum_{i=1}^n \frac{1}{i} \cdot \frac{i(i+1)}{2}$$

$$E(Y) = \frac{1}{2n} \sum_{i=1}^n i + 1$$

$$E(Y) = \frac{1}{2n} \left(\frac{n(n+1)}{2} + n \right)$$

$$E(Y) = \frac{1}{2} \left(\frac{n+1}{2} + 1 \right)$$

$$E(Y) = \frac{n+3}{4}$$

Exercice 3

On dispose d'un dé équilibré à 6 faces

et d'une pièce truquée telle que la probabilité d'obtenir pile vaut $p \in]0, 1[$

Soit $N \in \mathbb{N}^*$ (fini). On effectue N lancers de dé. Si n est le nombre de six obtenu, on lance alors n fois la pièce.

Z V.A nombre de six obtenus

X V.A nombre de pile

Y V.A nombre de face

$$Z = X + Y$$

$$Z = 0 \text{ si } X = Y = 0$$

1. déterminer la loi de Z , $E(Z)$, $V(Z)$
2. $\forall k \in \mathbb{N}, \forall n \in \mathbb{N}$ déterminer $\mathbb{P}(X = k | Z = n)$
3. $\forall 0 \leq k \leq n < N$ calculer $\mathbb{P}((X = k) \cap (Z = n))$
4. calculer $P(X = 0)$
5. Montrer que $\forall 0 \leq k \leq n \leq N, \binom{n}{k} \binom{N}{n} = \binom{N}{k} \binom{N-k}{n-k}$
Pour cette 5^e question il s'agit de prouver une égalité de deux combinaisons de type k parmi n , cette égalité servira pour la question 6. Elle est facile à prouver car il suffit de développer LHS et RHS en utilisant la formule $(k \text{ parmi } n) = n! / k!(n-k)!$ puis de simplifier des deux côtés
6. En déduire $P(X = k)$
Reconnaître la loi de X
7. Loi de Y ?
8. Calculer $Cov(X, Y)$, X et Y sont-ils indépendants ?
9. Loi de (X, Y) ?

1. $Z \hookrightarrow B(N, \frac{1}{6})$
 $E(Z) = \frac{N}{6}, V(Z) = N \cdot \frac{1}{6} \cdot \frac{5}{6} = \frac{5N}{36}$
- 2.

Soit $k > n$

$$\mathbb{P}(X = k | Z = n) = 0$$

Soit $0 \leq k \leq n$

$$\mathbb{P}(X = k | Z = n) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$\text{Donc } X | Z = n \hookrightarrow B(n, p)$$

3. $\mathbb{P}((X = k) \cap (Z = n)) = \mathbb{P}(X = k | Z = n) \mathbb{P}(Z = n)$
 $\forall 0 \leq k \leq n \leq N$
 $\binom{n}{k} p^k (1-p)^{n-k} \binom{N}{n} \left(\frac{1}{6}\right)^n \left(\frac{5}{6}\right)^{N-n}$
4. ** $P(X = k) = 0$ **

$$\mathbb{P}(x = 0) = \bigcup_{n=0}^N (X = 0) \cap (Z = n)$$

événements incompatible donc

$$\mathbb{P}(x = 0) = \sum_{n=0}^N P((X = 0) \cap (Z = n))$$

$$\mathbb{P}(x = 0) = \sum_{n=0}^N (1-p)^n \binom{N}{n} \frac{1}{6}^n \frac{5}{6}^{N-n}$$

$$\mathbb{P}(x = 0) = \sum_{n=0}^N (1-p)^n \binom{N}{n} \frac{5^{N-n}}{6^N}$$

$$\mathbb{P}(x = 0) = \frac{1}{6^N} \sum_{n=0}^N \binom{N}{n} (1-p)^n 5^{N-n}$$

$$\mathbb{P}(x = 0) = \frac{1}{6^N} (6-p)^N$$

$$\mathbb{P}(x = 0) = \left(1 - \frac{p}{6}\right)^N$$

Formule du binôme de Newton

$$(a+b)^N = \sum_{n=0}^N \binom{N}{n} a^n b^{N-n}$$

$$5. \binom{n}{k} \binom{N}{n} = ? \binom{N}{k} \binom{N-k}{n-k}$$

$$\frac{n!}{k!(n-k)!} \frac{N!}{n!(N-n)!} = \frac{N!}{k!(N-k)!} \frac{(N-k)!}{(n-k)!(N-n)!}$$

les deux expressions se simplifient en

$$\frac{N!}{k!(n-k)!(N-n)!}$$

$$6) \mathbb{P}(X = k) = \binom{N}{k} \frac{p^k}{6^N} \sum_{n=k}^N \binom{N-k}{n-k} (1-p)^{n-k} 5^{N-n}$$

Posons $i = n - k$

$$\mathcal{P}(X = k) = \binom{N}{k} \frac{p^k}{6^N} \sum_{i=0}^{N-k} \binom{N-k}{i} (1-p)^i 5^{N-k-i}$$

$$= \binom{N}{k} \frac{p^k}{6^N} (1-p+5)^{N-k} = \binom{N}{k} \left(\frac{p}{6}\right)^k \left(1 - \frac{p}{6}\right)^{N-k}$$

$$X \hookrightarrow \mathcal{B}(N, p/6)$$

7. Même raisonnement pour la loi de Y

$$Y \hookrightarrow \mathcal{B}(N, q/6) \text{ où } q = 1 - p$$

8. $Cov(X, Y) = ?$

Rappel : Covariance d'une somme dans le cas general

$$Var(Z) = Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

$$Z \hookrightarrow \mathcal{B}(N, 1/6)$$

$$X \hookrightarrow \mathcal{B}(N, p/6)$$

$$Y \hookrightarrow \mathcal{B}(N, q/6)$$

$$\begin{aligned}
X &\hookrightarrow \mathcal{B}(n, p) \\
E(X) &= np \\
V(X) &= npq = np(1 - p)
\end{aligned}$$

$$\begin{aligned}
Cov(X, Y) &= \frac{1}{2}(V(Z) - V(X) - V(Y)) \\
Cov(X, Y) &= \frac{1}{2}\left(\frac{5N}{36} - \frac{Np}{6}\left(1 - \frac{p}{6}\right) - \frac{Nq}{6}\left(1 - \frac{q}{6}\right)\right) \\
Cov(X, Y) &= \frac{1}{2} \times \frac{1}{36}(5N - NP(6 - p) - Nq(6 - q)) \\
Cov(X, Y) &= \frac{1}{2} \times \frac{1}{36}(5N - 6Np + Np^2 - 6Nq + Nq^2) \\
Cov(X, Y) &= \frac{1}{2} \times \frac{1}{36}(5N - 6Np + Np^2 - 6N(1 - p) + N(1 - 2p + p^2)) \\
Cov(X, Y) &= \frac{1}{2} \times \frac{1}{36}(2Np^2 - 2Np) \\
Cov(X, Y) &= \frac{1}{36}(Np(p - 1)) \neq 0 \text{ car } p \neq 0, p \neq 1 \\
&\Rightarrow X \text{ et } Y \text{ ne sont pas indépendants}
\end{aligned}$$

9. Loi du couple (X, Y)

$$Z \in \llbracket 0, N \rrbracket$$

$$X = i \text{ et } Y = j$$

$$Z = i + j$$

$$\mathbb{P}((X = i) \cap (Y = j)) = \mathbb{P}((X = i) \cap (Z = i + j))$$

$$= \binom{n}{i} \binom{N}{i+j} p^i (1-p)^{N-(i+j)} \left(\frac{5}{6}\right)^{N-(i+j)} \left(\frac{1}{6}\right)^{i+j}$$

Exercice 4

Une urne contient une boule blanche et une boule noire. On y prélève une boule, chaque boule ayant la même probabilité d'être tirée.

On note sa couleur et on la remet dans l'urne, avec C boules de la même couleur de la boule tirée. On répète cette épreuve n fois. ($n \geq 2$)

On définit:

$$X_i = \begin{cases} 1 & \text{si on obtient une boule blanche au } i^{\text{ème}} \text{ tirage} \\ 0 & \text{sinon} \end{cases}$$

$$Z_p = \sum_{i=1}^p X_i$$

1. Déterminer la loi du couple (X_1, X_2) et en déduire la loi de X_2

2. Déterminer la loi de Z_2

3. Déterminer $\mathbb{P}(X_{p+1} = 1 / Z_p = k)$

4. Montrer que $\mathbb{P}(X_{p+1} = 1) = \frac{1 + C\mathbb{E}(Z_p)}{2 + pc}$

5. Montrer que $\forall p; 1 \leq p \leq n$

$$\mathbb{P}(X_p = 1) = \mathbb{P}(X_p = 0) = \frac{1}{2}$$

Récurrence sur p .

$$1. \mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = 0) = \frac{1}{2}$$

Donc $X_1 \hookrightarrow \mathcal{B}(p = \frac{1}{2})$ Bernoulli

$$\mathbb{P}((X_1 = i) \cap (X_2 = k)) = \mathbb{P}(X_2 = k | X_1 = i) \overbrace{\mathbb{P}(X_1 = i)}^{\frac{1}{2}}$$

1^{er} cas $i \neq k$

$$\mathbb{P}(X_2 = k | X_1 = i) = \frac{1}{2+C} \rightarrow \mathbb{P}((X_1 = i) \cap (X_2 = k)) = \frac{1}{2*(2+C)}$$

2^{me} cas $i = k$

$$\mathbb{P}(X_2 = i | x_1 = i) = \frac{1+C}{2+C}$$

$X_1 \backslash X_2$	0	1	Loi de X_1
0	$\frac{1+C}{2(2+C)}$	$\frac{1}{2(2+C)}$	$\frac{1}{2}$
1	$\frac{1}{2(2+C)}$	$\frac{1+C}{2(2+C)}$	$\frac{1}{2}$
Loi de X_2	$\frac{1}{2}$	$\frac{1}{2}$	1

$$X_2 \hookrightarrow \mathcal{B}(p = \frac{1}{2})$$

$$2 \leq p \leq n \text{ et } Z_p = \sum_{i=1}^p X_i$$

$$2. Z_2 = X_1 + X_2$$

$$Z_2(\omega) = \{0, 1, 2\}$$

$$\mathbb{P}(Z_2 = 0) = \mathbb{P}((X_1 = 0) \cap (X_2 = 0)) = \frac{1+C}{2(2+C)}$$

$$\mathbb{P}(Z_2 = 1) = \mathbb{P}((X_1 = 1) \cap (X_2 = 0)) + \mathbb{P}((X_1 = 0) \cap (X_2 = 1)) = \frac{1}{2+C}$$

$$\mathbb{P}(Z_2 = 2) = \mathbb{P}((X_1 = 1) \cap (X_2 = 1)) = \frac{1+C}{2(2+C)}$$

$$3. \mathbb{P}(X_{p+1} = 1 | Z_p = k)$$

$$Z_p(\omega) = [[0, p]]$$

$(Z_p = k) \Leftrightarrow$ au cours des p tirages on a obtenu k boules blanches et $(p - k)$ boules noires

au $(p + 1)$ ^{ième} tirage l'urne contient: $2 + pc$ boules dont $1 + kc$ boules blanches

$$\text{Donc } \mathbb{P}(X_{p+1} = 1 | Z_p = k) = \frac{1+kc}{2+pc}$$

$$4. \mathbb{P}(X_{p+1} = 1)?$$

$$(X_{p+1} = 1) = \bigcup_{k=0}^p \underbrace{[(X_{p+1} = 1) \cap (Z_p = k)]}_{\text{événements incompatibles}}$$

$$\mathbb{P}(X_{p+1} = 1) = \sum_{k=0}^p \mathbb{P}((X_{p+1} = 1) \cap (Z_p = k))$$

$$\mathbb{P}(X_{p+1} = 1) = \sum_{k=0}^p \mathbb{P}\left(\frac{X_{p+1} = 1}{Z_p = k}\right) \mathbb{P}(Z_p = k)$$

$$= \sum_{k=0}^p \left(\frac{1+kc}{2+pc}\right) \mathbb{P}(Z_p = k)$$

$$= \frac{1}{2+pc} \underbrace{\left(\sum_{k=0}^p \mathbb{P}(Z_p = k) \right)}_{=1} + c \underbrace{\sum_{k=0}^p k \mathbb{P}(Z_p = k)}_{E(Z_p)}$$

5. Raisonement par récurrence sur p

si $p = 1$, $\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = 0) = \frac{1}{2}$ $X_1 \hookrightarrow \mathcal{B}(\frac{1}{2})$

$p = 2$, $\mathbb{P}(X_2 = 1) = \mathbb{P}(X_2 = 0) = \frac{1}{2}$

$X_2 \hookrightarrow \mathcal{B}(\frac{1}{2})$

\underline{Hypothèse de récurrence} Supposons que cette propriété reste vraie jusqu'au rang p

$$Z_p = \sum_{i=1}^p X_i$$

$$E(Z_p) = \sum_{i=1}^p E(X_i) = \sum_{i=1}^p \frac{1}{2} = \frac{p}{2}$$

$$\Rightarrow \mathbb{P}(X_{p+1} = 1) = \frac{1+cp/2}{2+pc} = \frac{1}{2} \left(\frac{2+pc}{2+pc} \right) = \frac{1}{2}$$

$$\mathbb{P}(X_{p+1} = 0) = 1 - \frac{1}{2} = \frac{1}{2}$$

Exercice 5

$a \in \mathbb{R}$

X, Y 2 variables aléatoires à valeurs dans \mathbb{N}

$$\mathbb{P}((X = k) \cap (Y = j)) = \frac{a}{2^{k+1}j!}$$

1. Déterminer la constante a
2. Déterminer les lois marginales de X et Y
3. Déterminer l'indépendance des variables X et Y
4. Calculer la covariance $Cov(X, Y)$

1. Donc il faut que $a \geq 0$ et $\sum_{k=0, j=0} P_{kj} = 1$

$$\sum_{k,j} \mathbb{P}((X = k) \cap (Y = j)) = 1 \Rightarrow \sum_{k,j} \frac{a}{2^{k+1} j!} = 1$$

$$\Rightarrow a \sum_{k,j=0}^{+\infty} \frac{1}{2^{k+1} j!} = 1$$

$$\Rightarrow a \underbrace{\sum_{j=0}^{+\infty} \frac{1}{j!}}_e \underbrace{\sum_{k=0}^{+\infty} \frac{1}{2^{k+1}}}_1 = 1$$

$$\Rightarrow a \cdot e = 1 \Rightarrow a = \frac{1}{e} = e^{-1}$$

Rappel :

$$e^x = \sum_{k=0}^{+\infty} \frac{x^k}{k!} \forall x \in \mathbb{R}$$

$$e = \sum_{k=0}^{+\infty} \frac{1}{k!} (x = 1)$$

$$\sum_{k=0}^{+\infty} \frac{1}{2^{k+1}} = 1/2$$

Forme géométrique $\sum_{k=0}^{+\infty} a^k = \frac{1}{1-a}$ avec $|a| < 1$

$$\sum_{k=0}^{+\infty} \frac{1}{2^k} = \frac{1}{2} \frac{1}{1 - \frac{1}{2}} = 1$$

2. Loi marginal de X

$$\mathbb{P}(X = k) = \sum_{j=0}^{+\infty} \frac{a}{2^{k+1} j!}$$

$\forall k \in \mathbb{N}$, a constant et 2^{k+1} aussi donc

$$\mathbb{P}(X = k) = \frac{a}{2^{k+1}} \sum_{j=0}^{+\infty} \frac{1}{j!} = \frac{a \cdot e}{2^{k+1}} = \frac{1}{2^{k+1}}$$

Loi marginal de Y

$$\mathbb{P}(Y = j) = \sum_{k=0}^{\infty} \frac{a}{2^{k+1} j!} = \frac{a}{j!} \sum_{k=0}^{\infty} \frac{1}{2^{k+1}}$$

$$\mathbb{P}(Y = j) = \frac{a}{j!} \frac{1}{2} \sum_{k=0}^{\infty} (1/2)^k$$

$$= \frac{a}{j!} \frac{1}{2} \frac{1}{1 - \frac{1}{2}} = \frac{a}{j!} = \frac{e^{-1}}{j!}$$

$$\mathbb{P}(Y = j) = \frac{e^{-1}}{j!} \quad \forall j \in \mathbb{N}$$

3. Indépendance ?

$$\forall (j, k) \in \mathbb{N}^2, \mathbb{P}((X = k) \cap (Y = j)) \stackrel{?}{=} \mathbb{P}(X = k)\mathbb{P}(Y = j)$$

$$\mathbb{P}((X = k) \cap (Y = j)) = \frac{a}{2^{k+1}j!} = \frac{1}{2^{k+1}} \frac{a}{j!} \text{ avec } a = e^{-1} \text{ donc oui}$$

4. $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$ car X et Y sont indépendants.

$$Rq \rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} = 0$$

5) Statistique multidimensionnelle

a) Tableau des données

Les observations de p variables sur n individus sont rassemblées en une matrice X à n lignes et p colonnes

$$X = \begin{pmatrix} X_1^{(1)} & \dots & \vdots & \dots \\ X_2^{(1)} & \dots & \vdots & \dots \\ X_i^{(1)} & \dots & X_i^{(j)} & \dots \\ \vdots & \dots & \vdots & \dots \\ X_n^{(1)} & \dots & X_n^{(j)} & \dots \end{pmatrix}$$

$$X^{(j)} = \begin{pmatrix} X_1^{(j)} \\ X_2^{(j)} \\ \vdots \\ X_n^{(j)} \end{pmatrix}$$

$i^{\text{ème}}$ individu : ${}^t e^i = (X_i^{(1)}, X_i^{(2)}, \dots, X_i^{(p)})$

Ligne numéro i de X :

$$l_i = \begin{pmatrix} X_i^{(1)} \\ \vdots \\ X_i^{(p)} \end{pmatrix}$$

b) Matrice des poids

On associe à chaque individu un poids $p_i \geq 0$ (p_i : de choisir l'individu numero i)

$$\sum_{i=1}^n p_i = 1$$

$$D = \begin{pmatrix} p_1 & 0 & \dots & \dots & 0 \\ 0 & p_2 & 0 & \dots & 0 \\ \vdots & 0 & \ddots & \dots & 0 \\ 0 & \dots & \dots & 0 & p_n \end{pmatrix}$$

matrice de poids

$$\text{Si } P_i = \frac{1}{n}$$

$$D = \frac{1}{n} I_n \text{ (avec } I_n \text{ la matrice identité)}$$

c) Centre de gravité

Vecteur g de moyenne arithmétique de chaque variable :

$${}^t g = (\overline{X^{(1)}}, \overline{X^{(2)}}, \dots, \overline{X^{(p)}})$$

Moyenne de $X^{(j)}$:

$$\overline{X^{(j)}} = \sum_{i=1}^n P_i X_i^{(j)}$$

Le tableau des données centrées est Y :

$$\forall (i, j), y_i^{(j)} = X_i^{(j)} - \overline{X^{(j)}}$$

d) Matrice variance-covariance et matrice de corrélation

Déf. : On appelle matrice de variance-covariance la matrice V tq:

$$V_{ij} = Cov(X^{(i)}, X^{(j)})$$

$$V_{ii} = V(X^{(i)}) \text{ variance de } X^{(i)}$$

$$V(X^{(i)}) = \sum_{j=1}^n P_j (y_j^{(i)})^2$$

Une matrice de variance-covariance est toujours symétrique, ie. ${}^t V = V$.

$$\sigma(X^{(i)}) = \sqrt{\sum_{j=1}^n P_j (y_j^{(i)})^2} \text{ écart-type de } X^{(i)}$$

On note $D_{1/S}$ la matrice diagonale des inverses des écarts-types

$$D_{1/S} = \begin{pmatrix} 1/S_1 & 0 & \dots & 0 \\ 0 & \ddots & 0 & \vdots \\ \vdots & 0 & \ddots & 0 \\ 0 & \dots & 0 & 1/S_p \end{pmatrix}$$

$$S_j = \sigma(X^{(j)})$$

$$Z = Y D_{1/S}$$

Z : matrice des données **centrées** et **réduites**

$$Z_i^{(j)} = \frac{X_i^{(j)} - \bar{X}^{(j)}}{S_j} = \frac{y_i^{(j)}}{S_j}$$

La matrice de corrélation

$$R = D_{1/S} V D_{1/S}$$

$$= \underbrace{D_{1/S} {}^t Y}_{Z} \underbrace{D D_{1/S} Y}_{Z}$$

$$R = {}^t Z D Z \text{ symétrique}$$

6) Espace des individus et espace des variables

Chaque individu étant un vecteur défini par p coordonnées.

On note F l'espace des individus de dimension p . Les n individus forment un nuage de points dans F et g en est le centre de gravité.

La distance entre 2 individus l_i et l_j est définie par:

$$\langle e_i, e_j \rangle = {}^t e_i M e_j$$

où M : matrice symétrique définie positive.

$$({}^t M = M \langle M_u, u \rangle > 0, \forall u \neq 0)$$

$$\|u\| = \sqrt{\langle u, u \rangle} = \sqrt{{}^t u M u}$$

$$d^2(e_i, e_j) = \|e_i - e_j\|^2 = {}^t(e_i - e_j)M(e_i - e_j)$$

$$d(e_i, e_j) = \sqrt{{}^t(e_i - e_j)M(e_i - e_j)}$$

Si $M = I$ on retrouve le produit scalaire canonique

Si $M = D_{1/S^2}$ ce qui revient à diviser chaque caractère par son écart-type

Définition :

On appelle inertie totale du nuage de points la **moyenne pondérée des carrés des distances des points au centre de gravité**.

$$I_g = \sum_{i=1}^n p_i {}^t(e_i - g)M(e_i - g)$$

$$I_g = \sum_{i=1}^n p_i \|e_i - g\|^2$$

7) Espace des variables

$$X^{(j)} = \begin{pmatrix} X_1^{(j)} \\ \vdots \\ X_n^{(j)} \end{pmatrix} \text{ Variable numéro } j$$

Soit E l'espace des variables $\dim E = n$

Pour étudier la proximité des variables il faut préciser cet espace d'une métrique M

ici $M = D$ (matrice des poids)

$$\langle Y^{(j)}, Y^{(k)} \rangle = {}^t Y^{(j)} D Y^{(k)}$$

$$\text{Cov}(X^{(j)}, X^{(k)}) = \langle Y^{(j)}, Y^{(k)} \rangle$$

$$\|Y^{(j)}\| = \sqrt{{}^t Y^{(j)} D Y^{(j)}} = S_j$$

$$\rho(X^{(j)}, X^{(k)}) = \frac{\text{Cov}(X^{(j)}, X^{(k)})}{S_j S_k} = \frac{\langle Y^{(j)}, Y^{(k)} \rangle}{\|Y^{(j)}\| \|Y^{(k)}\|}$$

$$\rho(X^{(j)}, X^{(k)}) = \frac{\langle Y^{(j)}, Y^{(k)} \rangle}{\|Y^{(j)}\| \|Y^{(k)}\|} = \cos \Theta_{j,k}$$

$$|\rho(X^{(j)}, X^{(k)})| \leq 1$$


A une variable $X^{(j)}$ on peut associer un axe de l'espace des individus F et un vecteur de l'espace des variables.

On peut également déduire de $X^{(1)}, X^{(2)}, \dots, X^{(p)}$ de nouvelles variables par combinaison linéaire,

ce qui revient à projeter les individus sur de nouveaux axes de F .

Soit Δ un axe de l'espace des individus, engendré par un vecteur unitaire a (M normé à 1; $\|a\| = {}^t a M a = 1$ M métrique).

cf : projection des individus sur un axe (Projection M_orthogonale)



La liste des coordonnées C_i des individus sur Δ forme une nouvelle variable (variable artificielle)

$$C = \begin{pmatrix} C_1 \\ C_2 \\ \vdots \\ C_i \\ \vdots \\ C_n \end{pmatrix}$$

$$C_i = \langle l_i, a \rangle = {}^t e_i M a$$

$$C = X M a$$

$$C = {}^t e_i \underbrace{\begin{pmatrix} X^{(1)} & \dots & X^{(p)} \\ \vdots & & \\ X^{(1)} & \dots & X^{(p)} \end{pmatrix}}_X \underbrace{\begin{pmatrix} x & 0 & \dots & 0 \\ 0 & \ddots & 0 & \vdots \\ \vdots & 0 & \ddots & 0 \\ 0 & \dots & 0 & x \end{pmatrix}}_M \underbrace{\begin{pmatrix} a_i \\ \vdots \\ a \end{pmatrix}}_a$$

Mat S.D.P (on suppose que les variables $X^{(j)}$ sont centrés $Y = X$)

$$C = \underbrace{X M a}_u = X u = \sum_{j=1}^p u_j X^{(j)}$$

$$u = Ma$$

$$u = Ma \text{ (Si } M = I \Rightarrow u = a)$$

$${}^t a M a = 1$$

$${}^t u M u = {}^t a {}^t M M^{-1} M a$$

$$= {}^t a \underbrace{M M^{-1}}_I M a$$

$$= {}^t a M a = 1$$

$$\Rightarrow \boxed{{}^t u M^{-1} u = 1} \text{ on dit que } u \text{ et } M^{-1} \text{ normé à } 1$$

u : facteur

$$V(C) = {}^t C D C$$

$$= {}^t (X u) D (X u)$$

$$= {}^t u \underbrace{{}^t X D X}_V u$$

$$V(C) = {}^t u V u$$

Remarque :

si u est un vecteur propre de V

$$V u = \lambda u \text{ (}\lambda \text{ valeur propre de } V)$$

$$V(c) = {}^t u \lambda u = \lambda {}^t u u = \lambda$$

si ($M = I \Rightarrow ||u|| = 1$)

$$\boxed{V(c) = \lambda}$$

${}^t u M u$ correspond à la norme M de U , au carré
en effet, $\langle u, v \rangle = {}^t u M v$

8) Analyse des Composantes principales

Le principe de la méthode est d'obtenir une **représentation approchée** du **nuage** des n individus dans un **S.E.V de dimension faible**. Ceci s'effectue par projection.

$$\langle u, v \rangle = \sum_{i=1}^n u_i v_i = \alpha$$

(produit scalaire canonique)

M symétrique définie positif


$$\langle u, v \rangle = {}^t u M v$$

$$||u|| = \sqrt{{}^t u u} = \sqrt{{}^t u M u}$$

Le choix de l'espace de projection s'effectue selon le critère suivant qui revient à déformer le moins possible les distances en projections.

Il faut que l'inertie du nuage projeté sur le S.E.V F_k ($\underbrace{\dim F_k = k}_{\text{h faible par rapport à p}}$) soit maximale

P : Projection M_orthogonale sur F_k
 $P^2 = P$ et ${}^tPM = MP$ (M métrique)



Le nuage projeté sur F_k est associé au tableau X^tP
 Matrice de Var-Cov de nuage projeté

On applique P à la transposée de X : $X^tP = {}^t(P^tX)$

$${}^t(X^tP)D(X^tP)$$

$$P^t \underbrace{XDX^t}_V P = \boxed{PV^tP}$$

Remarque

- (1) $\text{Trace}(A) = \sum_{i=1}^n a_{ii} = \sum_{i=1}^n \lambda_i$ (λ_i valeurs propres de A)
- (2) $\text{Trace}(AB) = \text{Trace}(BA)$
- (3) $I(\text{inertie}) = \text{Trace}(VM) = \text{Trace}(MV)$

L'inertie du nuage projeté d'après (3) :

$$I_{NP} = \text{Tr}(PV^tPM)$$

$$\text{Tr}(\underbrace{P}_{A} \underbrace{VMP}_{B}) \text{ car } {}^tPM = MP$$

$$\text{Tr}(XMP^2) = \text{Tr}(VMP)$$

L'inertie du nuage projeté est : $\boxed{I_{NP} = \text{Tr}(VMP)}$

Le problème est donc de trouver P projection M_orthogonale de rang k maximisant la trace de VMP

ce qui déterminera F_k

Th: Soit F_k un S.E.V portant l'inertie maximale, alors le S.E.V de dimension $k + 1$ portant l'inertie maximale est la somme directe de F_k et des S.E.V de dimension 1 M orthogonal à F_k portant l'inertie maximale

$$F_{k+1} = F_k \oplus \vec{b}\mathbb{R} \text{ (Somme directe)}$$

$$F_k \cap \vec{b}\mathbb{R} = \{\vec{0}\} \setminus$$

et \

$$\dim F_k + \dim \vec{b}\mathbb{R} = k + 1 \setminus$$

$$\vec{b}\mathbb{R} = \{\lambda \vec{b}, \lambda \in \mathbb{R}\}$$

Rappels (Formes quadratiques et projection sur une droite)

$$g : \mathbb{R}^n \longrightarrow \mathbb{R}$$

$$\frac{dg}{du} = \begin{pmatrix} \frac{\partial g}{\partial u_1} \\ \vdots \\ \frac{\partial g}{\partial u_p} \end{pmatrix} \text{ gradient de } g$$

$$u = \begin{pmatrix} u_1 \\ \vdots \\ u_p \end{pmatrix}$$

$${}^t a u = \sum_{i=1}^p a_i u_i = g(u) (a_i \in \mathbb{R})$$

$$\frac{\partial g}{\partial u_i} = a_i V_i$$

$$\frac{\partial({}^t a u)}{\partial u} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix}$$

$$A \in \mathcal{M}_p(\mathbb{R})$$

$$\frac{d}{du} \left(\underbrace{{}^t u A u}_{\text{forme quadratique si } A \text{ est symétrique: } {}^t A = A} \right) = Au + {}^t A u$$

$$\frac{d}{du} ({}^t u A u) = 2Au$$

Projecteur M_orthogonale sur la droite Δ engendrée par a

$$P = \frac{a {}^t a M}{{}^t a M a}$$

$$a {}^t a = \begin{pmatrix} a_1 \\ \vdots \\ a_p \end{pmatrix} (a_1 \quad \cdots \quad a_p)$$

Inertie du nuage projeté :

$$I_{NP} = Tr(VMP)$$

$$= Tr(VM \frac{a {}^t a M}{{}^t a M a})$$

$$= \frac{1}{{}^t a M a} Tr(VM a {}^t a M) \text{ avec } Tr(AB) = Tr(BA)$$

$$= \frac{1}{{}^t a M a} Tr({}^t a M V M a)$$

$$I_{NP} = \frac{{}^t_a MVMa}{{}^t_a Ma} \frac{d}{da} \left(\frac{{}^t_a MVMa}{{}^t_a Ma} \right) = 0$$

$$\frac{({}^t_a Ma)2MVMa - ({}^t_a MVMa)2Ma}{({}^t_a Ma)^2}$$

$$({}^t_a Ma)MVMa = ({}^t_a MVMa)Ma$$

$$MVMa = \left(\frac{({}^t_a MVMa)}{({}^t_a Ma)} \right) Ma$$

En multipliant par M^{-1}

$$\rightarrow VMa = \left(\frac{({}^t_a MVMa)}{({}^t_a Ma)} \right) a$$

$$VMa = \lambda a$$

avec

$$\lambda = \frac{({}^t_a MVMa)}{({}^t_a Ma)}$$

a est un vecteur propre de VM associé à λ

Le S.E.V F_k de dimension k est engendré par les k valeurs propres de VM associés aux k plus grandes valeurs propres

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq \dots$$

$$\% \text{ d'inertie} : \frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p} \geq 80\%$$

Composantes principales

$$C^{(i)} = Yu^{(i)} \quad i = 1 - - - k$$

$$u^{(i)} = Ma^{(i)} \text{ facteur axes factoriels si } M = I \Rightarrow u^{(i)} = a^{(i)} \forall i$$

Corrélations entre $C^{(i)}$ et $X^{(i)}$

$$\rho(X^{(i)}, C^{(j)}) = \frac{Cov(X^{(i)}, C^{(j)})}{\sigma(X^{(i)})\sigma(C^{(j)})}$$

Exercice 1 (ACP)

$$\text{Soit } X = \begin{pmatrix} 3 & 8/5 & 5 \\ 4 & 2 & 6 \\ 3 & 9/5 & 6 \end{pmatrix}$$

$$p_i = \frac{1}{3} \forall i$$

$M = I_3$ (Métrique de l'espace des individus)

1. Déterminer le centre de gravité
2. Calculer Y (données centrées)
3. Calculer la matrice V
4. Diagonaliser V ($M = I_3$)
5. Déterminer les facteurs primitives
6. calculer les coefficients de corrélation

1. Déterminer le centre de gravité de ce nuage:

$$\bar{X}^{(j)} = \sum_{i=1}^3 p_i x_i^{(j)} = \frac{1}{3} \sum_{i=1}^3 x_i^{(j)}$$

$${}^t g = (\bar{X}^{(1)} \quad \bar{X}^{(2)} \quad \bar{X}^{(3)})$$

$$\bar{X}^{(1)} = \frac{10}{3}, \bar{X}^{(2)} = \frac{9}{5}, \bar{X}^{(3)} = \frac{17}{3}$$

$${}^t g = (\frac{10}{3}, \frac{9}{5}, \frac{17}{3})$$

$$\bar{X}^{(j)} = \sum_{i=1}^3 p_i x_i^j = \frac{1}{3} \sum_{i=1}^3 X_i^j$$

2) La matrice de données centrées

$$Y : y_i^{(j)} = X_i^{(j)} - \bar{X}^{(j)}$$

$$Y = \begin{pmatrix} -\frac{1}{3} & -\frac{1}{5} & -\frac{2}{3} \\ \frac{2}{3} & \frac{1}{5} & \frac{1}{3} \\ -\frac{1}{3} & 0 & \frac{1}{3} \end{pmatrix}$$

3. Matrice de Var-Covariance

$$V = {}^t Y D Y$$

$$D = \frac{1}{3} I_3$$

$$D = \begin{pmatrix} \frac{1}{3} & 0 & 0 \\ 0 & \frac{1}{3} & 0 \\ 0 & 0 & \frac{1}{3} \end{pmatrix} \text{ matrice de poids}$$

$$V = \frac{1}{3} {}^t Y Y$$

$$V_{ii} = \text{Var}(X^{(i)}) \Rightarrow \sigma(X^{(i)}) = \sqrt{\text{Var}(X^{(i)})} \forall i$$

$$V = \frac{1}{3} \begin{pmatrix} -\frac{1}{3} & \frac{2}{3} & -\frac{1}{3} \\ -\frac{1}{5} & \frac{1}{5} & 0 \\ -\frac{2}{3} & \frac{1}{3} & \frac{1}{3} \end{pmatrix} \begin{pmatrix} -\frac{1}{3} & -\frac{1}{5} & -\frac{2}{3} \\ \frac{2}{3} & \frac{1}{5} & \frac{1}{3} \\ -\frac{1}{3} & 0 & \frac{1}{3} \end{pmatrix} = \begin{pmatrix} \frac{2}{9} & \frac{1}{15} & \frac{1}{9} \\ \frac{1}{15} & \frac{2}{75} & \frac{1}{15} \\ \frac{1}{9} & \frac{1}{15} & \frac{2}{9} \end{pmatrix}$$

4. On doit diagonaliser MV $M = I_3$ donc on va diagonaliser V

Le polynôme caractéristique de V

$$P_V(\lambda) = \det(V - \lambda I_3)$$

$P_V(\lambda) = 0 \implies$ les racines de cette équation sont les valeurs propres de cette matrice

$$P_V(\lambda) = \begin{vmatrix} \frac{2}{9} - \lambda & \frac{1}{15} & \frac{1}{9} \\ \frac{1}{15} & \frac{2}{75} - \lambda & \frac{1}{15} \\ \frac{1}{9} & \frac{1}{15} & \frac{2}{9} - \lambda \end{vmatrix}$$

$$L_1 \leftarrow L_1 - L_3$$

$$P_V(\lambda) = \begin{vmatrix} \frac{1}{9} - \lambda & 0 & \lambda - \frac{1}{9} \\ \frac{1}{15} & \frac{2}{75} - \lambda & \frac{1}{15} \\ \frac{1}{9} & \frac{1}{15} & \frac{2}{9} - \lambda \end{vmatrix}$$

$$C_3 \leftarrow C_3 + C_1$$

$$P_V(\lambda) = \begin{vmatrix} \frac{1}{9} - \lambda & 0 & 0 \\ \frac{1}{15} & \frac{2}{75} - \lambda & \frac{2}{15} \\ \frac{1}{9} & \frac{1}{15} & \frac{1}{3} - \lambda \end{vmatrix} = (\frac{1}{9} - \lambda)((\frac{2}{75} - \lambda)(\frac{1}{3} - \lambda) - \frac{2}{15^2})$$

$$= (\frac{1}{9} - \lambda)(\lambda^2 - (\frac{2}{75} + \frac{1}{3})\lambda)$$

$$= (\frac{1}{9} - \lambda)(\lambda^2 - \frac{27}{75}\lambda) = 0$$

$$= (\frac{1}{9} - \lambda)\lambda(\lambda - \frac{9}{25}) = 0$$

$$\implies \lambda_1 = \frac{9}{25}, \lambda_2 = \frac{1}{9}, \lambda_3 = 0$$

Remarque : $\text{Trace}(V) = \lambda_1 + \lambda_2 + \lambda_3$

Valeur propre	$\lambda_1 = 0.36$	$\lambda_2 = 0.11$	$\lambda_3 = 0$
% d'inertie	$\frac{\lambda_1}{\lambda_1 + \lambda_2 + \lambda_3} = 76\%$	$\frac{\lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = 24\%$	0

Le pourcentage d'inertie apporté par le plan factoriel $\frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = 100\%$

On ordonne les valeurs propres dans l'ordre décroissant, et on en prend tant que l'on a pas atteint 80%.

par exemple, dans notre cas, $76\% < 80\%$ donc on rajoute λ_2 , puis comme $100\% > 80\%$, on s'arrête ici.

Sous-espace propre :

$$E_{\lambda_1} = E_{\frac{9}{25}} = \text{Ker}(V - \frac{9}{25}I_3)$$

$$\forall w = \begin{pmatrix} x \\ y \\ z \end{pmatrix} \in E_{\frac{9}{25}} \Leftrightarrow (V - \frac{9}{25}I_3) \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$\begin{cases} (1) : (\frac{2}{9} - \frac{9}{25})x + \frac{1}{15}y + \frac{1}{9}z = 0 \\ (2) : \frac{1}{15}x + (\frac{2}{75} - \frac{9}{25})y + \frac{1}{15}z = 0 \\ (3) : \frac{1}{9}x + \frac{1}{15}y + (\frac{2}{9} - \frac{9}{25})z = 0 \end{cases}$$

$$(1) - (3) : (\frac{1}{9} - \frac{9}{25})x + (\frac{9}{25} - \frac{1}{9})z = 0$$

$$x = z \text{ et } y = \frac{2}{5}x$$

$$E_{\frac{9}{25}} = \text{Vect} \left(\begin{pmatrix} 5 \\ 2 \\ 5 \end{pmatrix} \right) \text{ droite}$$

$$\|w_1\| = \sqrt{(5)^2 + (2)^2 + 5^2} = \sqrt{54}$$

$$u^{(1)} = \frac{1}{\sqrt{54}} \begin{pmatrix} 5 \\ 2 \\ 5 \end{pmatrix} \text{ normé 1}^{\text{er}} \text{ facteur}$$

$$E_{1/9} = \text{Ker}(V - \frac{1}{9}I_3)$$

$$\begin{cases} (1) : \frac{1}{9}x + \frac{1}{15}y + \frac{1}{9}z = 0 \\ (2) : \frac{1}{15}x + (\frac{2}{75} - \frac{1}{9})y + \frac{1}{15}z = 0 \\ (3) : \text{identique à (1)} \end{cases}$$

$$(1) - (2) \Rightarrow y = 0$$

$$(1) \Rightarrow x = -z$$

$$E_{\frac{1}{9}} = \text{Vect} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}$$

$$u^{(2)} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} 2^e \text{ facteur}$$

$(u^{(1)}, u^{(2)})$ base orthonormées

5. Composantes principales

$$C^{(i)} = Yu^{(i)} \quad i = 1, 2$$

$$u^{(1)} = \begin{pmatrix} 0,68 \\ 0,27 \\ 0,68 \end{pmatrix}$$

$$u^{(2)} = \begin{pmatrix} 0,71 \\ 0 \\ -0,71 \end{pmatrix}$$

$$C^{(1)} = \begin{pmatrix} -0,73 \\ 0,73 \\ 0 \end{pmatrix}$$

$$C^{(2)} = \begin{pmatrix} 0,24 \\ 0,24 \\ -0,47 \end{pmatrix}$$

6. Coefficient de corrélation

$$\rho(X^{(i)}, C^{(j)}) = \frac{\text{Cov}(X^{(i)}, C^{(j)})}{\sigma(X^{(i)})\sigma(C^{(j)})}$$

$$\text{Cov}(X^{(i)}, C^{(j)}) = \langle y^{(i)}, C^{(j)} \rangle$$

$$\text{Cov}(X^{(1)}, C^{(1)}) = \langle y^{(1)}, C^{(1)} \rangle$$

$$= {}^t y^{(1)} DC^{(1)}$$

$$M = D = \frac{1}{3}I$$

$$= \frac{1}{3}((- \frac{1}{3})(-0,73) + (\frac{2}{3})(0,73))$$

$$\sigma(X^{(1)}) = \sqrt{\text{Var} X^{(1)}} = 0,47$$

$$\sigma(C^{(1)}) = \|C^{(1)}\| = \sqrt{(\frac{1}{3})((-0,73)^2 + (0,73)^2)} = 0.59 \simeq 0.60$$

$$\rho(X^{(1)}, C^{(1)}) = \frac{\text{Cov}(X^{(1)}, C^{(1)})}{\sigma(X^{(1)})\sigma(C^{(1)})} = \boxed{0,87}$$

	$C^{(1)}$	$C^{(2)}$
$X^{(1)}$	0,87	0,5
$X^{(2)}$	1	0
$X^{(3)}$	0,87	-0,5

Exercice 2 (ACP)

Même questions que l'exercice 1

$$X = \begin{pmatrix} 16 & 2 & 0 \\ 8 & 12 & 10 \\ 12 & 16 & 14 \\ 20 & 8 & 14 \\ 16 & 4 & 10 \\ 0 & 6 & 12 \end{pmatrix}$$

$$p_i = \frac{1}{6} \forall i$$

 $M = I_3$ dans l'espace des individus

$$1. \bar{X}^{(1)} = \frac{72}{6} = 12$$

$$\bar{X}^{(2)} = \frac{48}{6} = 8$$

$$\bar{X}^{(3)} = \frac{60}{6} = 10$$

$${}^t g = (12, 8, 10)$$

2.

$$Y = \begin{pmatrix} 4 & -6 & -10 \\ -4 & 4 & 0 \\ 0 & 8 & 4 \\ 8 & 0 & 4 \\ 4 & -4 & 0 \\ -12 & -2 & 2 \end{pmatrix}$$

$$3. V = \frac{1}{6} {}^t Y Y$$

$$V = \frac{1}{6} \begin{pmatrix} 4 & -4 & 0 & 8 & 4 & -12 \\ -6 & 4 & 8 & 0 & -4 & -2 \\ -10 & 0 & 4 & 4 & 0 & 2 \end{pmatrix} \begin{pmatrix} 4 & -6 & -10 \\ -4 & 4 & 0 \\ 0 & 8 & 4 \\ 8 & 0 & 4 \\ 4 & -4 & 0 \\ -12 & -2 & 2 \end{pmatrix} = \begin{pmatrix} \frac{128}{3} & -\frac{16}{3} & -\frac{4}{3} \\ -\frac{16}{3} & \frac{68}{3} & \frac{44}{3} \\ -\frac{16}{3} & \frac{44}{3} & \frac{68}{3} \end{pmatrix}$$

4. Diago de V

$$P_V(\lambda) = \begin{vmatrix} \frac{128}{3} - \lambda & -\frac{16}{3} & -\frac{16}{3} \\ -\frac{16}{3} & \frac{68}{3} - \lambda & \frac{44}{3} \\ -\frac{16}{3} & \frac{44}{3} & \frac{68}{3} - \lambda \end{vmatrix}$$

$$C_1 \leftarrow C_1 + C_2 + C_3$$

$$P_V(\lambda) = \begin{vmatrix} 32 - \lambda & -\frac{16}{3} & -\frac{16}{3} \\ 32 - \lambda & \frac{68}{3} - \lambda & \frac{44}{3} \\ 32 - \lambda & \frac{44}{3} & \frac{68}{3} - \lambda \end{vmatrix} = (32 - \lambda)$$

$$L_2 \leftarrow L_2 - L_1$$

$$L_3 \leftarrow L_3 - L_1$$

$$= (32 - \lambda) \begin{vmatrix} 28 - \lambda & 20 \\ 20 & 28 - \lambda \end{vmatrix}$$

$$P_V(\lambda) = (32 - \lambda)((28 - \lambda)^2 - 20^2)$$

$$= (32 - \lambda)(28 - \lambda - 20)(28 - \lambda + 20)$$

$$\boxed{P_V(\lambda) = (32 - \lambda)(8 - \lambda)(48 - \lambda)}$$

$$\boxed{\lambda_1 = 48 > \lambda_2 = 32 > \lambda_3 = 8}$$

Valeur propres	λ_1	λ_2	λ_3
pourcentage d'inertie	$\frac{48}{88} = 0,54$	$\frac{32}{88} = 0,36$	$\frac{8}{88} = 0,09$

$$\boxed{\frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \lambda_3} = \frac{80}{88} = 90\%}$$

Axes factoriels :

$$u^{(1)} = \begin{pmatrix} \frac{\sqrt{6}}{3} \\ -\frac{\sqrt{6}}{6} \\ -\frac{\sqrt{6}}{6} \end{pmatrix}, u^{(2)} = \begin{pmatrix} \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} \\ \frac{\sqrt{3}}{3} \end{pmatrix} \text{ base orthonormée}$$

Composantes principales :

$$C^{(1)} = Y u^{(1)} = \begin{pmatrix} 4\sqrt{6} \\ -2\sqrt{6} \\ -2\sqrt{6} \\ 2\sqrt{6} \\ 2\sqrt{6} \\ -4\sqrt{6} \end{pmatrix}$$

$$C^{(2)} = Y u^{(2)} = \begin{pmatrix} -4\sqrt{3} \\ 0 \\ 4\sqrt{3} \\ 4\sqrt{3} \\ 0 \\ -4\sqrt{3} \end{pmatrix}$$

6. coefficient de covariance

	$C^{(1)}$	$C^{(2)}$
$X^{(1)}$	0,87	0,5
$X^{(2)}$	-0,59	0,69
$X^{(3)}$	-0,59	0,69

$$\rho(X^{(i)}, C^{(j)}) = \frac{Cov(X^{(i)}, C^{(j)})}{\sigma(x^{(i)})\sigma(C^{(j)})}$$

Méthode ACP

Méthode ACP = Analyse Composante Principale

On a une matrice

P variables (colonnes)

n Individus (lignes) : population de pressions, vitesses, objets, habitants...

Un élément de la matrice i, j = valeur de P_j pour l'individu i

Inertie (<http://jybaudot.fr/Stats/inertie.html>) : moyenne des distances au carré des points au **barycentre** (<https://fr.wikipedia.org/wiki/Barycentre>).