

# Introduction à l'imagerie médicale, cours 2

Élodie PUYBAREAU

# Plan du cours

1 Qualité et Débruitage

2 Recalage d'images médicales

3 Segmentation

# QUALITÉ ET DÉBRUITAGE

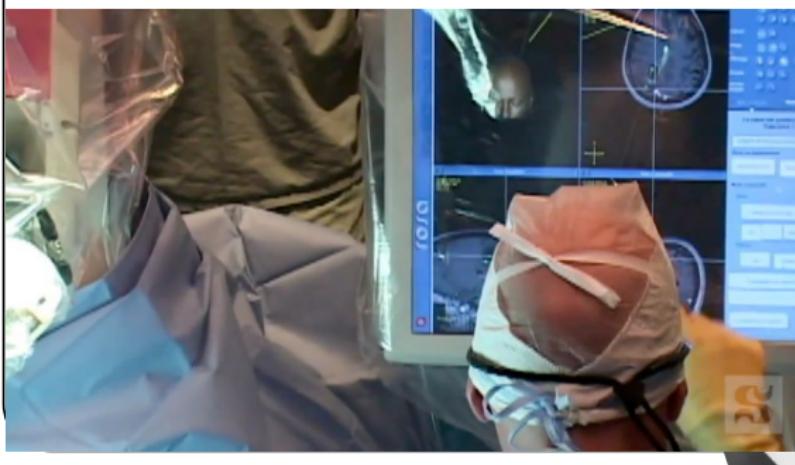
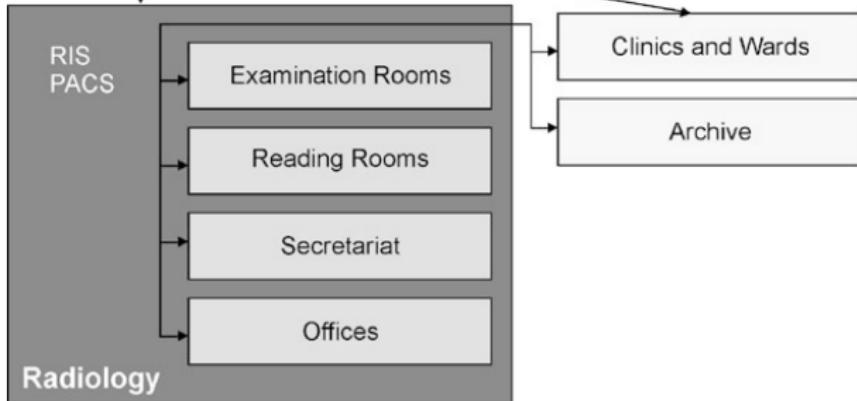
D'après les cours de Maxime Descoteaux

<http://scil.dinf.usherbrooke.ca/fr/teaching/imn530>

# Image médicale

- DICOM -  
Digital Image Communication in Medicine
- PACS -  
Picture Archiving and communication system
- RAS -  
Radiologist Aid System

# Hospital Information System (HIS)



# DICOM

- Format le plus répandu dans les hôpitaux (tous les nouveaux appareils cliniques supportent le format DICOM)
- Problème... plus qu'un format bien défini
- Boîte à fourre-tout
  - Les constructeurs définissent leur “tag” ou étiquettes maison
- Cauchemar pour les traiteurs d’images
  - Pour être éthique -> dénomalisation nécessaire!

# DICOM et autres formats

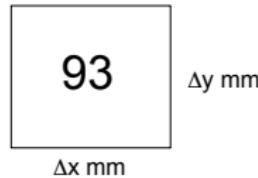
- Entête (header) et fichiers de données
  - Série de fichiers 2D dans un répertoire
  - Série de fichiers 3D
  - Un fichier 4D
- Des milliers de convertisseurs et lecteurs de dicom et autres formats de fichiers...  
( Matlab: dicominfo, dicomread, dicomwrite  
support dans ImageJ et SimpleITK)

## Autres formats / extensions

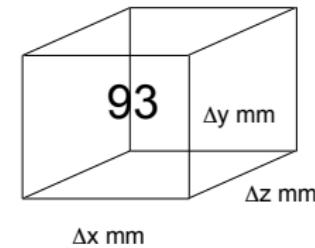
- DICOM (.dcm)
- NIFTI (.nii)
- Analyze (.hdr .img)
- Gis (.ima .dim) -> France
- Minc (.mnc) -> Montreal Neurological Institute (MNI)
- Nrrd (.nrrd) -> USA

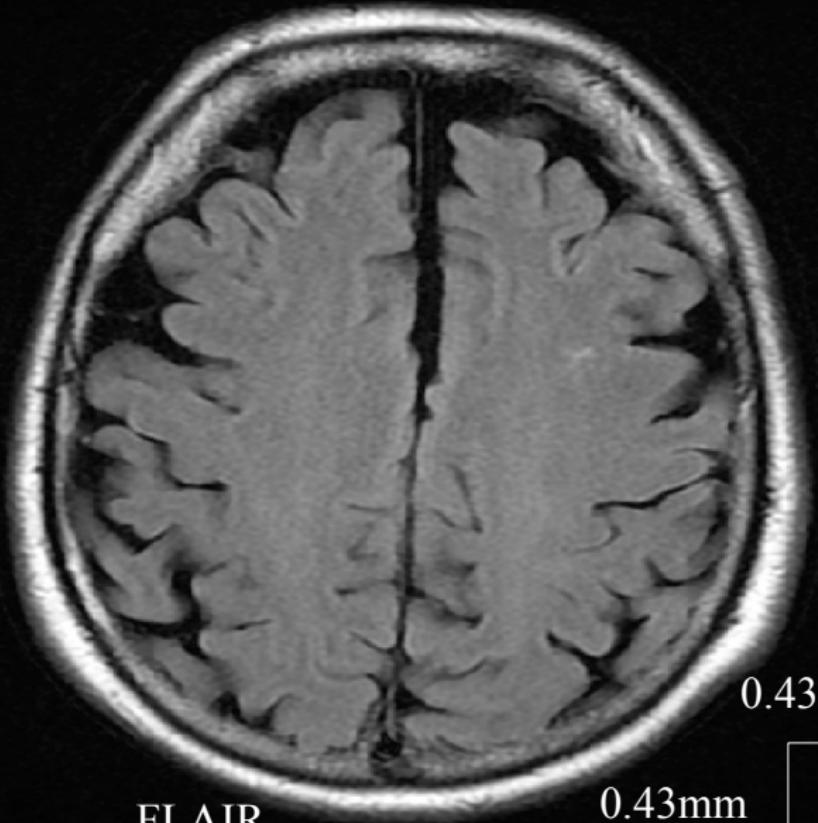
# Résolution

**Pixel**  
“picture element”



**Voxel**  
“Volume element”





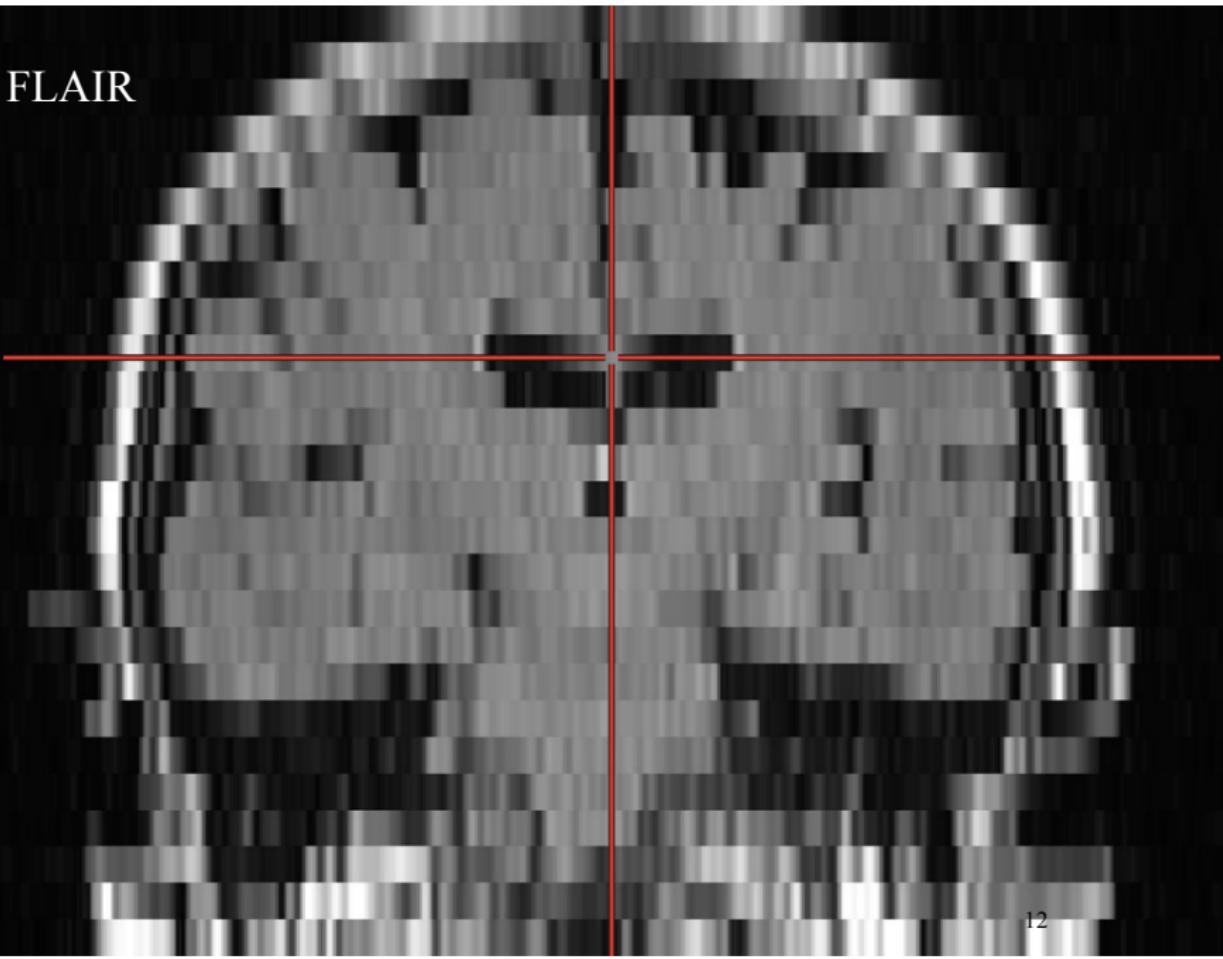
FLAIR

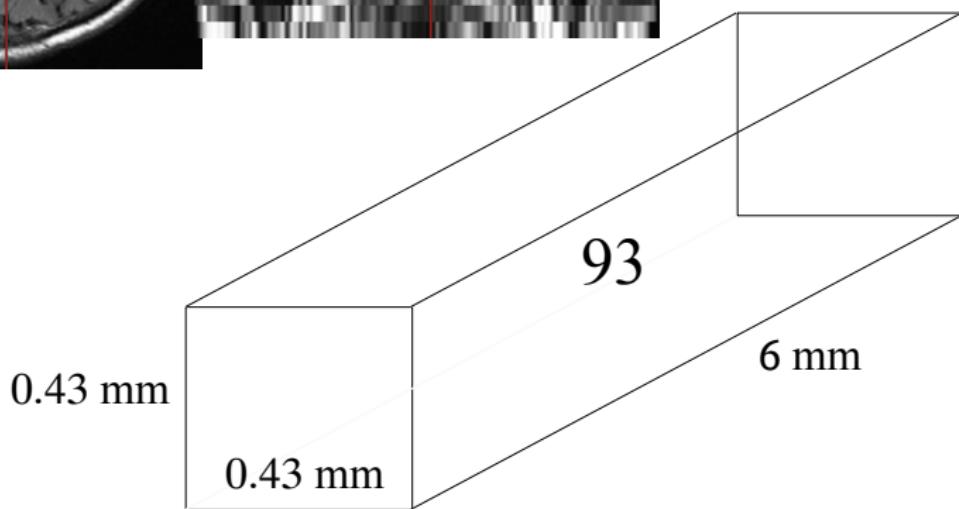
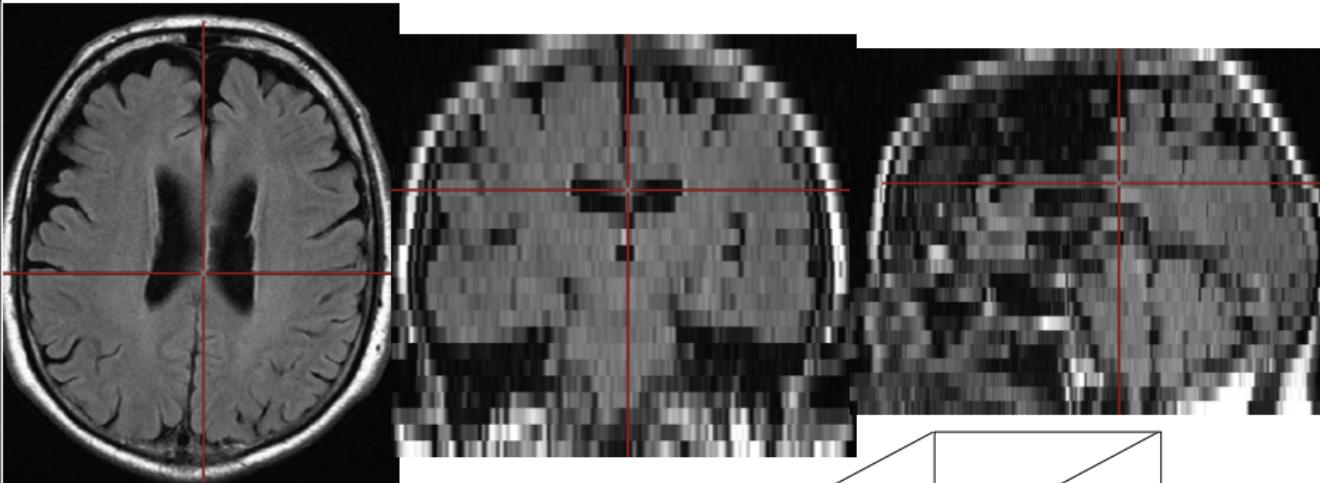
0.43mm



0.43mm

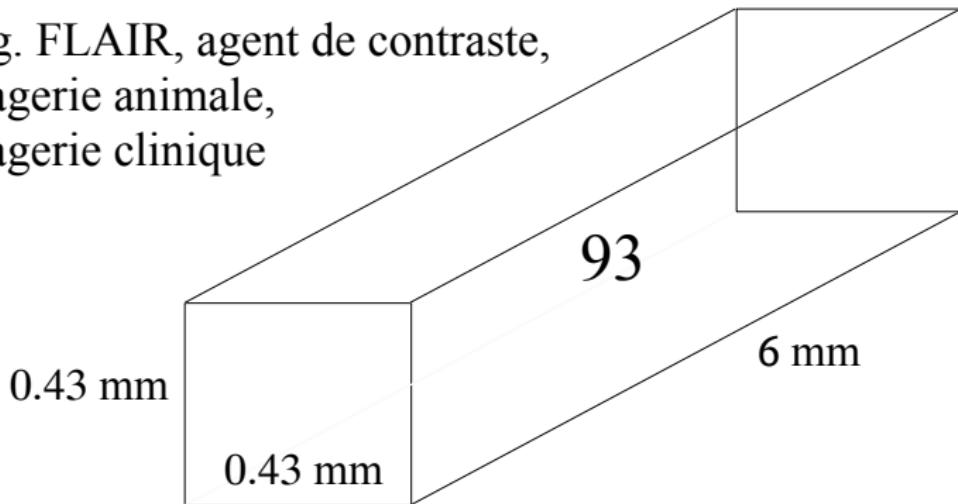
FLAIR





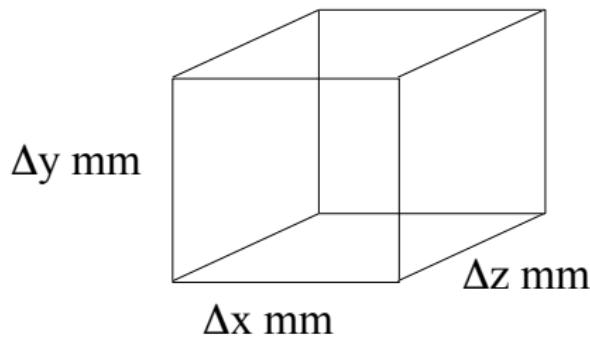
# Imagerie numérique 3D

- Acquisition anisotrope
- Souvent,  $\Delta x = \Delta y \neq \Delta z$   
( $\Delta z \gg$  résolution dans le plan)
- E.g. FLAIR, agent de contraste,  
imagerie animale,  
imagerie clinique



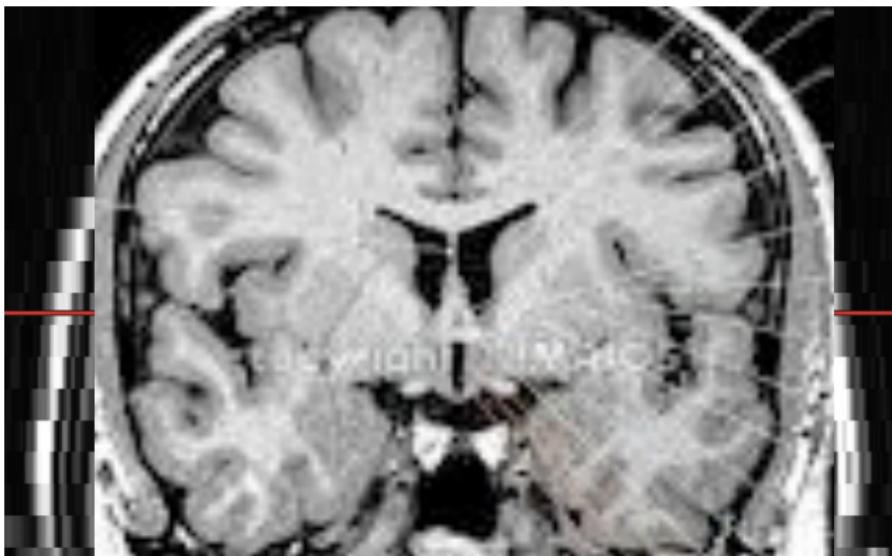
# Imagerie numérique 3D

- Acquisition isotrope
- Souvent,  $\Delta x = \Delta y = \Delta z$
- E.g. T1 isotrope, IRM de diffusion, IRM fonctionnelle

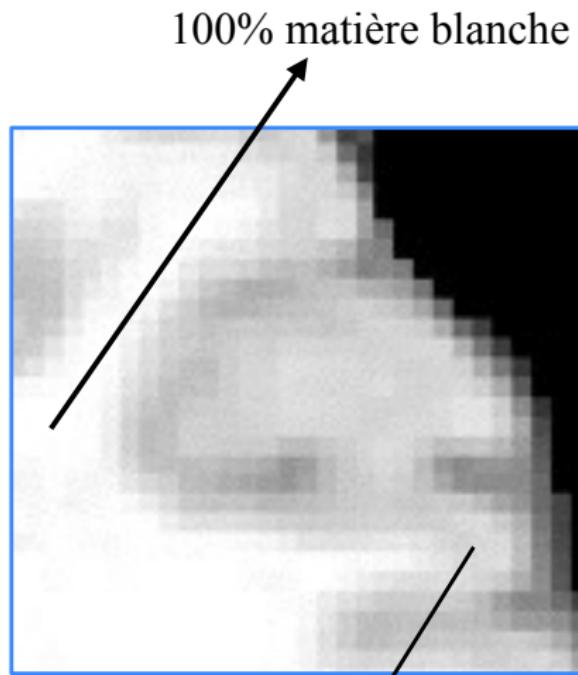
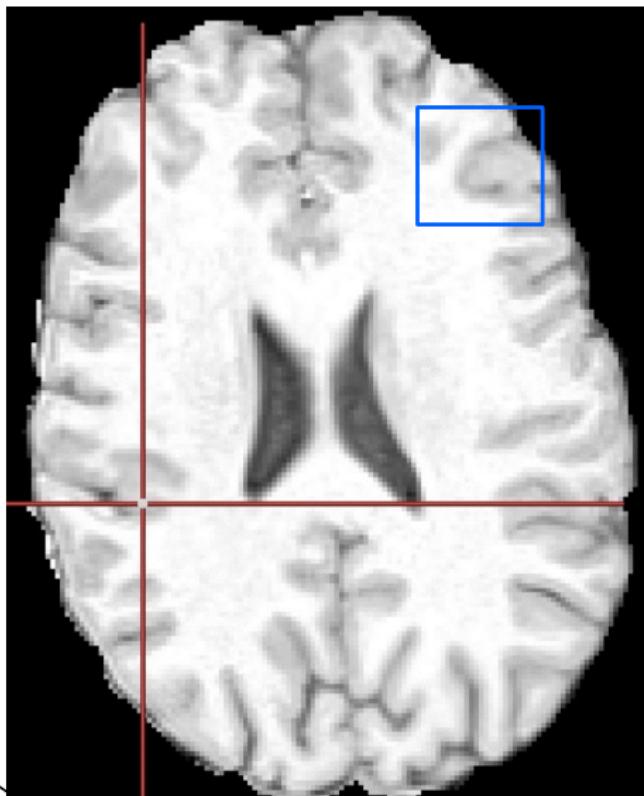


# Volume partiel

- Les structures sont souvent plus petites que la résolution de l'image. Cela crée ce qu'on appelle du volume partiel



# Volume partiel - 1 voxel mélange de plusieurs tissus



100% matière blanche  
100% matière grise  
cortex

# Information importante dans l'entête

- Taille du voxel
- Taille de l'image
- Matrice de transformation
- Type des données

\*\*\*\*\*  
Image: "Rat Sprague-Dawley (LDS97-j18) [PT]"  
\*\*\*\*\*

Format: DICOM  
Dimensions: 240 x 240 x 1  
Voxel size: 0.25 x 0.25 x 1.175  
Dimension labels: 0. left->right (mm)  
1. posterior->anterior (mm)  
2. inferior->superior (mm)  
Data type: unsigned 16 bit integer (little endian)  
Data layout: [ -0 -1 +2 ]  
Data scaling: offset = 0, multiplier = 2.06052e-06  
Comments: Rat Sprague-Dawley (LDS97-j18) [PT]  
DOS: 23/02/2010 12:20:00  
Transform: 1 0 0 -59.75  
0 1 0 -59.75  
0 0 1 0  
0 0 0 1

# Qualité de l'image

# Améliorer la qualité d'image: comment?

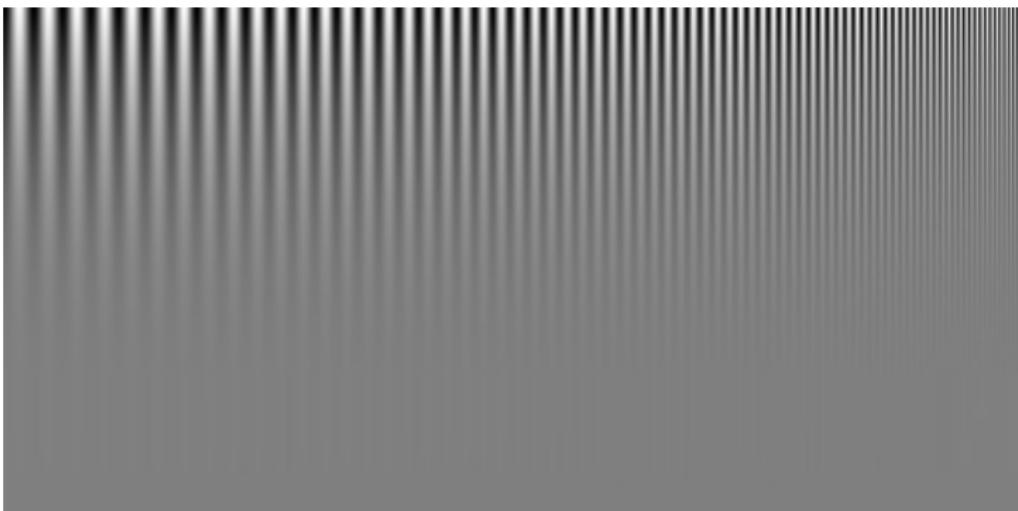
- Améliorer les séquences et acquisitions
  - Réduire les distorsions
  - Augmenter le rapport signal à bruit
- Algorithme de correction et débruitage
- Les traiteurs d'image ont leur mot à dire!  
(surtout pour le débruitage, pour les artéfacts, surtout les physiciens de l'IRM)

# Rehaussement d'images

- Améliorer la perception visuelle des objets pour un observateur humain
- Souvent, petit pré-traitement pour que les analyses suivantes, plus complexes (segmentation-recalage), se passent mieux
- Égalisation d'histogramme
- Rehaussement de contours
- Débruitage

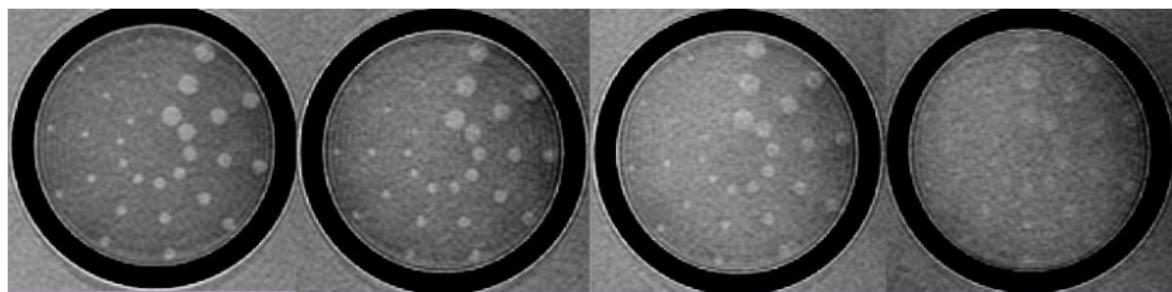
# Contraste et résolution

- La résolution perçue dépend du contraste dans l'image
- Pas de bonne mesure perceptuelle de la résolution dans une image



# Résolution spatiale & contraste

- L'effet du contraste sur la perception: les trous du fantôme se dégrade en réduisant le contraste de 5.1%, 3.7%, 2.2%, 1%



Vous pouvez jouer avec le simulateur BrainWeb:  
<http://brainweb.bic.mni.mcgill.ca/cgi/brainweb1>

# Quelques définitions de contrastes

- Contraste de Michelson :

$$C_{\text{Michelson}} = \frac{l_{\max} - l_{\min}}{l_{\max} + l_{\min}}$$

- Contraste Root-Mean-Square (RMS) :

$$C_{\text{rms}}(f) = \sqrt{\frac{1}{MN-1} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} (l(i, j) - \bar{l})^2} \quad \bar{l} = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} l(i, j)$$

# Contraste

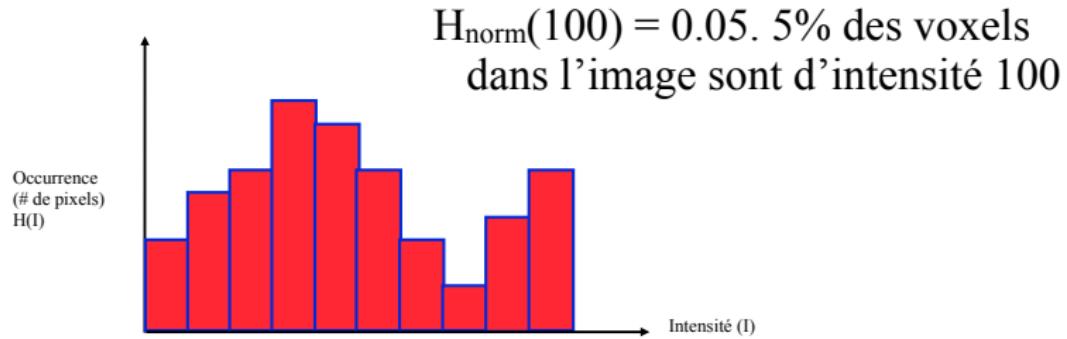


$C_{\text{Michelson}}$  égaux

$C_{\text{rms}} = 0.006$

$C_{\text{rms}} = 0.018$

# Histogramme

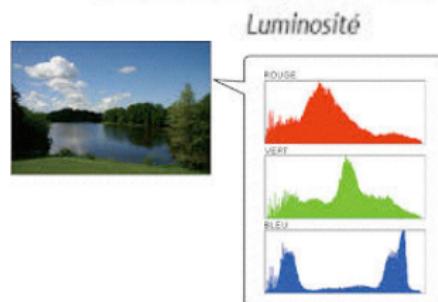
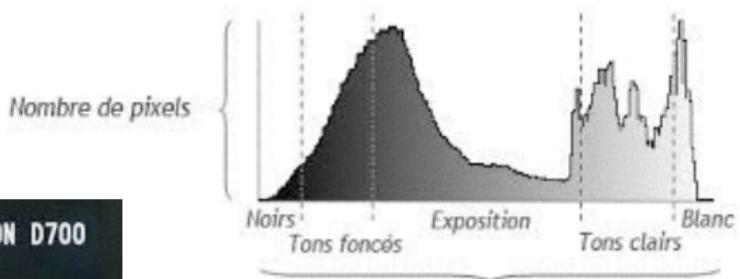


- $H(l)$  représente le # de pixels d'intensité  $l$

$$H_{\text{norm}}(l) = \frac{H(l)}{\sum_{k=I_{\min}}^{I_{\max}} H(k)}$$

Sera utile pour le recalage plus tard

# Histogramme



Première étape pour connaître le contenu d'une image.

# Bruit et débruitage

Remerciements et inspirations:

- Pierre-Marc Jodoin - IMN259

<http://www.dmi.usherb.ca/~jodoin/cours/imn259/index.html>

- Pierrick Coupé - Marseille, France

[http://www.labri.fr/index.php?n=Annuaires.Profile&id=Coupe\\_ID1317371796](http://www.labri.fr/index.php?n=Annuaires.Profile&id=Coupe_ID1317371796)

# Bruit

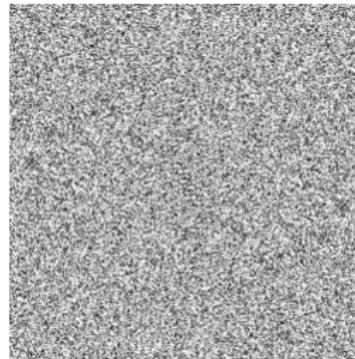
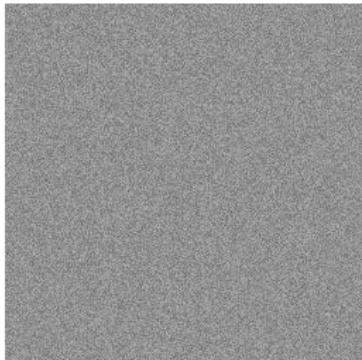
$$g = f * h + \eta$$



Bruit additif non corrélé

En général, **le bruit est blanc**, c-à-d que sa distribution fréquentielle est globalement uniforme

Bruit blanc ( $\eta$ )

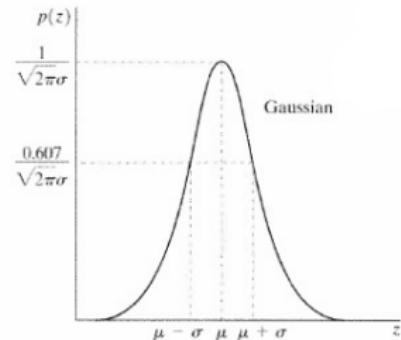


# Bruit

Une variable de bruit «  $z$  » est considérée comme étant une **variable aléatoire** suivant une **densité de probabilité**

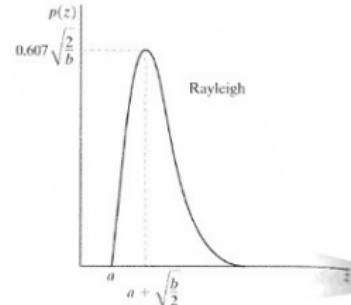
## Bruit gaussien

$$p(z) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(z-\mu)^2}{2\sigma^2}}$$

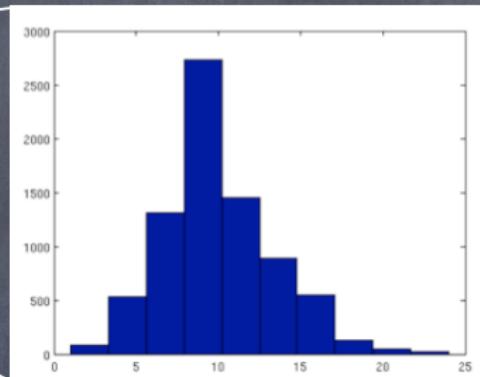


## Bruit de Rayleigh ou appelé bruit Ricien

$$p(z) = \frac{2(z-a)}{b} e^{-\frac{(z-a)^2}{b}} \quad \forall z \geq a$$

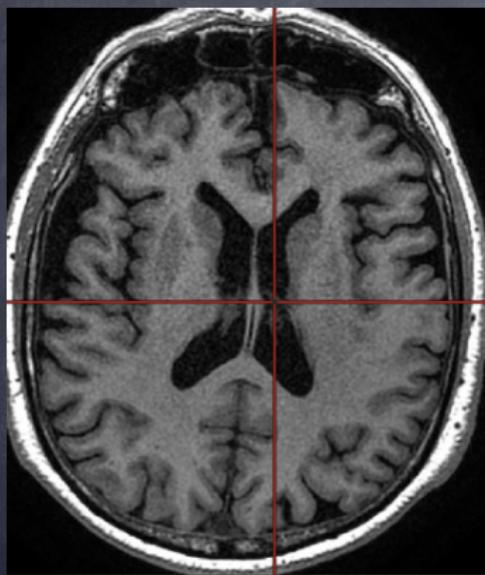


# Bruit Gaussien



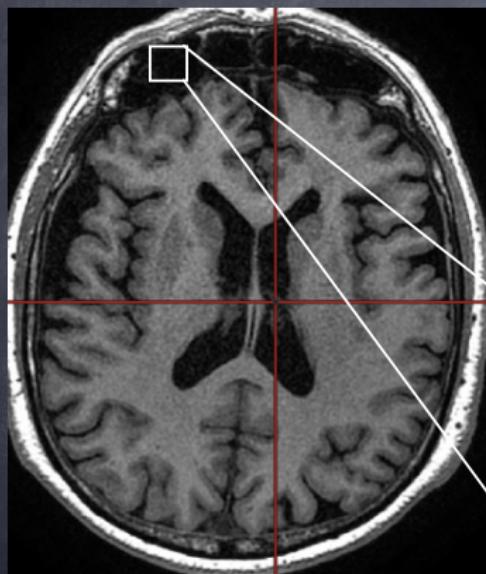
- Nature du bruit dépend de la modalité d'imagerie

# Bruit

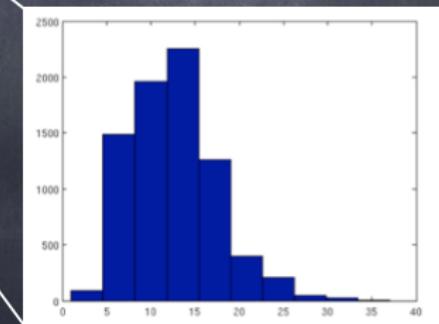


- ➊ Nature du bruit dépend de la modalité d'imagerie

# Bruit



- Nature du bruit dépend de la modalité d'imagerie

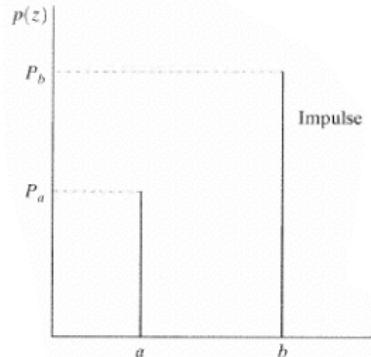


Ricien

# Bruit

Bruit poivre et sel

$$p(z) = \frac{1}{b-a} \quad \forall a \leq z \leq b$$



Exemple de bruit sur une image composée de 3 régions uniformes

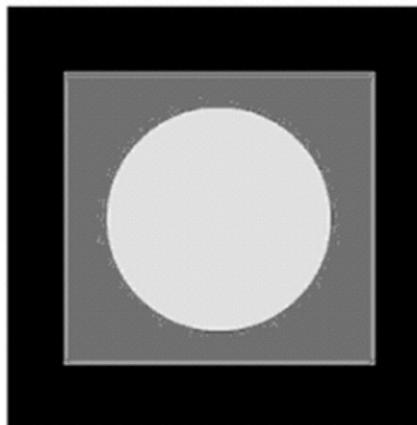
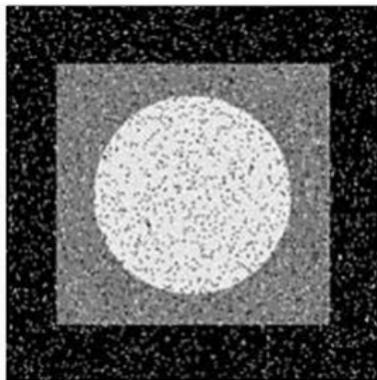
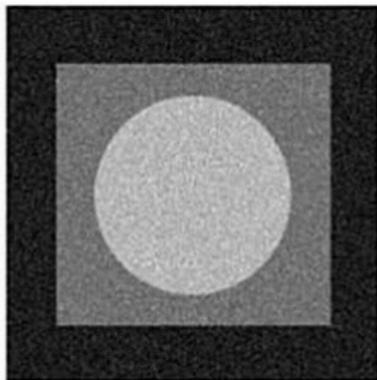
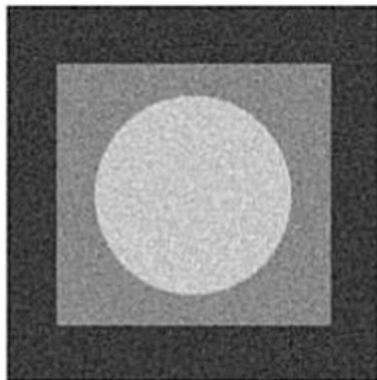


Image d'origine non bruitée



# Métriques de qualité

Une métrique de qualité est une fonction qui mesure la **qualité visuelle** d'une image. Ainsi plus une image est dégradée par du flou, du bruit ou des artéfacts de compression (e.g. JPEG) plus la qualité sera faible.



Qualité faible



Qualité bonne



Qualité excellente

# Métriques de qualité les plus fréquentes en imagerie médicale

Erreur quadratique moyenne (*mean square error*)

$$MSE(f, g) = \frac{1}{nm} \sum_{i,j} (f(i, j) - g(i, j))^2$$

Ratio signal sur bruit (*signal to noise ratio*) en DB

$$\begin{aligned} SNR(f, g) &= 10 \log \frac{P_f}{P_{f-g}} \\ &= 10 \log \frac{\sum_y f(i, j)^2}{\sum_y (f(i, j) - g(i, j))^2} \\ &= 20 \log \frac{\sum_y f(i, j)}{\sum_y |f(i, j) - g(i, j)|} \end{aligned}$$

# Métriques de qualité

Une métrique beaucoup plus souvent utilisée est le PSNR en traitement d'image

Ratio signal sur bruit impulsionnel (*Peak signal to noise ratio*)

$$PSNR(f, g) = 10 \log \left( \frac{d^2}{MSE(f, g)} \right)$$

où  $d$  est la valeur maximale dans l'image

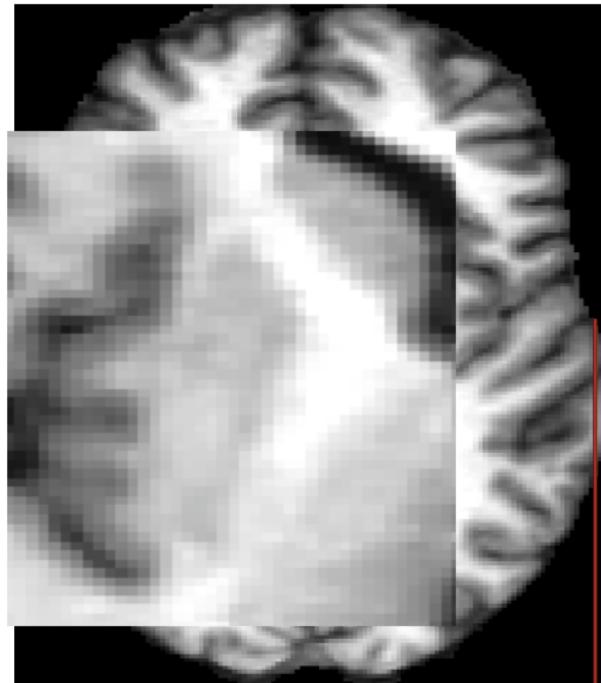
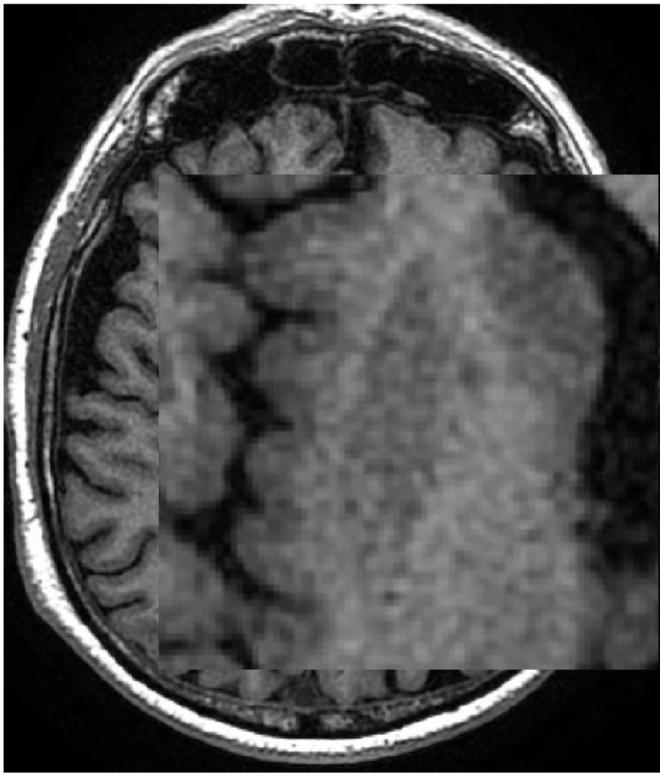
Le problème avec MSE, SNR et PSNR est qu'une légère modification d'une image, parfois même imperceptible par l'œil humain, peut avoir un effet majeur sur ces métriques. Par conséquent, d'autres métriques ont été proposés. Une des plus utilisée est **MSSIM**

Z Wang, A Bovik, H. Sheikh, E. Simoncelli **Image Quality Assessment: From Error Visibility to Structural Similarity**, IEEE TIP, 13(4), 2004

# Problème avec ces métriques “d’analyse d’image classique”

- Besoin d’une vérité sans bruit!!!  
(impossible pour nous)

# Rapport signal à bruit (SNR)

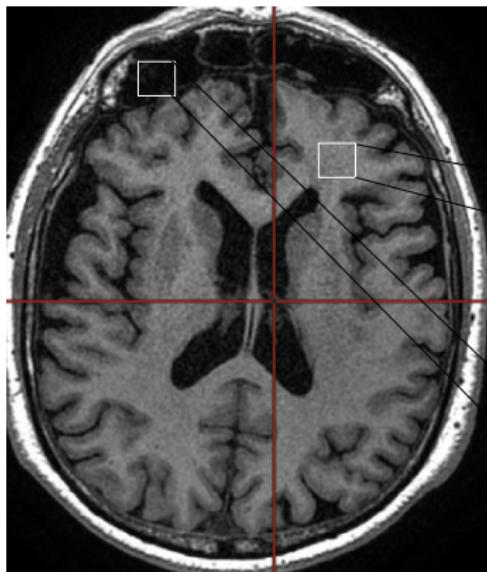


Quelle image préférez-vous?

# En pratique, on estime le SNR à partir de l'image

- Estimation de la moyenne du signal d'intérêt
- Estimation de l'écart type du bruit
- $\text{SNR} = \text{mean}( S ) / \text{std}( \text{fond} )$ 
  - Si le bruit est supposé Gaussien
  - Recherche active pour les autres types de bruit  
(Ricien, Chi-carré)

# Estimation du SNR



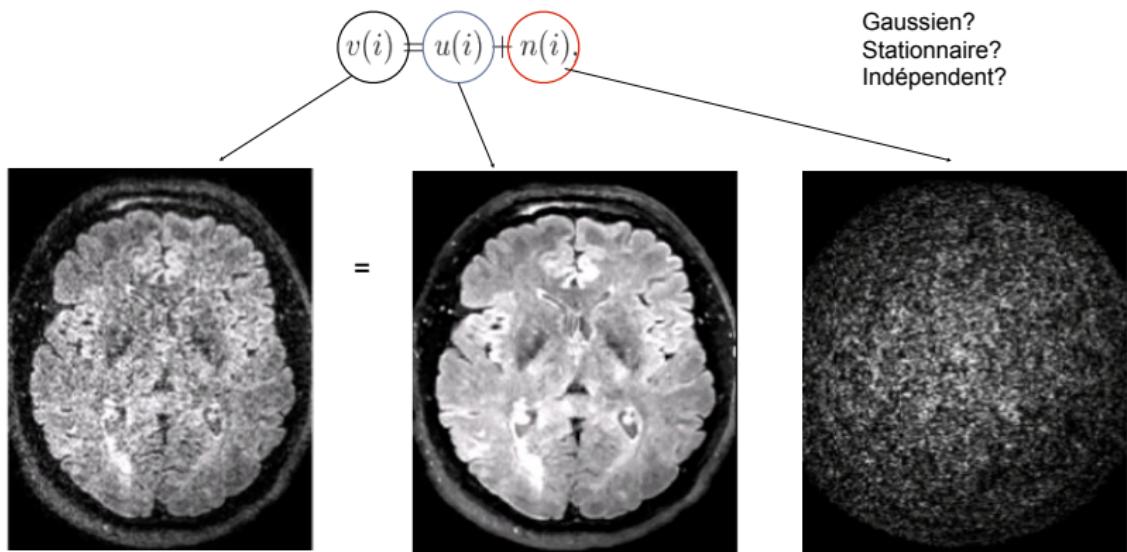
Potentiellement plusieurs S intéressants dans lequel il faut rapporter le SNR

mean( S )

$$\text{SNR} = \text{mean}(S) / \text{std}( \text{fond} )$$

std( fond )

# Débruitage



Problème: On ne connaît pas l'image sans bruit ni la nature du bruit exacte...

# Débruitage: hypothèse classique

- Les images sont constantes par morceaux
- Les voisinages de pixels/voxels sont largement corrélés
- Débruitage: “moyennage local de voxels”
- “moyennage” intelligent

# Débruitage

- Filtrage linéaire
  - Filtrage passe-bas
  - Convolution avec une Gaussienne
  - Diffusion linéaire
  - Problème:
    - Lissage isotrope. Lisse les contours en enlevant du bruit.
    - Besoin d'un modèle de contour
- Filtrage non-linéaire
  - Filtrage le long des contours, pas à travers.
  - Préserve les contours
- Méthodes avancées
  - NL means
  - Block matching

# Diffusion linéaire

L'équation  $\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial^2 x}$  est souvent appelée l'équation de la **diffusion de la chaleur**

En 2D, cette équation prend la forme

$$\frac{\partial u}{\partial t} = \operatorname{div}(g \nabla u)$$

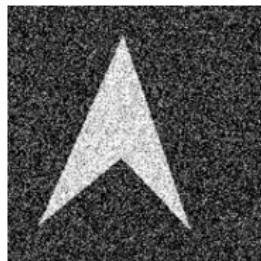
où  $g$  est un terme de « diffusivité », généralement positif.

En traitement d'images, la fonction  $u(x,y,t)$  peut se comprendre comme une image qui évolue dans le temps. C'est-à-dire une fonction dont les **niveaux de gris** représentent des concentrations locales qui se « diffusent » dans le temps et à travers l'image. En posant comme condition initiale:

$$u(x, y, t = 0) = f(x, y)$$

on peut voir  $u(x,y,t)$  comme une version filtrée de  $f(x,y)$ . Le filtrage s'opère en vertu des propriétés de la diffusion.

# Diffusion linéaire



$$u(x, y, t = 0) = f(x, y)$$



$$u(x, y, t = 1)$$



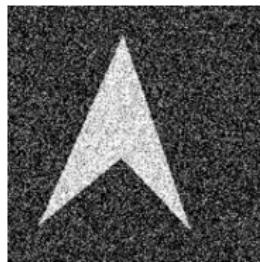
$$u(x, y, t = 20)$$



$$u(x, y, t = 100)$$

Plusieurs méthodes numériques pour l'implémentation.  
Dérivées finies ou convolution avec un filtre Gaussien.  
On en reparlera dans un contexte de segmentation.

# Diffusion linéaire



$$u(x, y, t = 0) = f(x, y)$$

$$u(x, y, t = 1)$$

$$u(x, y, t = 20)$$

$$u(x, y, t = 100)$$

La convolution Gaussienne est équivalente à faire évoluer l'équation de la chaleur pour  $t = \sigma^2$  itérations

# Diffusion : linéaire et non-linéaire

$$\frac{\partial u}{\partial t} = \operatorname{div}(g \nabla u)$$

Avec la diffusion, il est possible de filtrer l'image tout en préservant les discontinuités (contours). Pour y arriver, il nous faut réduire la diffusion près des contours, c-à-d là où le gradient est élevé

$$|\nabla u| = \sqrt{u_x^2 + u_y^2}$$

Il faut donc une « diffusivité »  $g$  qui diminue aux endroits où le gradient est élevé. Plusieurs fonctions ont été proposées, mentionnons-en trois

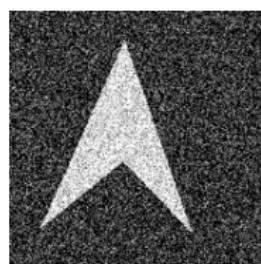
$$g(|\nabla u|) = \frac{I}{\sqrt{I + \frac{|\nabla u|^2}{\lambda^2}}} \quad (\text{Charbonnier})$$

$$g(|\nabla u|) = \frac{I}{1 + \frac{|\nabla u|^2}{\lambda^2}} \quad (\text{Perona-Malik})$$

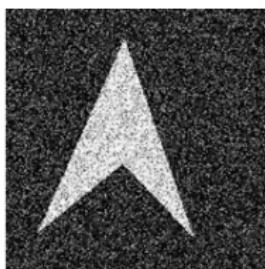
$$g(|\nabla u|) = e^{-|\nabla u|^2 / 2\lambda^2}$$

# Diffusion : linéaire et **non-linéaire**

Résultats avec la diffusivité de Perona-Malik       $\tau = 0.25, 1000$  itérations



$$u(x, y, t = 0) = f(x, y)$$



$$\lambda = 1$$



$$\lambda = 3$$



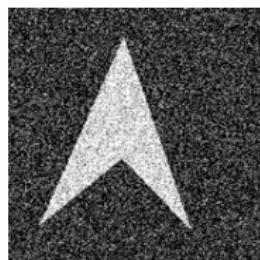
$$\lambda = 5$$



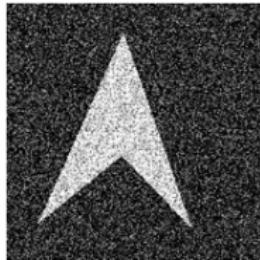
Diffusion linéaire

# Diffusion non-linéaire - filtrage anisotrope

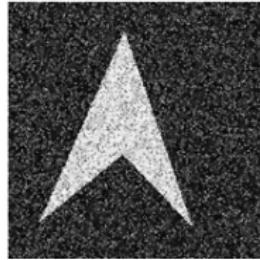
Résultats avec la diffusivité de Perona-Malik     $\tau = 0.25, \lambda = 5$



$u(x, y, t = 0) = f(x, y)$



$u(x, y, t = 1)$



$u(x, y, t = 100)$



$u(x, y, t = 200)$



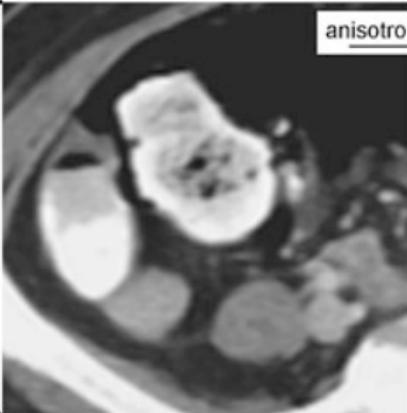
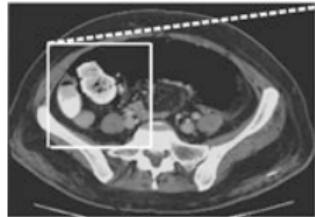
$u(x, y, t = 500)$



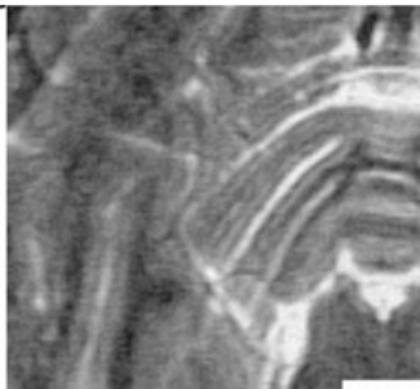
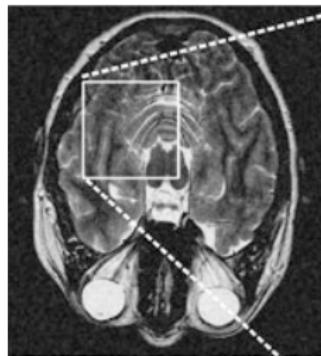
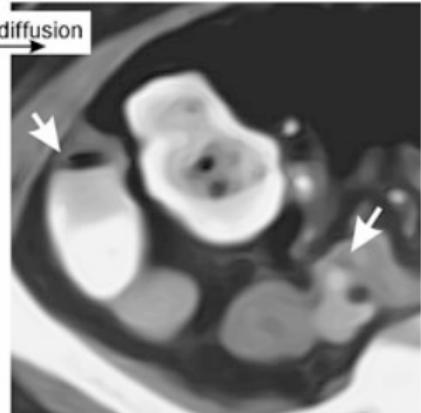
$u(x, y, t = 750)$



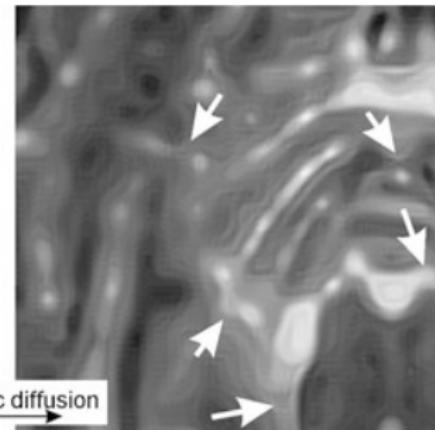
$u(x, y, t = 1000)$



anisotropic diffusion →



anisotropic diffusion →



# Diffusion : linéaire et non-linéaire

L'inconvénient avec les approches basées sur la diffusion est leur **lenteur**. Il existe toutefois des moyens pour accélérer les calculs:

- (1) Implémentation sur architecture **parallèle** (comme les GPUs par exemple)
- (2) Utiliser un optimiseur **implicite** (Jacobi, Gauss-Seidel, SOR)
- (3) Approche **multirésolution**

## Quelques autres filtres

# Filtre non-linéaire : filtre médian

Utile pour contrer le bruit poivre et sel (aussi appelé bruit impulsionnel - *speckle noise* en anglais)

$$g(x, y) = \text{médiane}_{\eta_{x,y}} \{ f(x, y) \}$$

( $\eta_{x,y}$  est un voisinage centré sur  $(x, y)$ )

Exemples:

216	5	8
1	10	11
6	3	12

bruit

1,3,5,6,8,10,11,12,216

médiane



Image bruitée



Gauss,  $\sigma = 1$



Gauss,  $\sigma = 2$

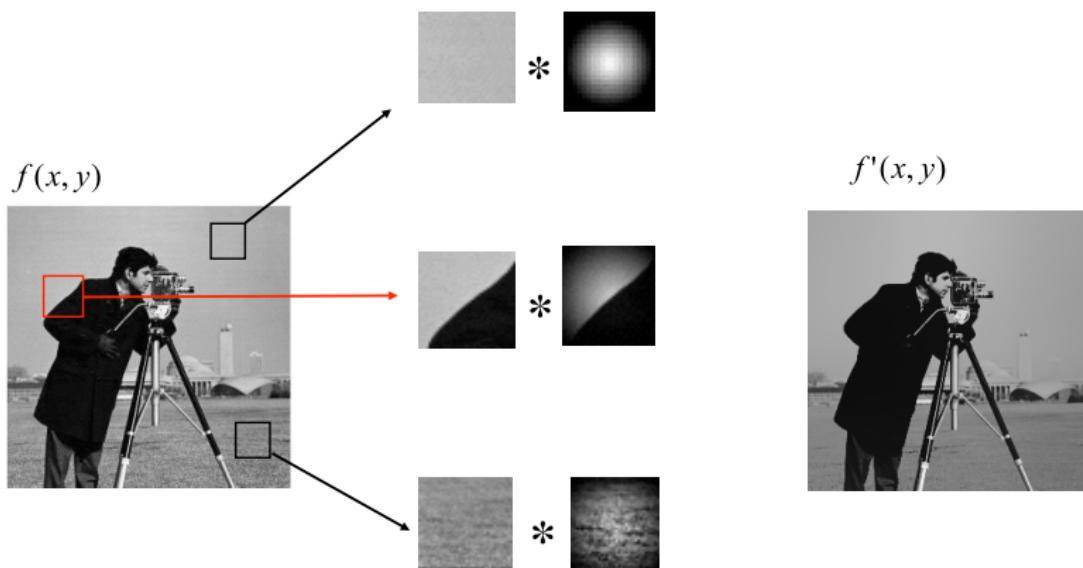


Mediane (3x3)

# Filtre médian

- Marche bien avec des contours droits
- Marche bien lorsque que sauts/discontinuités forts
- Limitations:
  - Pour les images constantes par morceau
  - Choix du voisinage

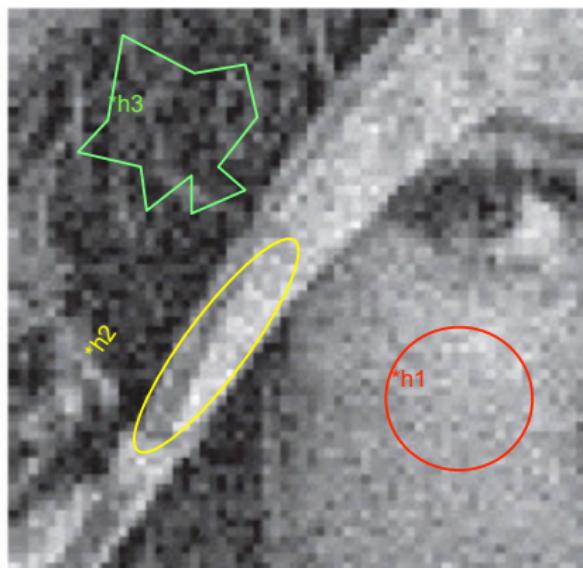
# Filtrage bilatéral



Avec l'approche bilatérale, la forme du filtre dépend du contenu de l'image

# Filtrage bilatéral

- Lissage non-uniforme
- S'adapte en fonction de l'information locale de l'image
  - Lisse où c'est possible
  - Préserve détails fins quand il le faut



# Filtrage bilatéral

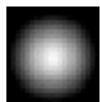
Filtrage gaussien classique :

$$(\underbrace{f * h}_{\text{Convolution}})(x, y) = \underbrace{f'(x, y)}_{\text{Niveau de gris résultant}} = \sum_s \sum_t f(x - s, y - t) h_\sigma(s, t)$$

Somme sur les voisins du pixel (x,y)

Niveau de gris du pixel (x,y)

Filtre



Filtrage bilatéral :

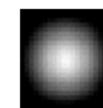
$$f'(x, y) = \frac{1}{W} \sum_s \sum_t f(x - s, y - t) h_{\sigma_S}(s, t) h_{\sigma_R}(f_{s,t})$$

Terme de normalisation

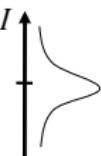
Taille du voisinage

Filtre spatial      Filtre range

On ne crée pas d'information



Taille du noyau Gaussien



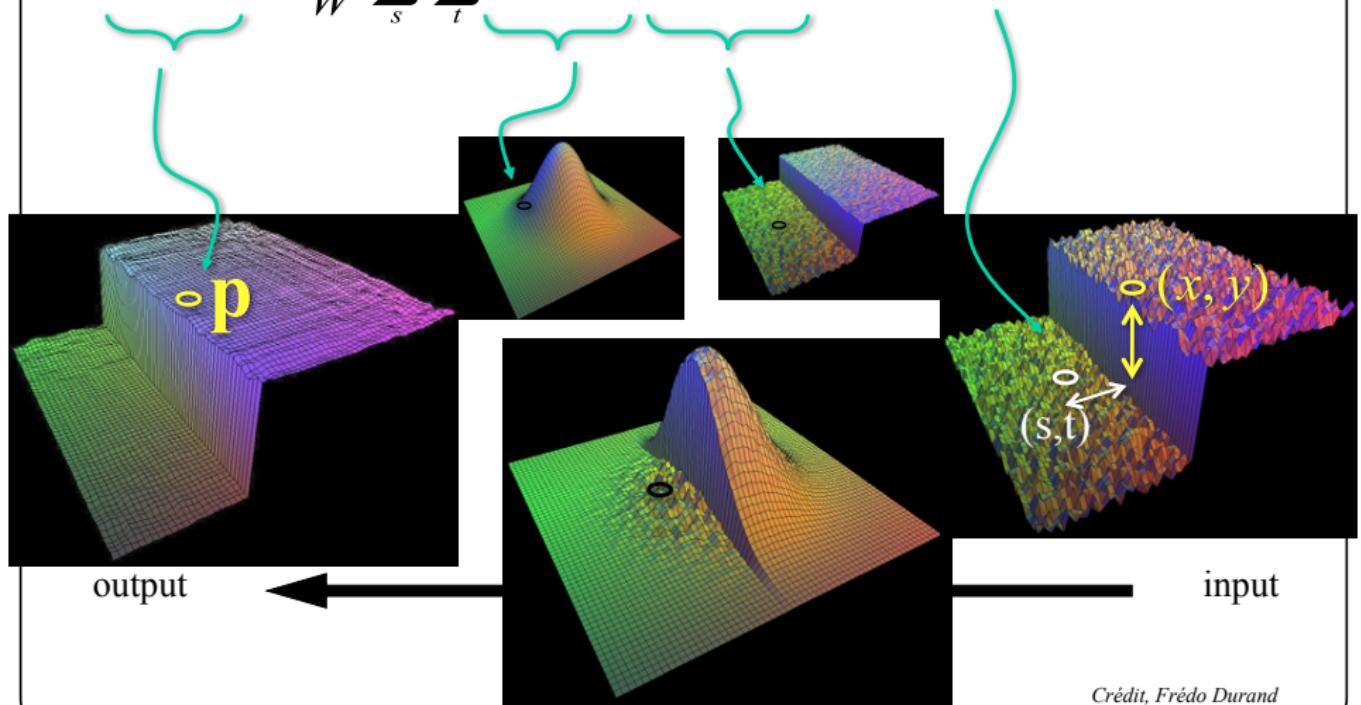
# Filtrage bilatéral

$$h_{\sigma_s}(x, y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma_s^2}$$

$$h_{\sigma_R}(f_{s,t}) = \frac{1}{\sqrt{2\pi}\sigma_R} e^{-|f_{s,t} - f_{x,y}|^2/2\sigma_R^2}$$

# Filtrage bilatéral

$$f'(x, y) = \frac{1}{W} \sum_s \sum_t h_{\sigma_s}(s, t) h_{\sigma_R}(f_{s,t}) f(x - s, y - t)$$



Crédit, Frédo Durand



input

$\sigma_r = 0.1$



$\sigma_r = 0.25$



$\sigma_r = \infty$   
(Gaussian blur)



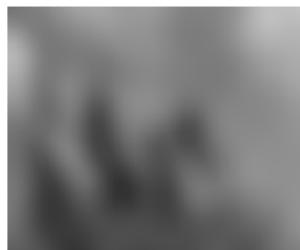
$\sigma_s = 2$



$\sigma_s = 6$



$\sigma_s = 18$



# Filtrage bilatéral

**Note 1 :** le filtrage bilatéral fonctionne mal en présence d'images fortement bruitées.

$f(x, y)$  peu bruité



$f(x, y)$  fortement bruité

# Filtrage bilatéral

**Note 2 :** en présence d'images fortement bruitées, on peut rendre ce filtre **itératif**.

$$f'(x, y) \leftarrow \text{FILTRE\_BL}(f(x, y))$$

POUR iter = 1 jusqu'à N FAIRE

$$f'(x, y) \leftarrow \text{FILTRE\_BL}(f'(x, y))$$

Itération 0



Itération 1



Itération 2

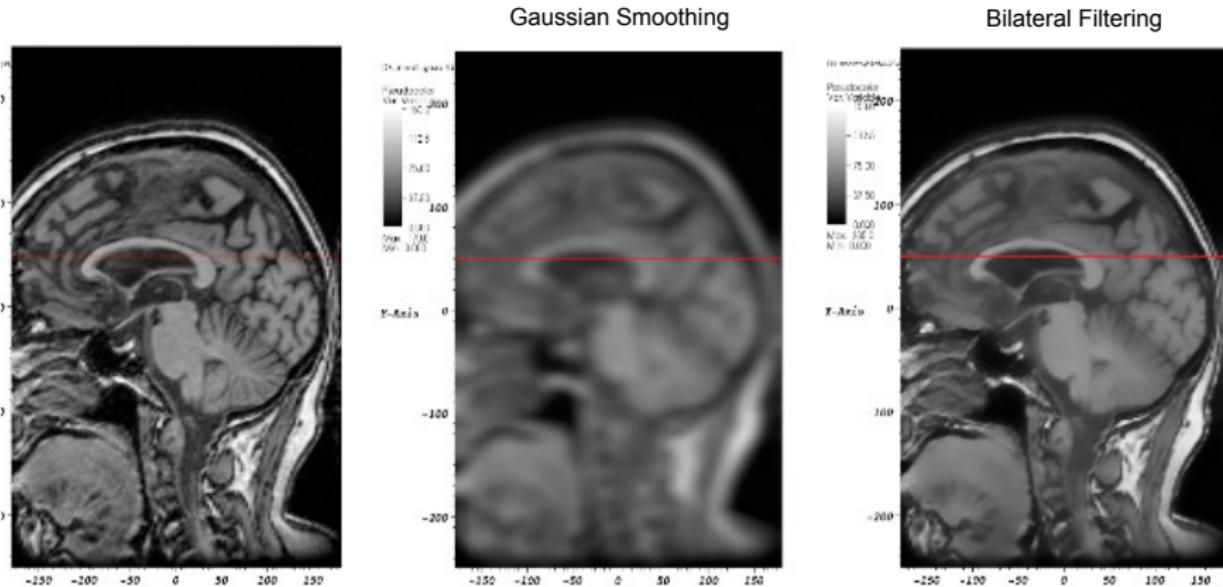


Itération 3



# Filtrage bilatéral

- Mieux que le Gaussien mais lisse quand même trop les contours



# Filtrage bilatéral

**Note 3 :** une implémentation directe du filtrage bilatéral est **très coûteuse** en temps de calcul. Pour en réduire les délais, il faut **approximer** les calculs. De plus, un filtre bilatéral n'étant PAS linéaire, il **ne peut pas** s'effectuer via une **transformée de Fourier**.

# Comparaison des débruitages “classiques” par filtrage

Original  
 $\sigma = 20$



Gaussian  
Smoothing



Anisotropic  
Filtering



Bilateral Filtering



Hard WT

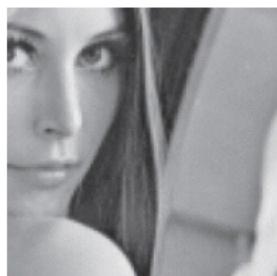


Soft WT



Buades *et al.* (2005)

# Comparaison des débruitages “classiques” par filtrage



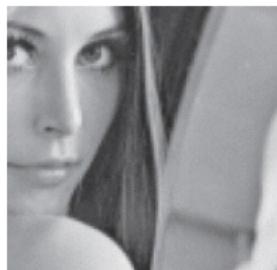
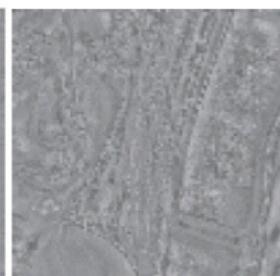
Gaussian  
Smoothing



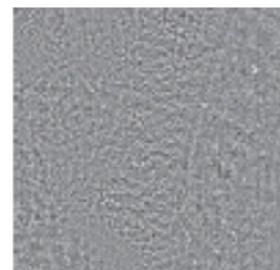
Anisotropic  
Filtering



Bilateral Filtering



Hard WT



Soft WT



## *Non-Local Means*

Le but est donc de faire la moyenne de tous les pixels dont le même **contenu est très similaire** plus ou moins du bruit.

$$\bar{g}(p) = \frac{1}{C} \sum_q w(p, q) g(q)$$

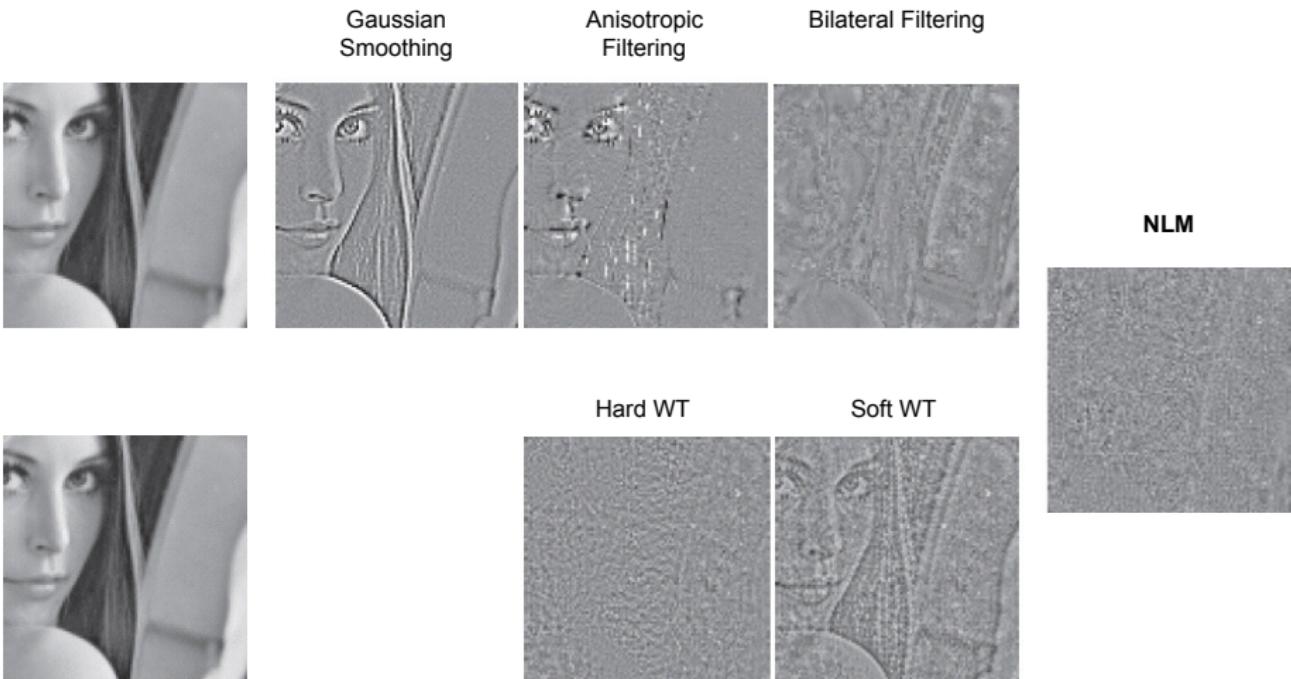
où

$$w(p, q) \geq 0$$

$$\sum_x \sum_y w(p, q) = 1$$

$w(p, q)$  détermine dans quelle mesure les pixels  $p$  et  $q$  sont similaires

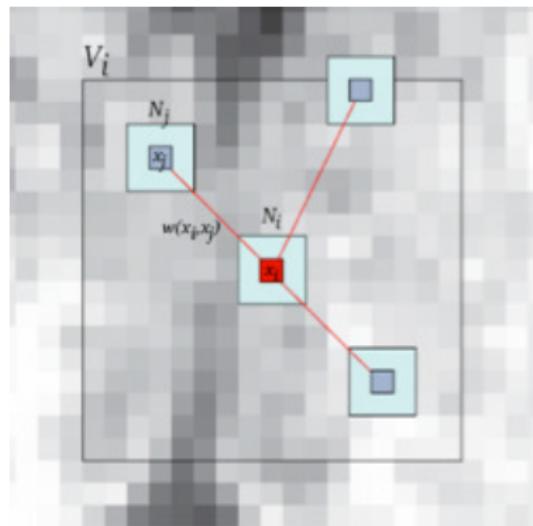
# Comparaison et différence



# Débruitage NLmeans pour l'IRM

Moyennage pondéré sur un grand ensemble de voxels

Poids: similitudes entre les “patchs”



Petites patches et petit volume  $V \rightarrow$  6 heures de calculs

# Débruitage NLmeans pour l'IRM en optimisant la position des blocs *a priori*

- Temps de calcul (6 heures) → pré-sélection des patches et blocs (3 minutes)

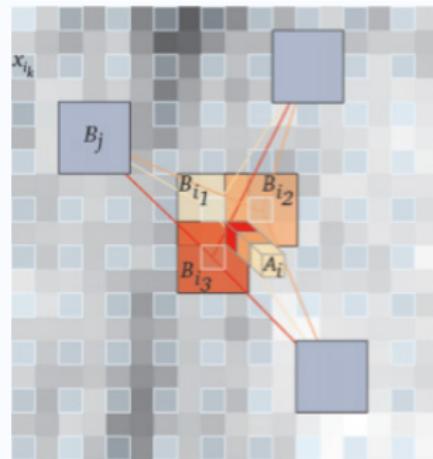
Image sub-sampling

Block averaging

$$\mathbf{NL}(u)(B_{i_k}) = \sum_{B_j \in V_{i_k}} w(B_{i_k}, B_j) \mathbf{u}(B_j)$$

Estimator aggregation

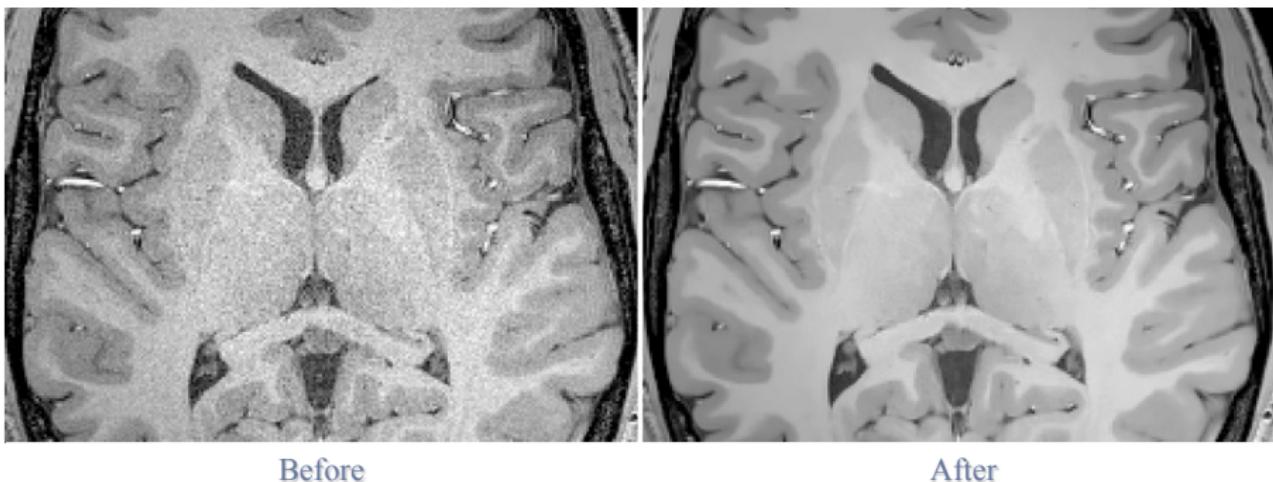
$$NL(u)(x_i) = \frac{1}{|\mathbf{A}_i|} \sum_{p \in \mathbf{A}_i} \mathbf{A}_i(p).$$



$$w(x_i, x_j) = \begin{cases} \frac{1}{Z_i} e^{-\frac{\|\mathbf{u}(N_i) - \mathbf{u}(N_j)\|_2^2}{h^2}} & \text{if } \mu_1 < \frac{\mathbf{u}(N_i)}{\mathbf{u}(N_j)} < \frac{1}{\mu_1} \text{ and } \sigma_1^2 < \frac{\text{Var}(\mathbf{u}(N_i))}{\text{Var}(\mathbf{u}(N_j))} < \frac{1}{\sigma_1^2} \\ 0 & \text{otherwise.} \end{cases}$$

# Débruitage NLmeans pour l'IRM en optimisant la position des blocs *a priori*

- 6 heures de calculs



<https://sites.google.com/site/pierrickcoupe/softwares/denoising-for-medical-imaging/mri-denoising>

# Extension pour le bruit Rician

$$NL_R(u)(x_i) = \sqrt{\max \left( \left( \sum_{x_j \in V_i} w(x_i, x_j) u(x_j)^2 \right) - 2\sigma^2, 0 \right)}$$



Original



Denoised



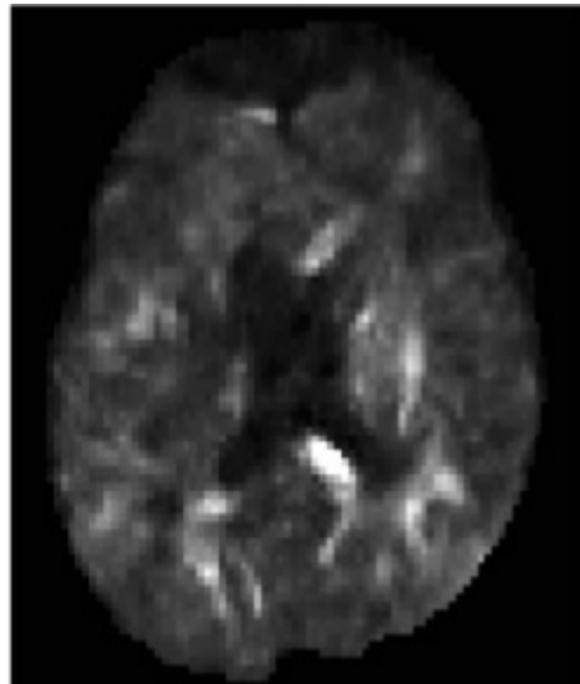
$|Original - Denoised|$

[Coupé et al 2008, 2009, 2010]

# NLmeans Rician (extrêmement utile en imagerie de diffusion)



Avant



Après

# Filtrage NLmeans

Une implémentation directe du NLmeans est **très coûteuse** en temps de calcul. Il existe toutefois des moyens pour accélérer les calculs:

- (1) Implémentation sur architecture **parallèle**  
(multi-core, Mammouth ou GPUs par exemple)
- (2) Approche **multirésolution**

L'idée de grouper les patchs qui se ressemblent a du sens. On réduit les mélanges non-cohérents.

On peut faire mieux ou pas?

# Méthode par bloc

Block Matching 3D collaborative filtering (Dabov *et al.* 2007)

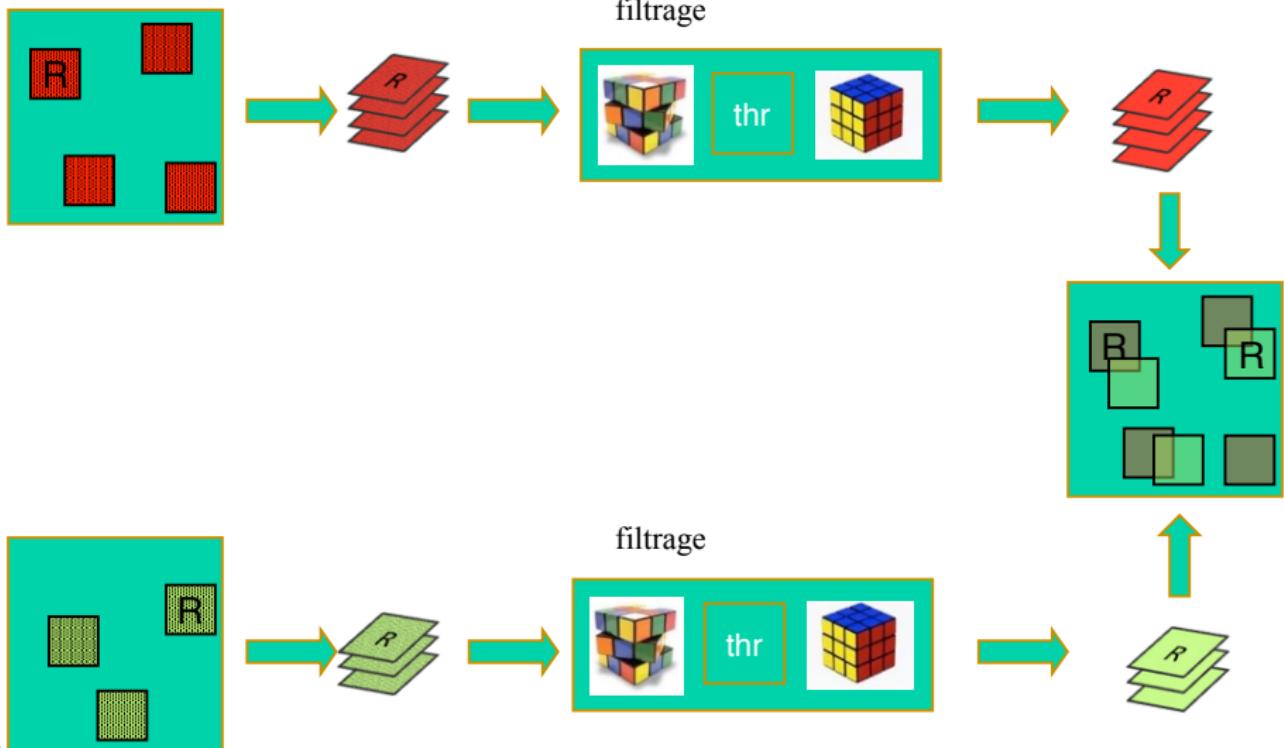
- On regroupe les patchs avec une structure locale semblable (**BM**)
- On débruite co-jointement le groupe (**3D**)
- On fusionne de façon astucieuse
- Champ de recherche actif

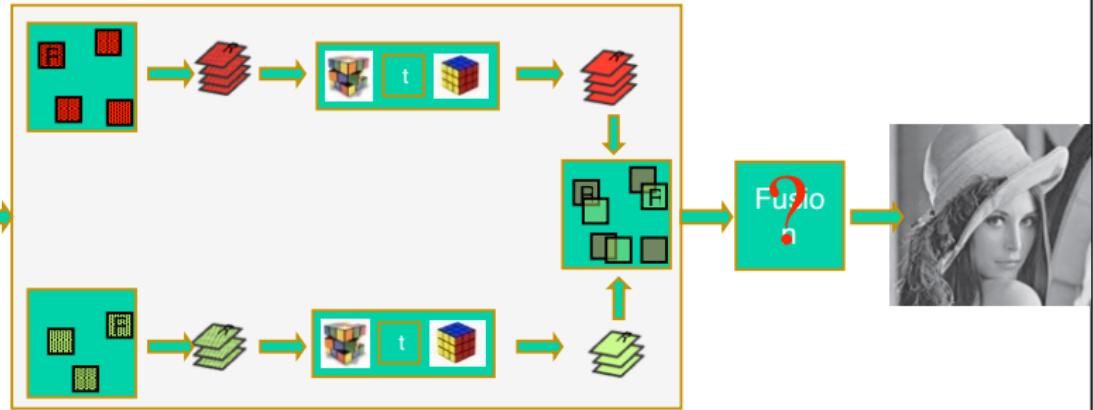
# Block matching 3D (BM3D)

- Ondelettes et seuillage utilisés (voir IMN359...)
- Chaque patch dans le groupe se fait débruiter indépendamment

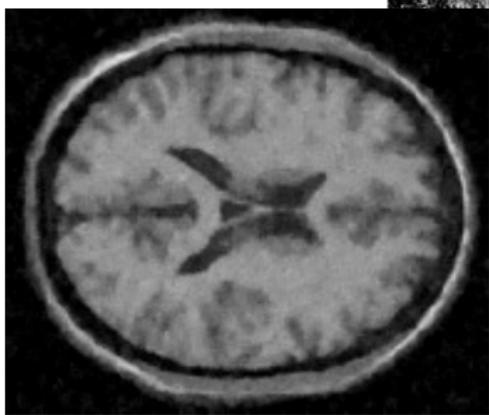
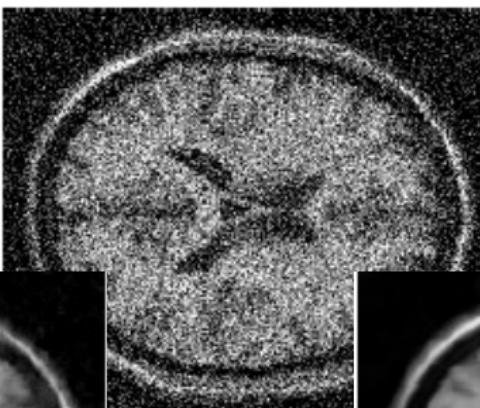


- Contrairement au NLmeans où seulement le voxel central de référence se fait débruiter, dans le BM3D, toute la patch se fait débruiter

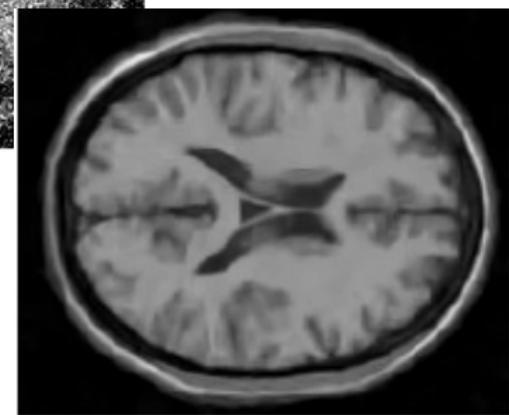




# Block matching versus NL means



3D Non-Local Means



BM4D

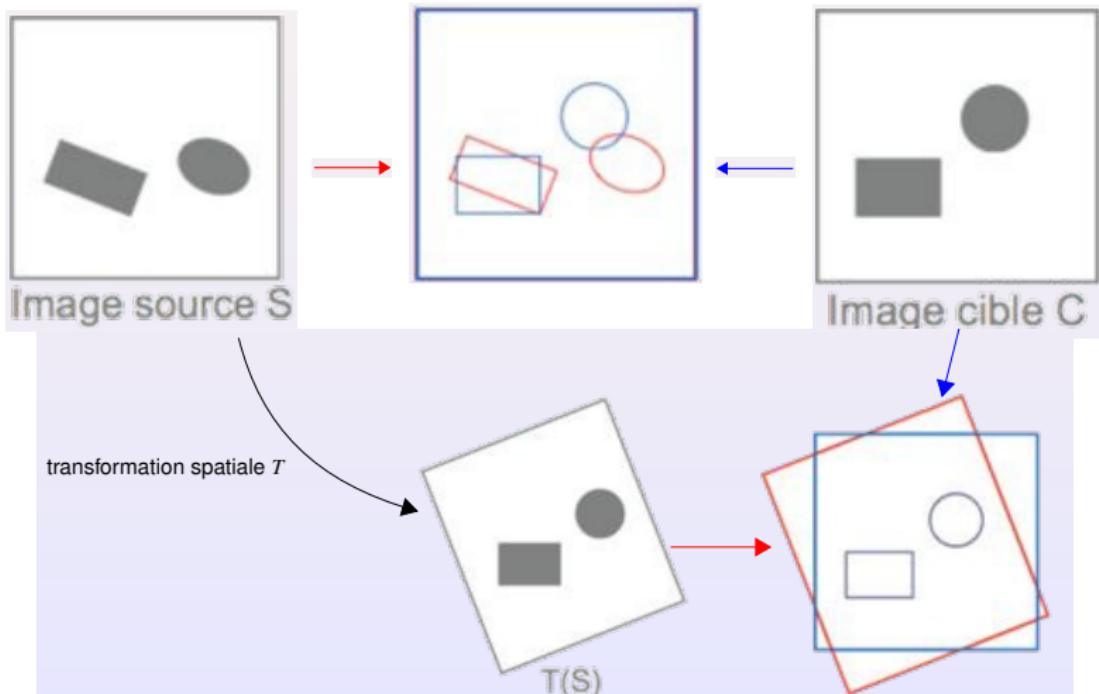
# RECALAGE D'IMAGES MÉDICALES

D'après les cours de :

- Maxime Descoteaux  
<http://scil.dinf.usherbrooke.ca/fr/teaching/imn530>
- Caroline Petitjean
- Christophe Portefaix

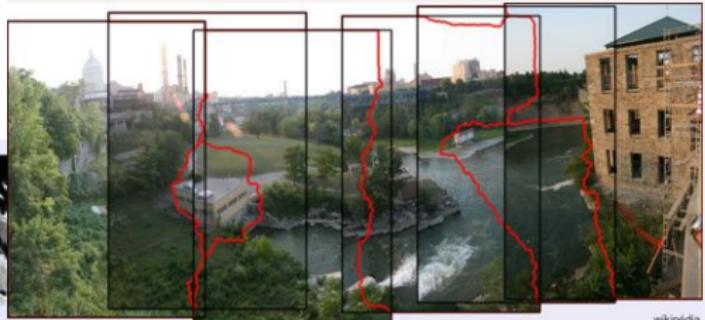
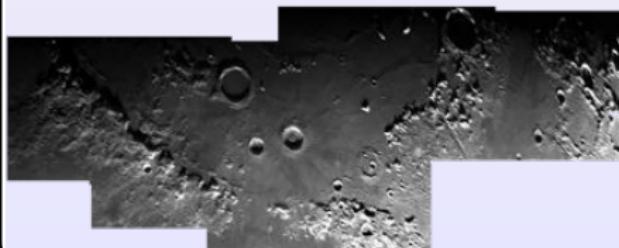
# Recalage - quoi?

- Deux images S et C : cherche  $T$  tel que  $T(S)$  ressemble à C



# Recalage : applications

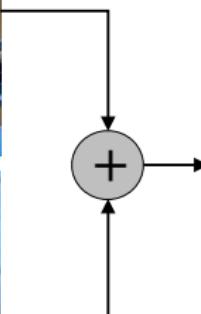
- Outil **fondamental** en analyse d'images médicales, mais pas uniquement
- Où ailleurs en imagerie?
- Crédit d'images panoramiques
- Mosaïques
- Astronomie



wikipedia

# Systèmes par mosaïque

Ce type d'approche consiste à **construire les images panoramiques** à partir d'une série d'images prises avec le même système optique. On peut, par exemple, utiliser une caméra en rotation autour de son centre optique.



# Systèmes par mosaïque

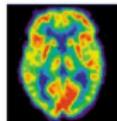
Évidemment, un nombre arbitraire d'images peut être utilisé...



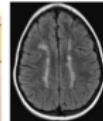
[Microsoft research, 2007]

[Mode panoramique du iPhone est un autre bel exemple]

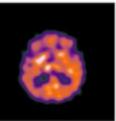
# Exemples en imagerie médicale



TEP



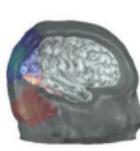
IRM



SPECT



EEG



MEG

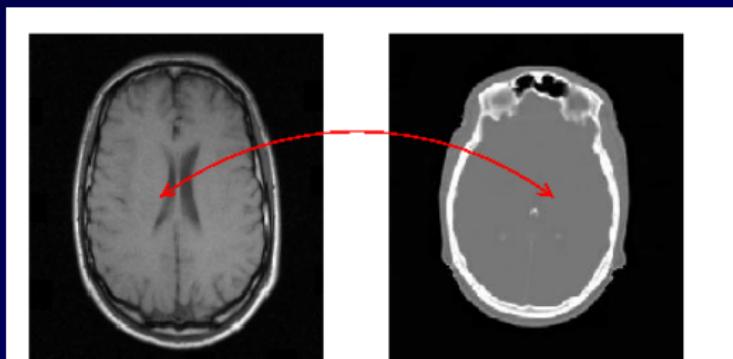
# Recalage

## Définition

- Consiste à trouver une transformation spatiale permettant d'aligner une image (source ou **flottante**) sur une autre (cible ou **référence**).



Image registration  
Image matching

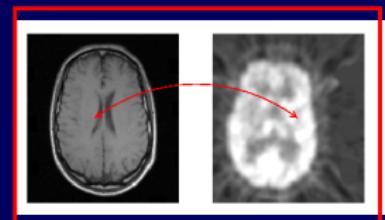
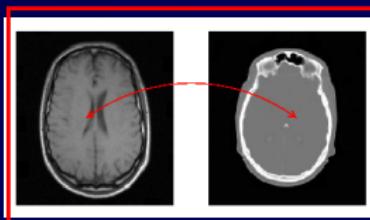
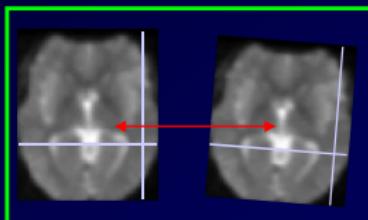


# Recalage

## Définition

- Consiste à trouver une transformation spatiale permettant d'aligner une image (source ou **flottante**) sur une autre (cible ou **référence**).

Recalage monomodal ou multimodal

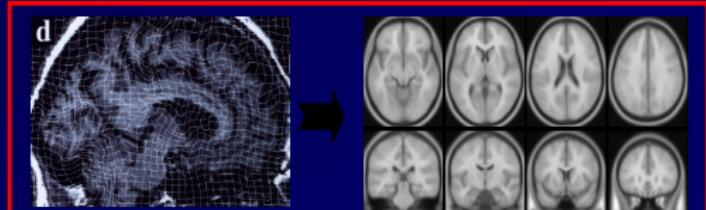
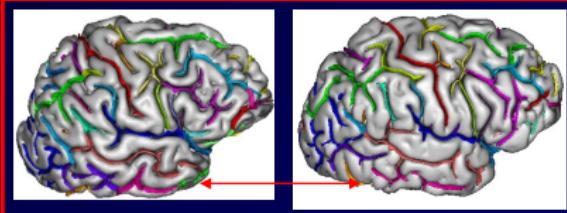
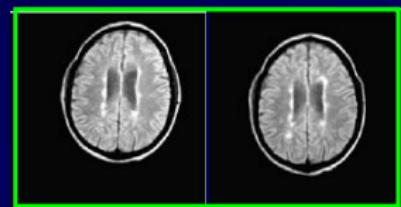


# Recalage

## Définition

- Consiste à trouver une transformation spatiale permettant d'aligner une image (source ou **flottante**) sur une autre (cible ou **référence**).

Recalage intra- ou inter-sujets



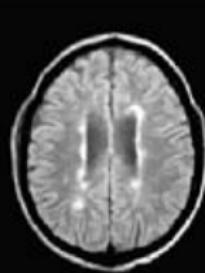
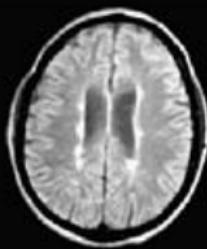
# Recalage : exemples

## 1) Intra-patient, mono-modalité

- Exemple : évolution de lésions (images IRM d'un patient atteint de SEP à quelques mois d'intervalle)

Source

Cible



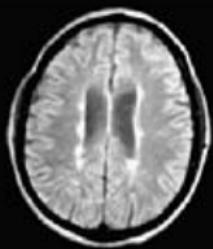
Source : Université Louis Pasteur, Strasbourg

# Recalage : exemples

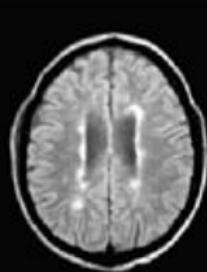
## 1) Intra-patient, mono-modalité

- Exemple : évolution de lésions (images IRM d'un patient atteint de SEP à quelques mois d'intervalle)

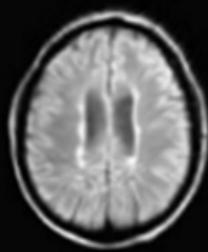
Source



Cible



Source recalée

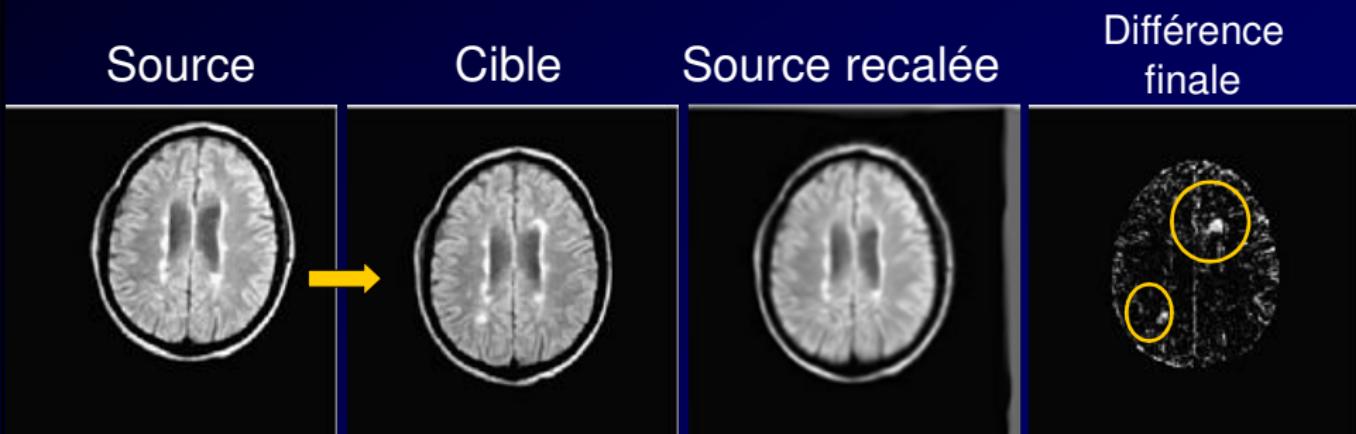


Source : Université Louis Pasteur, Strasbourg

# Recalage : exemples

## 1) Intra-patient, mono-modalité

- Exemple : évolution de lésions (images IRM d'un patient atteint de SEP à quelques mois d'intervalle)

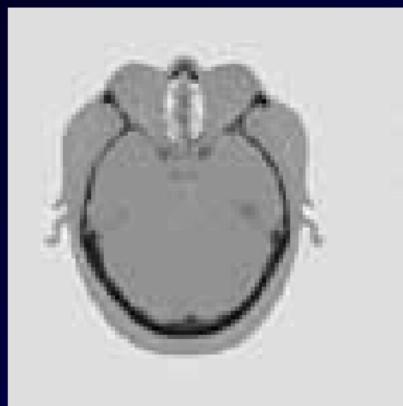


Source : Université Louis Pasteur, Strasbourg

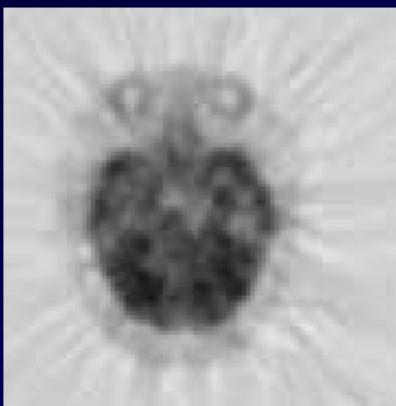
# Recalage : exemples

## 2) Intra-patient, multi-modalité

- Exemple : fusion d'informations provenant de 2 modalités différentes



Source (scanner)



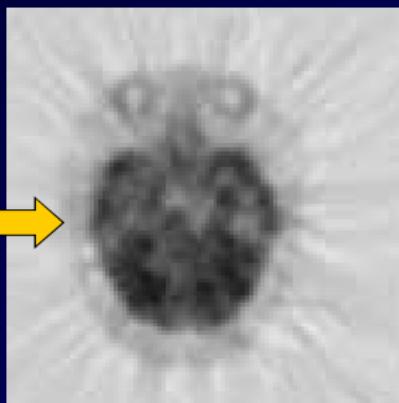
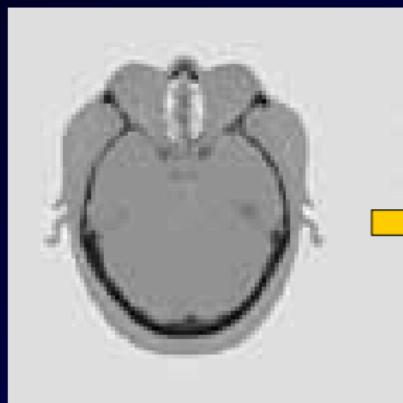
Cible (TEP)

Source : EPFL

# Recalage : exemples

## 2) Intra-patient, multi-modalité

- Exemple : fusion d'informations provenant de 2 modalités différentes

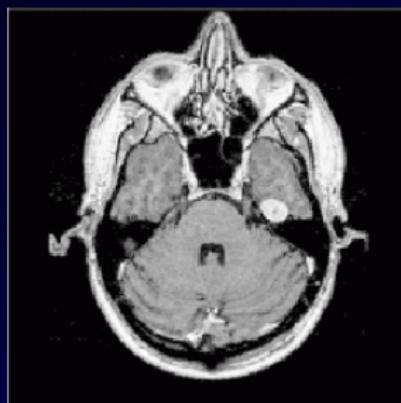


Source : EPFL

# Recalage : exemples

## 2) Intra-patient, multi-modalité

- Exemple : fusion d'informations provenant de 2 modalités différentes



Source (IRM)



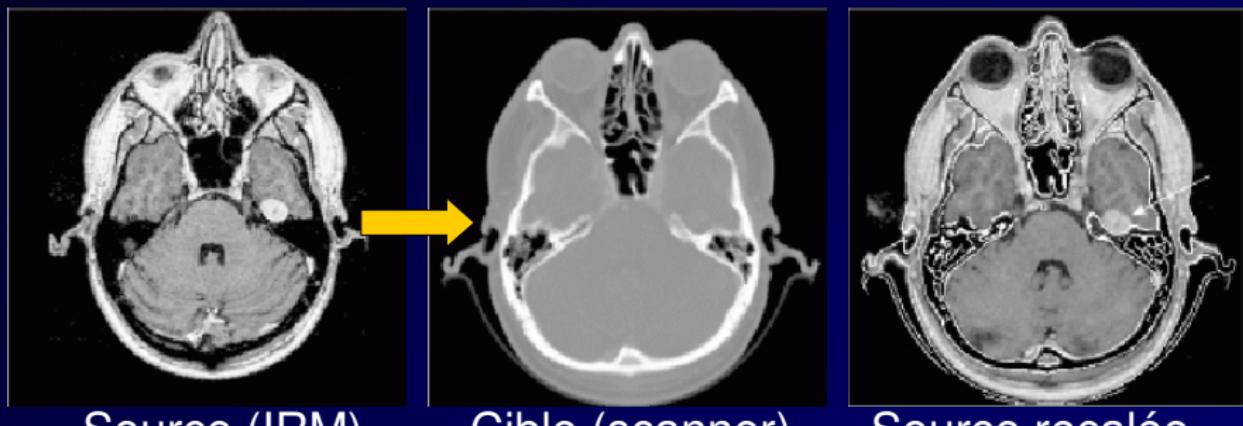
Cible (scanner)

Source : Université de Hambourg

# Recalage : exemples

## 2) Intra-patient, multi-modalité

- Exemple : fusion d'informations provenant de 2 modalités différentes



Source (IRM)

Cible (scanner)

Source recalée

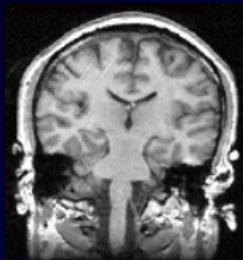
Source : Université de Hambourg

# Recalage : exemples

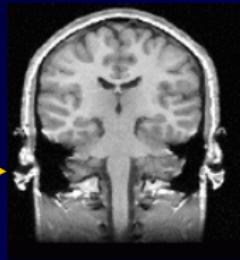
## 3) Inter-patient, intra-modalité

- Exemple : Segmentation à partir d'un atlas anatomique

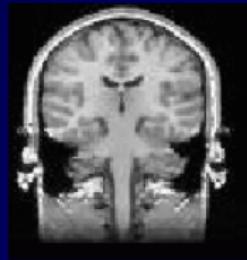
Source  
(individu)



Cible  
(atlas)



Source  
recalée



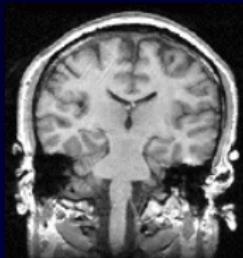
Source : INRIA

# Recalage : exemples

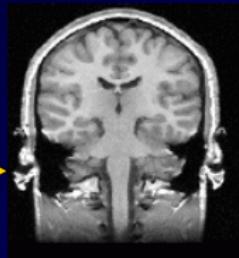
## 3) Inter-patient, intra-modalité

- Exemple : Segmentation à partir d'un atlas anatomique

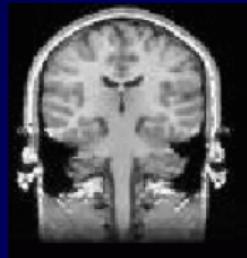
Source  
(individu)



Cible  
(atlas)



Source  
recalée



Atlas segmenté  
et étiqueté

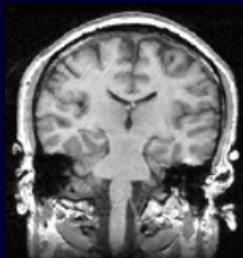
Source : INRIA

# Recalage : exemples

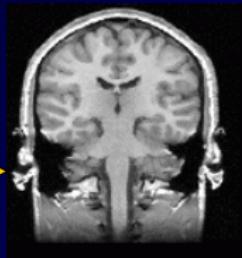
## 3) Inter-patient, intra-modalité

- Exemple : Segmentation à partir d'un atlas anatomique

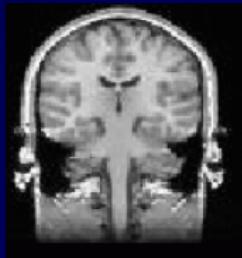
Source  
(individu)



Cible  
(atlas)



Source  
recalée

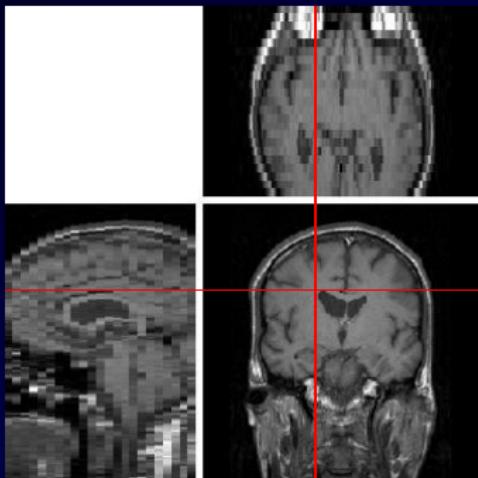


Atlas segmenté  
et étiqueté

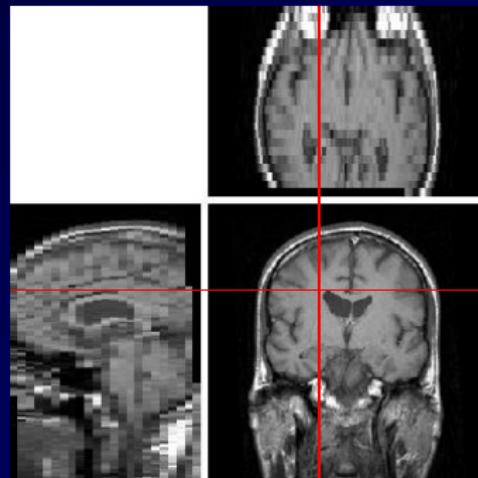
Source : INRIA

# Recalage : exemples

## 4) Extension en 3D



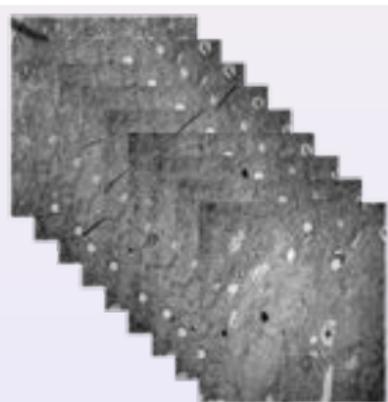
First 3D image



Second 3D image

# Recalage en imagerie médicale

- Reconstruction d'un volume 3D
  - À partir d'une série de coupes 2D contiguës (microscopie, épaisseur de coupe 60 nm environ)



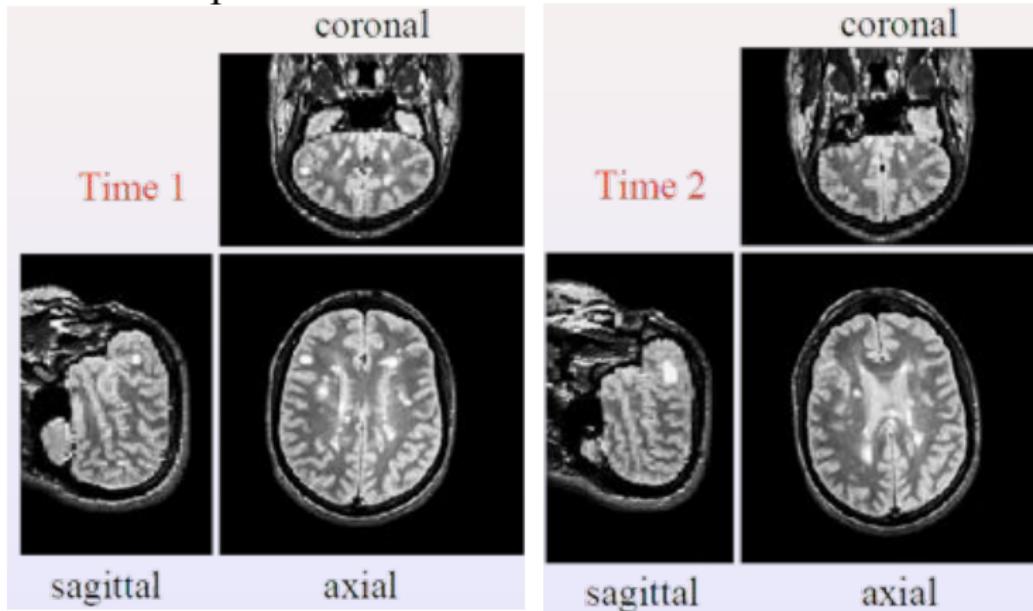
*Series of successive 2D slices*



*Orthogonal views of the reconstructed volume using affine transformations*

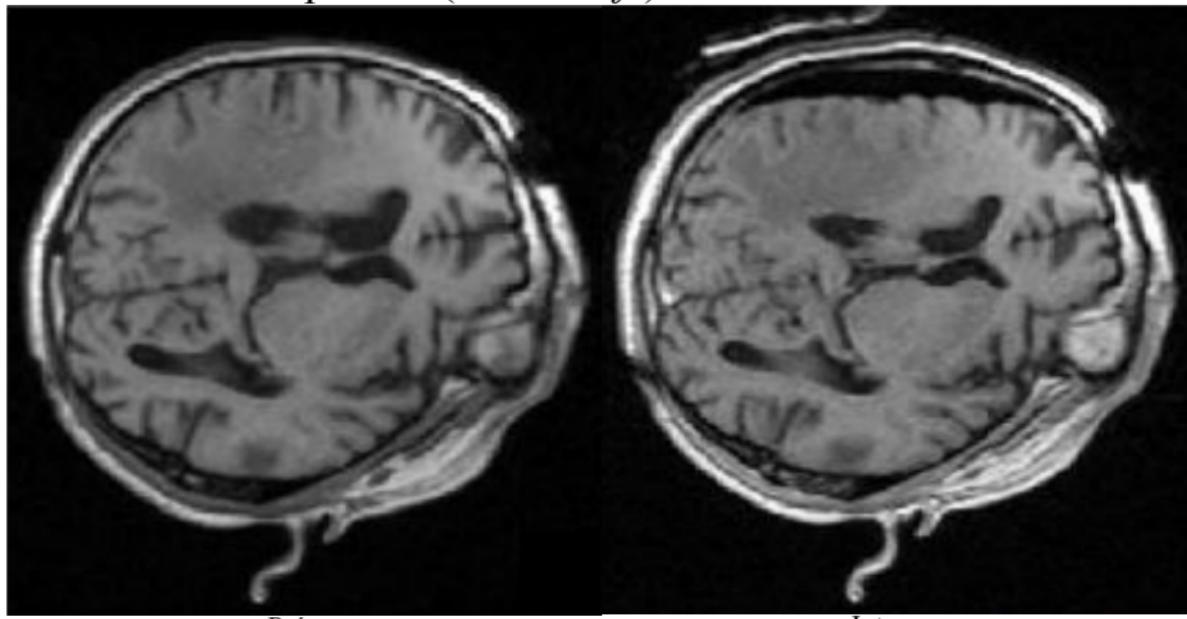
# Recalage en imagerie médicale

- Évolution temporelle



# Recalage en imagerie médicale

- Évolution temporelle (*brain-shift*)

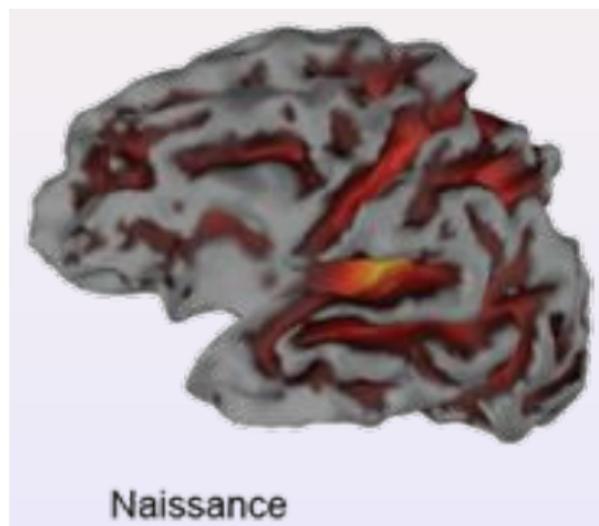


Pré-op

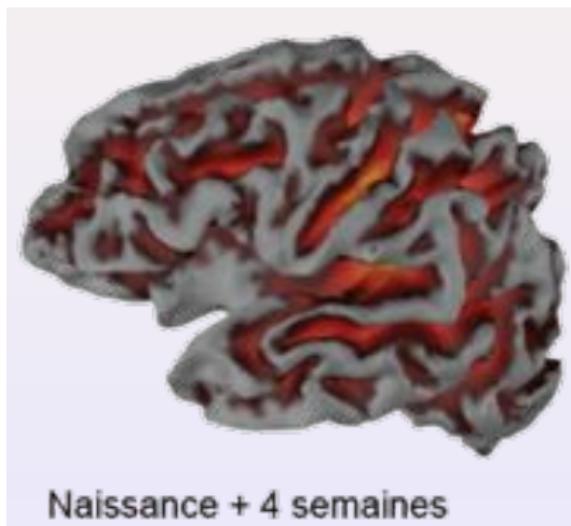
Intra-op

# Recalage en imagerie médicale

- Évolution temporelle, développement cérébral



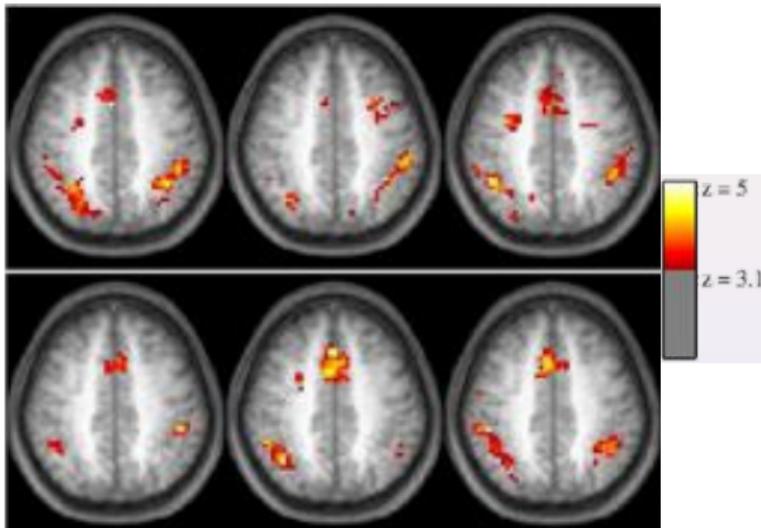
Naissance



Naissance + 4 semaines

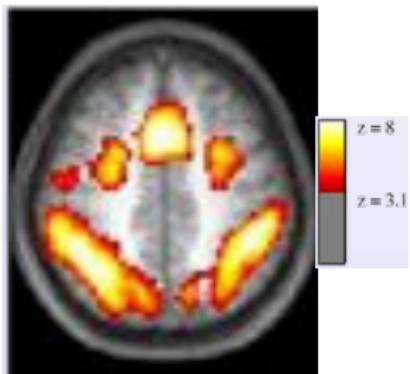
# Recalage en imagerie médicale

- Comparaison entre différents sujets



Individu

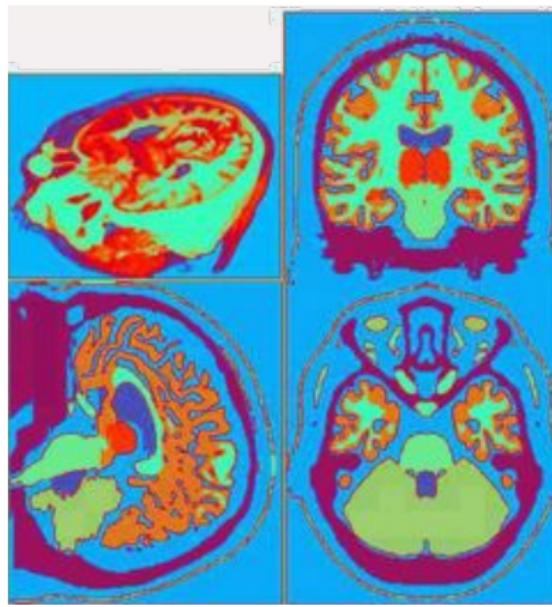
Moyenne du groupe



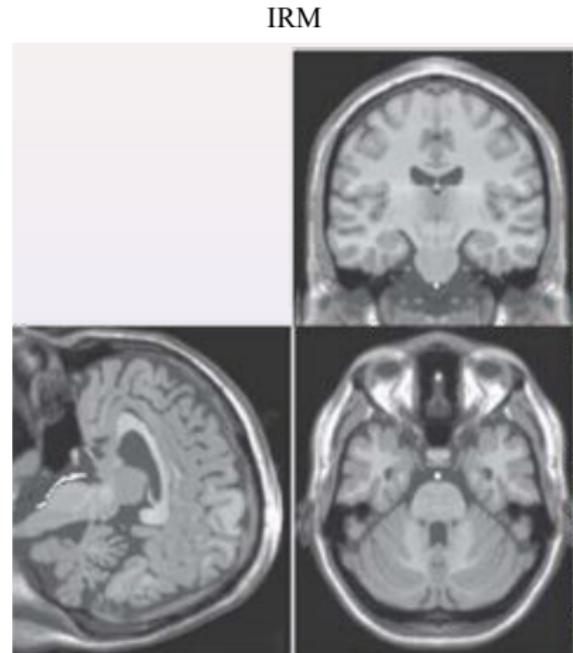
Cours de Whittingstall 13

# Recalage en imagerie médicale

- Superposition sur un atlas



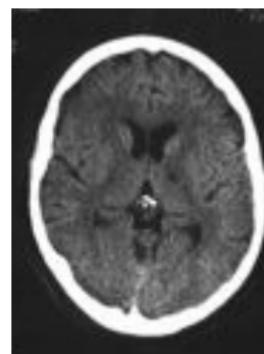
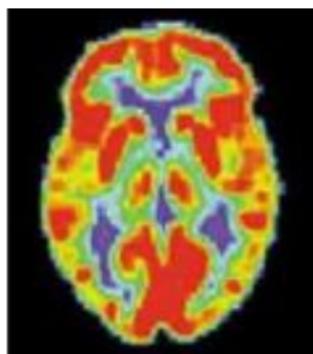
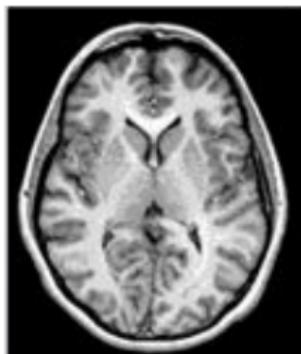
Atlas



IRM

# Recalage en imagerie médicale

- Fusion de modalité - certainement le plus important et répandu



# Recalage

## ➤ Applications

	1 Modalité	Plusieurs Modalités
1 Patient	<ul style="list-style-type: none"><li>➤ Correction du mouvement<ul style="list-style-type: none"><li>↳ intra-série</li><li>↳ inter-série et intra-examen<ul style="list-style-type: none"><li>&gt; Comparaison séries (pré/post PdC)</li></ul></li></ul></li><li>➤ inter-examen<ul style="list-style-type: none"><li>↳ Contrôle post-opératoire</li><li>↳ Suivi d'une pathologie/traitement</li><li>↳ Morphogenèse</li><li>↳ Suivi de structures déformables (cœur, poitrine, sang,..)</li></ul></li><li>➤ Recalage temporel intra-volume</li><li>➤ Correction de distorsion</li></ul>	<ul style="list-style-type: none"><li>➤ Complémentarité entre sources d'images:<ul style="list-style-type: none"><li>↳ Fusion anatomie / fonction</li></ul></li><li>➤ Planning thérapeutique / Chirurgie assistés par ordinateur</li></ul>
Plusieurs Patients	<ul style="list-style-type: none"><li>➤ Normalisation spatiale</li><li>➤ Création d'atlas statistiques</li><li>➤ Recalage / Segmentation avec un atlas</li></ul>	<ul style="list-style-type: none"><li>➤ Cartographie fonctionnelle du corps entier</li><li>➤ Normalisation anatomo-fonctionnelle</li></ul>

# Principe des méthodes de recalage

- Tout se joue sur 3 choix importants:
  - Critère de similarité
  - Transformations considérées
  - Méthode d'optimisation

# Critère de similarité

- Supposons que l'on se donne un critère de similarité:  
 $\text{Simil}(I, J)$  qui mesure la “*ressemblance*” entre deux images I et J

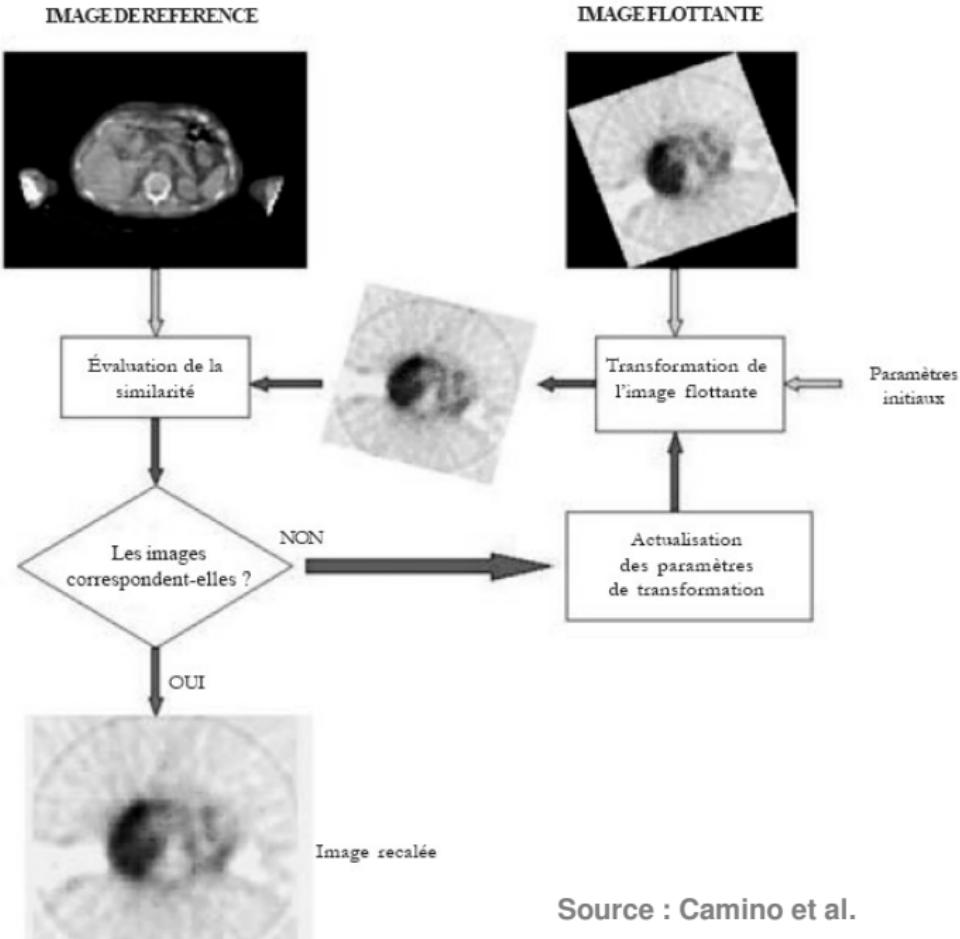
$$\text{Simil}(\begin{array}{|c|c|}\hline \text{Image 1} & \text{Image 2} \\ \hline \end{array}) = \text{:(sad face)}$$

$$\text{Simil}(\begin{array}{|c|c|}\hline \text{Image 1} & \text{Image 2} \\ \hline \end{array}) = \text{:)(neutral face)}$$

- On choisit également une famille de transformation  $\mathcal{F}$
- Le problème de recalage s'écrit alors comme :

$$\arg \min_{T \in \mathcal{F}} \text{Simil}(T(I), J) = ?$$

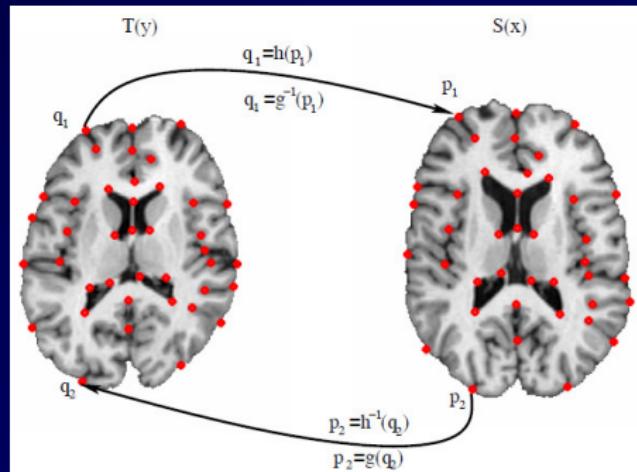
# Méthode de recalage



Source : Camino et al.

# Primitives géométriques

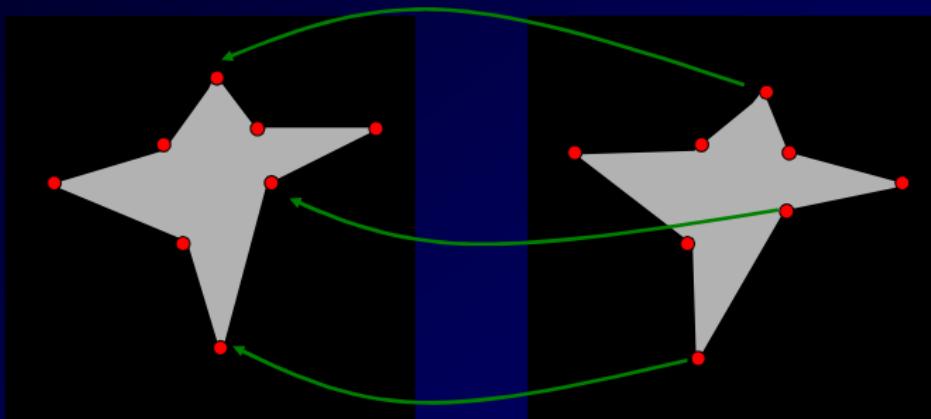
- Structures particulières dans l'image
  - Points, courbes, surfaces
  - Extraits automatiquement ou manuellement



Source : Johnson & Christensen, IPMI, 2001

# Primitives géométriques

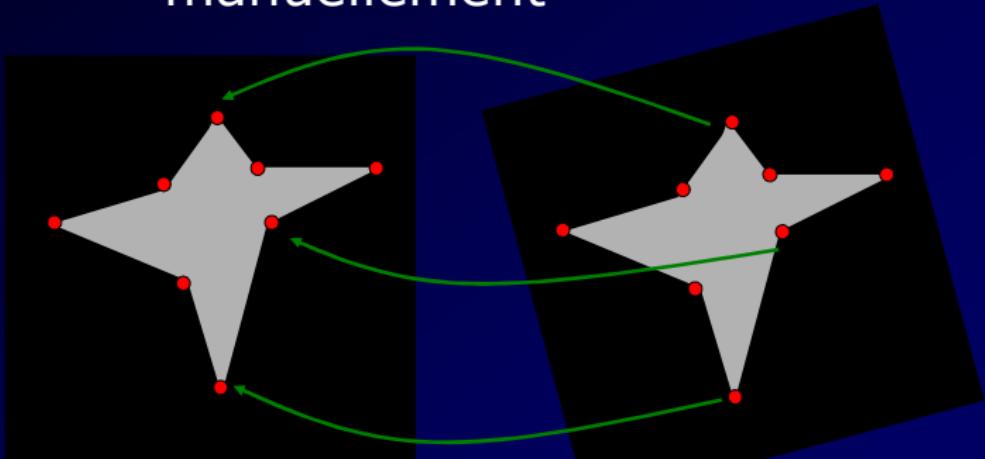
- Structures particulières dans l'image
  - Points, courbes, surfaces
  - Extraits automatiquement ou manuellement



Détection des primitives : ici points de forte courbure

# Primitives géométriques

- Structures particulières dans l'image
  - Points, courbes, surfaces
  - Extraits automatiquement ou manuellement



# Primitives géométriques

- Structures particulières
  - Points, courbes, surfaces
  - Extraits automatiquement ou manuellement

Primitives  
intrinsèques

Primitives  
extrinsèques

# Primitives intrinsèques

- Structures intrinsèques au patient
- Information pertinente présente dans les 2 jeux de données
  - Points
  - Courbes (contours)
  - Surfaces segmentées
  - Volumes
- Points anatomiques
  - identifiés manuellement par l'opérateur
  - isolés automatiquement

# Primitives extrinsèques

- Repères externes, visibles dans les 2 modalités
  - fixées au patient ou à la table d'examen
  - Invasifs
    - Cadre stéréotaxique
    - Vis dans la boîte crânienne
  - Non invasifs
    - Cadre non vissé
    - Moule
    - Repères collés à la peau

# Primitives extrinsèques

- Avantages
  - Permet de recalier des données très différentes
- Inconvénients
  - Les marqueurs doivent être positionnés avant l'acquisition
  - Le recalage rétrospectif n'est pas possible

# Primitives extrinsèques

- Autres repères externes, contention

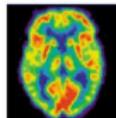


# Primitives

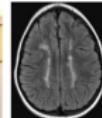
- Structures particulières de l'image
  - Points, courbes, surfaces
  - Extraits automatiquement ou manuellement

- Pas de structures particulières : tous les voxels de l'image sont utilisés

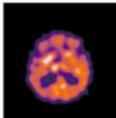
# Les critères de similarité



TEP



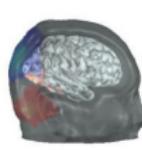
IRM



SPECT



EEG



MEG

# Critère de similarité

- Conservation de l'énergie: Cas idéal:  $T(I) = J$ , images identiques
  - Somme des différences au carré (SSD) :

$$S(T) = \sum_{x,y} \left( I(x,y) - \tilde{J}(T(x,y)) \right)^2$$

où  $\tilde{J}(T(x,y))$  est l'interpolation de  $J$  au point  $T(x,y)$

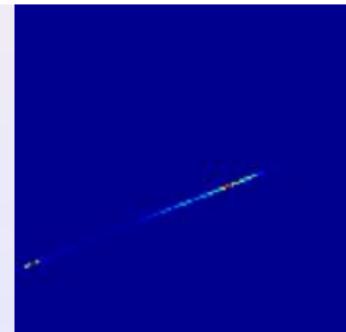
- Somme des différences en valeur absolue (SAD) :

$$S(T) = \sum_{x,y} \left| I(x,y) - \tilde{J}(T(x,y)) \right|$$

# Critère de similarité - dépendance linéaire ou affine

- On ne cherche plus à avoir  $T(I) = J$
- Mais une relation (affine) de la forme  $T(I) = \alpha * J + \beta$  (détailé plus tard dans la section transformation)
- Cas  $\beta = 0$ , dépendance linéaire
- Modélise aussi les différents contrastes dans les images

SSD = 4000



# Coefficient de corrélation

- Critère adapté : **coefficient de corrélation**

$$\rho(I, J) = \frac{\sum_{x,y} (I(x, y) - \bar{I}) (J(x, y) - \bar{J})}{\sqrt{\sum_{x,y} (I(x, y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x, y) - \bar{J})^2}}$$

avec  $\bar{I} = \frac{1}{n} \sum_{x,y} I(x, y)$ , valeur moyenne de  $I$  (idem pour  $\bar{J}$ )

- $p(I, I) = 1$
- $p(I, -I) = -1$
- $p(I, \alpha * I + \beta) = \text{sign}(\alpha) \quad (1 \text{ ou } -1)$

# Coefficient de corrélation

- Si  $p(I, J)$  proche de 0?

$$\sum_{x,y} (I(x,y) - \bar{I}) (J(x,y) - \bar{J}) \text{ petit (par rapport à } \sqrt{\sum_{x,y} (I(x,y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x,y) - \bar{J})^2})$$

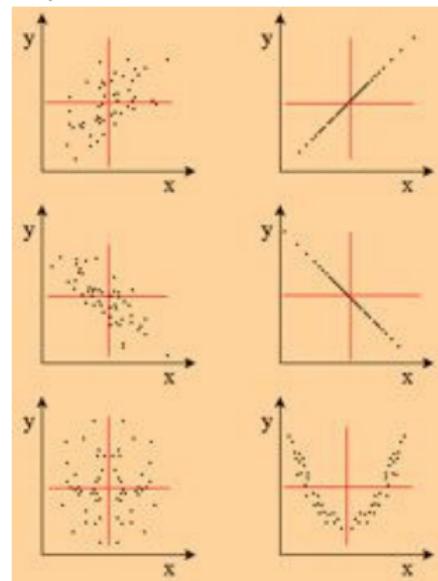
- Les pixels de même signe (produit  $> 0$ ) ou de signes opposés (produit  $< 0$ ) se compensent
- Les intensités des 2 images ne sont pas corrélées linéairement
- $p(I, J)$  toujours compris entre -1 et 1:
  - proche 1 : corrélation positive
  - proche -1 : corrélation négative
  - proche de 0 : absence de corrélation linéaire

# Coefficient de corrélation

- Un outil statistique plus général qui permet d'étudier l'intensité de liaison entre deux (ou plus) variables aléatoires

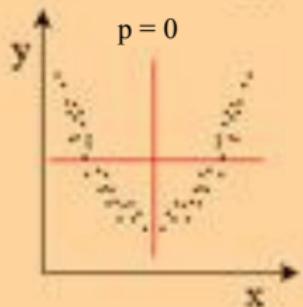
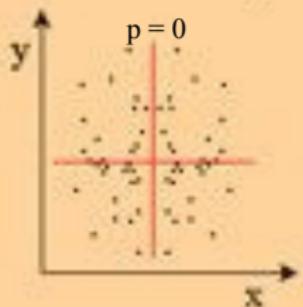
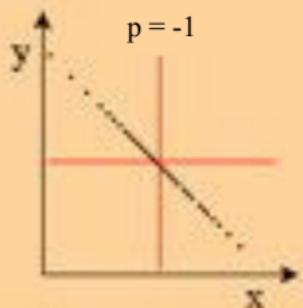
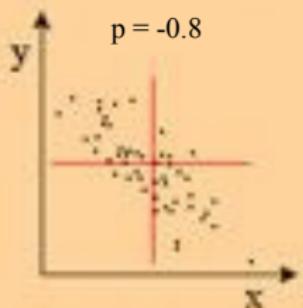
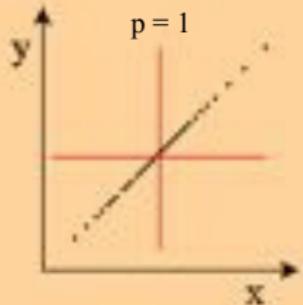
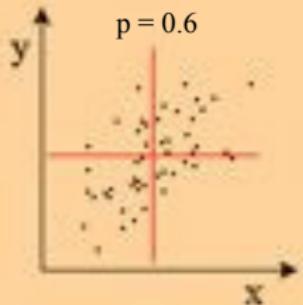
$$\rho(I, J) = \frac{\sum_{x,y} (I(x, y) - \bar{I})(J(x, y) - \bar{J})}{\sqrt{\sum_{x,y} (I(x, y) - \bar{I})^2} \sqrt{\sum_{x,y} (J(x, y) - \bar{J})^2}}$$

$$\rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$



Exemples

$$\rho = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$



# Coefficient de corrélation

- Calculable à partir de l'histogramme conjoint  $H_{I,J}$ ?
- $n$ , nombre de pixels dans chaque image
- $I$  et  $J$  moyens

$$\bar{I} = \frac{1}{n} \sum_{i,j} H(i,j) i \quad (\text{idem pour } \bar{J})$$

- Covariance

$$\sum_{x,y} (I(x,y) - \bar{I}) (J(x,y) - \bar{J}) = \sum_{i,j} H(i,j) (i - \bar{I}) (j - \bar{J})$$

$$\sum_{x,y} (I(x,y) - \bar{I})^2 = \frac{1}{n} \sum_{i,j} H_{i,j} i^2 - \bar{I}^2 \quad (\text{idem pour } J)$$

# Coefficient de corrélation

- À partir de l'histogramme conjoint

$$\rho(I, J) = \frac{\sum_{i,j} H(i,j) (i - \bar{I}) (j - \bar{J})}{\sqrt{(\frac{1}{n} \sum_{i,j} H_{i,j} i^2 - \bar{I}^2)(\frac{1}{n} \sum_{i,j} H_{i,j} j^2 - \bar{J}^2)}}$$

# Conservation de l'intensité - SSD

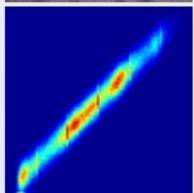
$I$



$J$

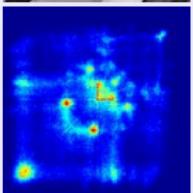


$H_{I,J}$

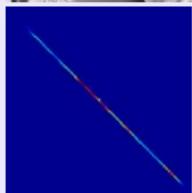


$\text{SSD}(I, J)$

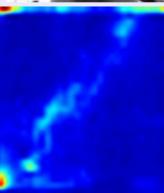
652



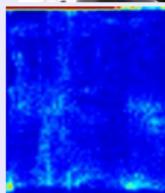
$10^9$



$10^{10}$

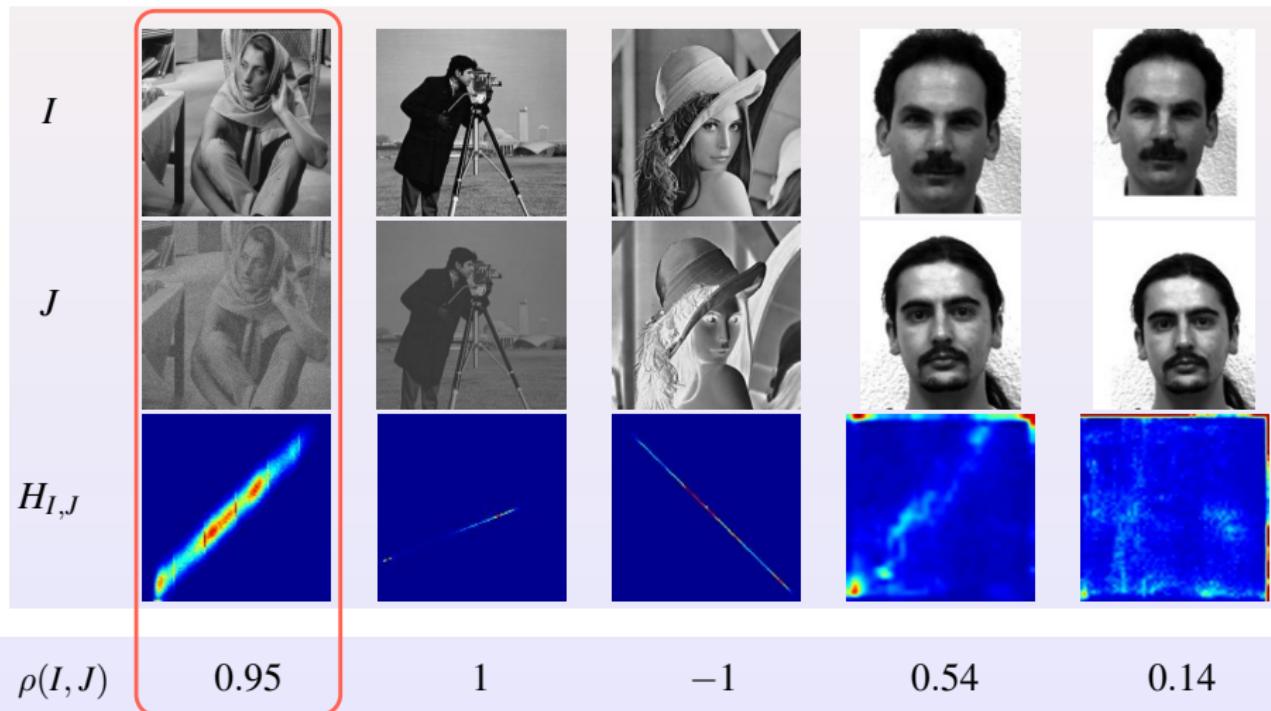


5600



13400

# Coefficient de corrélation



# Critère de similarité

- Comparaison des histogrammes de I et J?



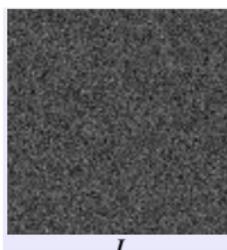
&



&



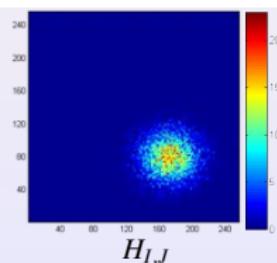
- Histogramme conjoint :



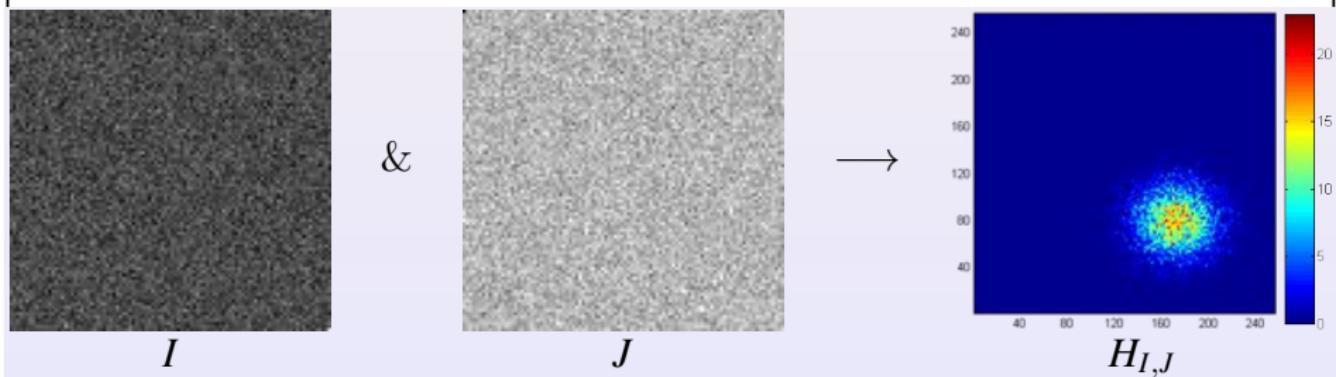
&



→



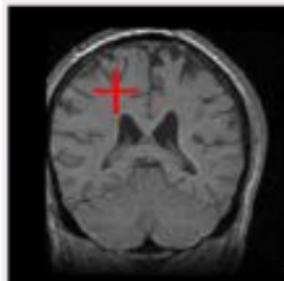
# Histogramme conjoint



$$H_{I,J}(i,j) = \text{Card}\left\{(x,y) \mid I(x,y) = i \text{ et } J(x,y) = j\right\}$$

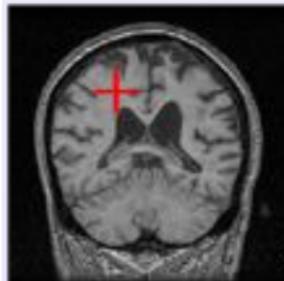
# Histogramme conjoint

$$H_{I,J}(i,j) = \text{Card}\{(x,y) \mid I(x,y) = i \text{ et } J(x,y) = j\}$$



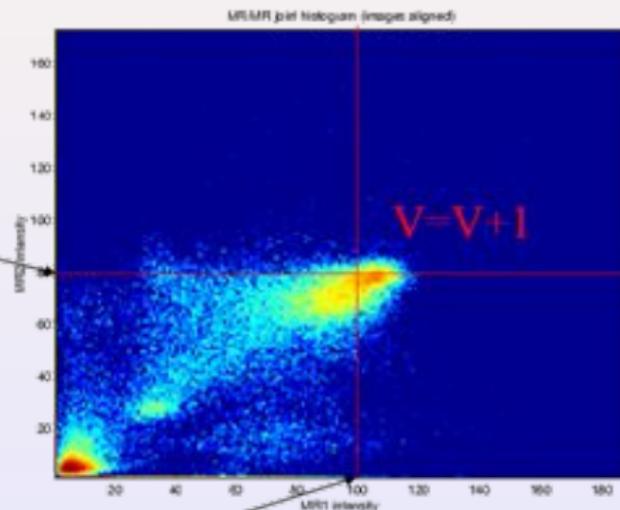
Intensity = 80

Image 2



Intensity = 100

Image 1



# Histogramme conjoint

$$H_{I,J}(i,j) = \text{Card} \left\{ (x,y) \mid I(x,y) = i \text{ et } J(x,y) = j \right\}$$

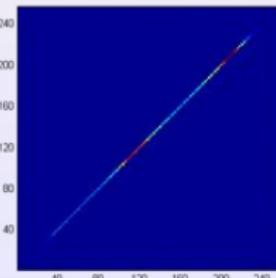
- si I et J sont de tailles X x Y à valeurs dans {0, ..., 255} :
- Taille de  $H_{I,J} = ?$ 
  - 256x256
- $\sum_i (\sum_j (H_{I,J})) = ?$ 
  - $X * Y$



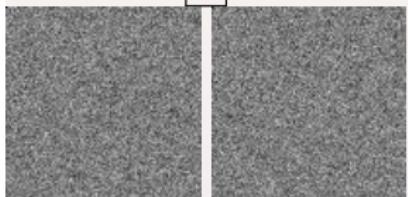
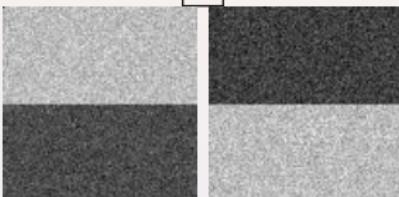
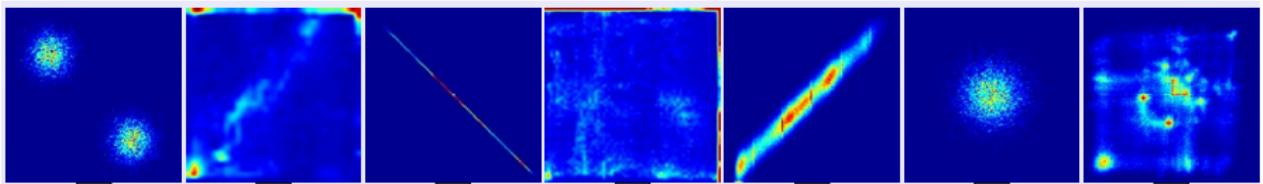
*I*



*J*



$H_{I,J}$

**A****B****C****D****E****F****G**

1

2

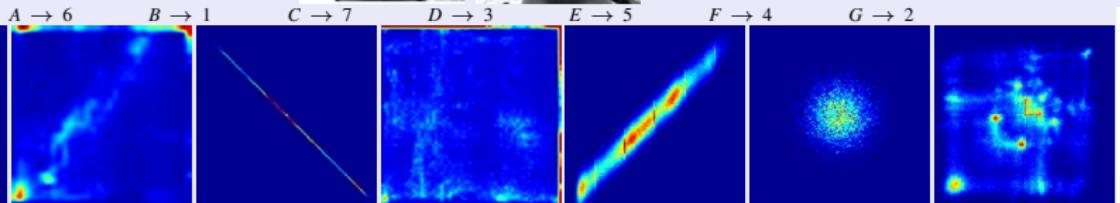
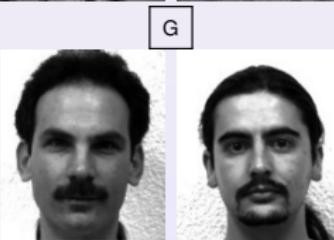
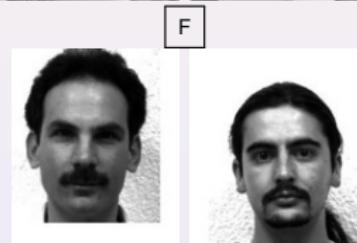
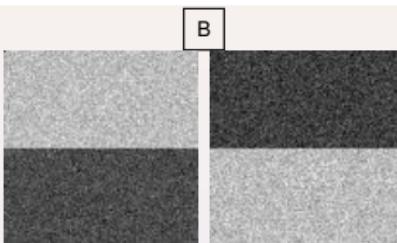
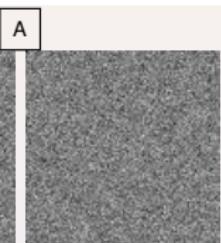
3

4

5

6

7



1

2

3

4

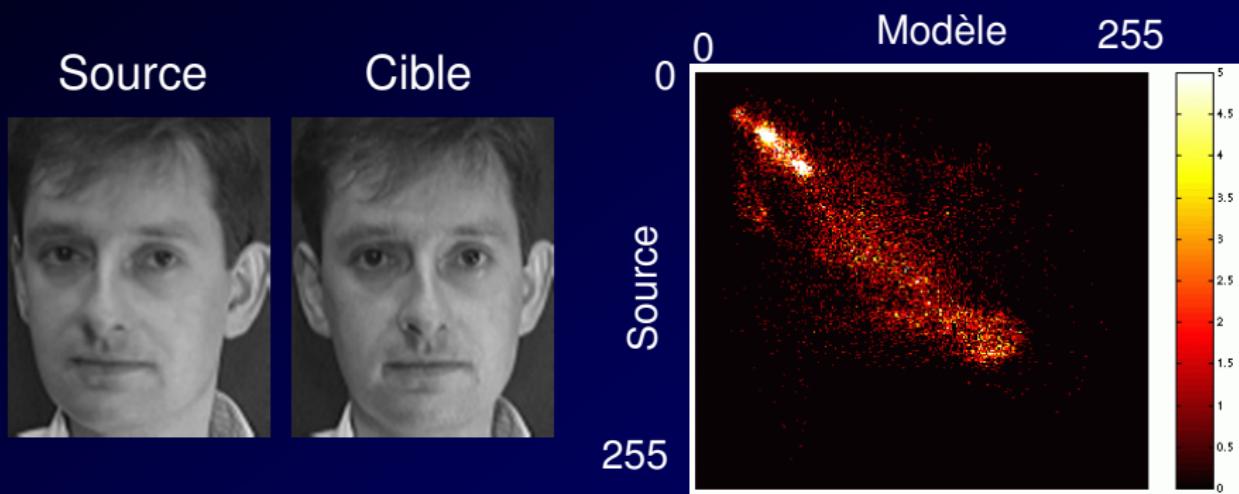
5

6

7

# Critères de similarité

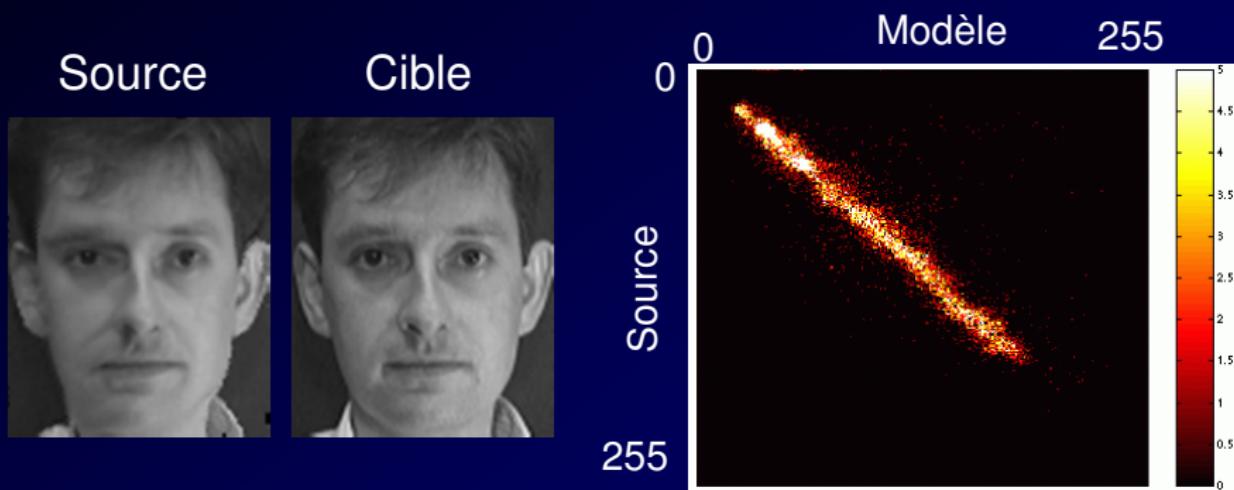
- Entropie conjointe de 2 images  $H(I,J) = - \sum_i \sum_j p_{i,j} \log(p_{i,j})$



Entropie conjointe  $H = 3.72$

# Critères de similarité

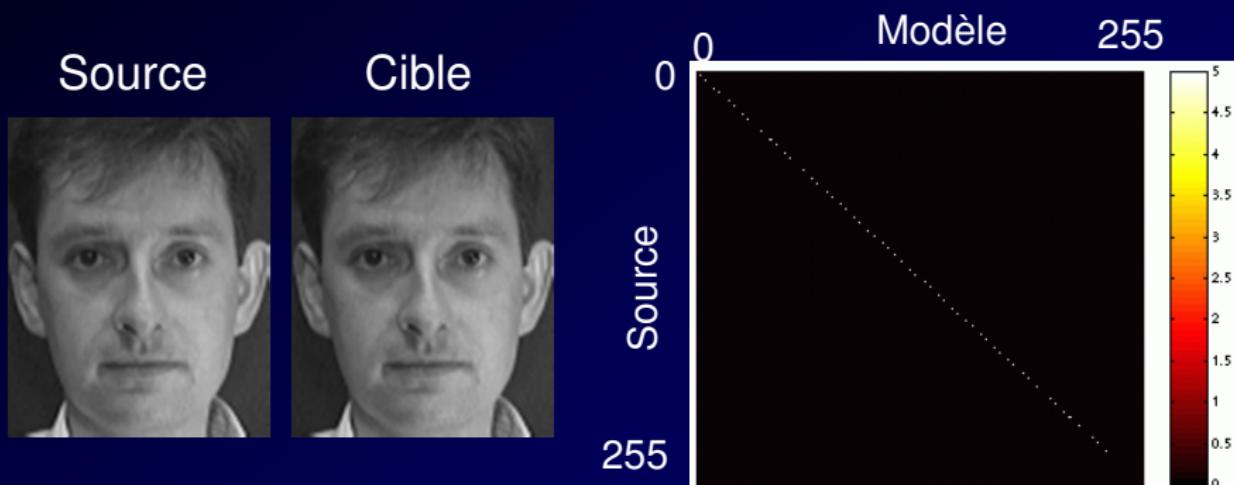
- Entropie conjointe de 2 images  $H(I,J) = - \sum_i \sum_j p_{i,j} \log(p_{i,j})$



Entropie conjointe  $H = 3.5$

# Critères de similarité

- Entropie conjointe de 2 images  $H(I,J) = - \sum_i \sum_j p_{i,j} \log(p_{i,j})$



Entropie conjointe  $H = 2.5$

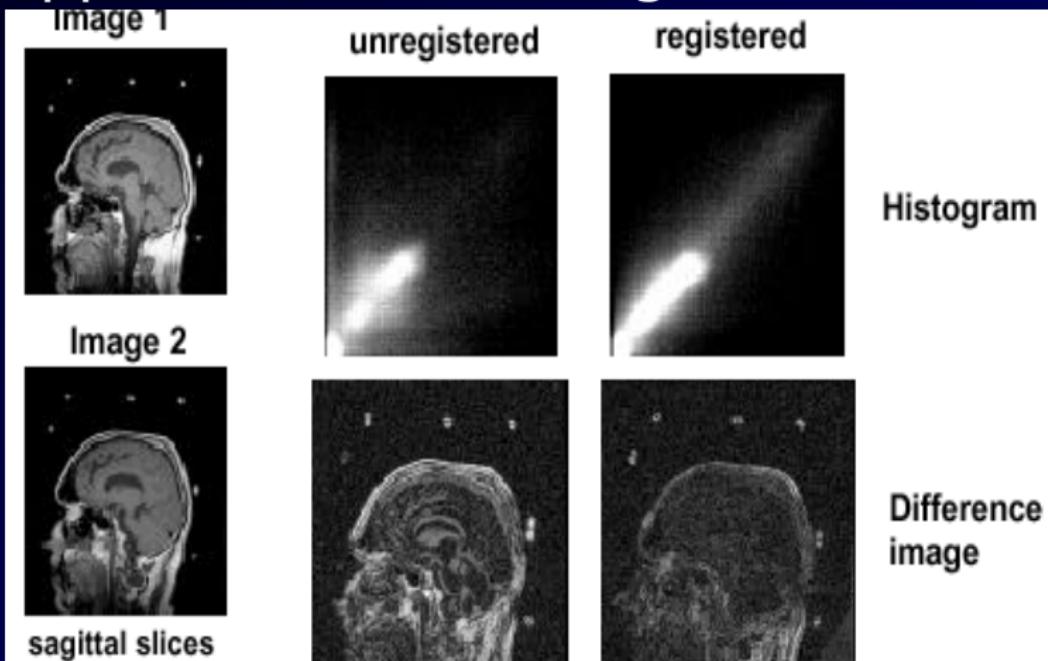
- Entropie conjointe  $H(I,J)$  est min quand I et J sont recalées

# Critères de similarité

- Entropie conjointe de 2 images  $H(I,J) = - \sum_i \sum_j p_{i,j} \log(p_{i,j})$
- Entropie conjointe  $H(I,J)$  est **min** quand I et J sont recalées
- Information mutuelle :
  - $IM(I,J) = H(I) + H(J) - H(I,J)$
  - On cherche à la **maximiser**

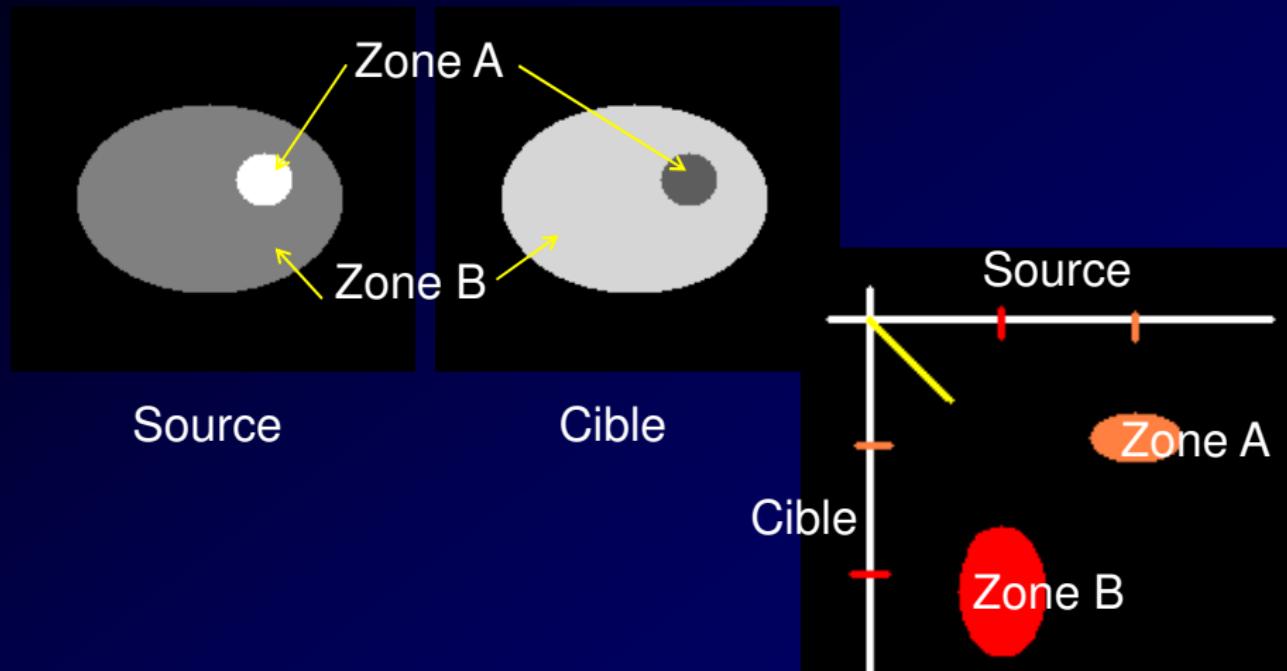
# Critère de similarité

- Application au recalage monomodal



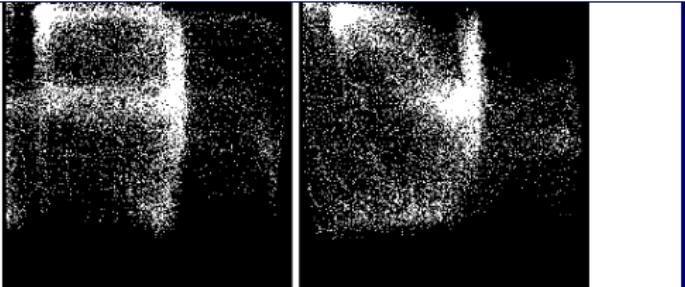
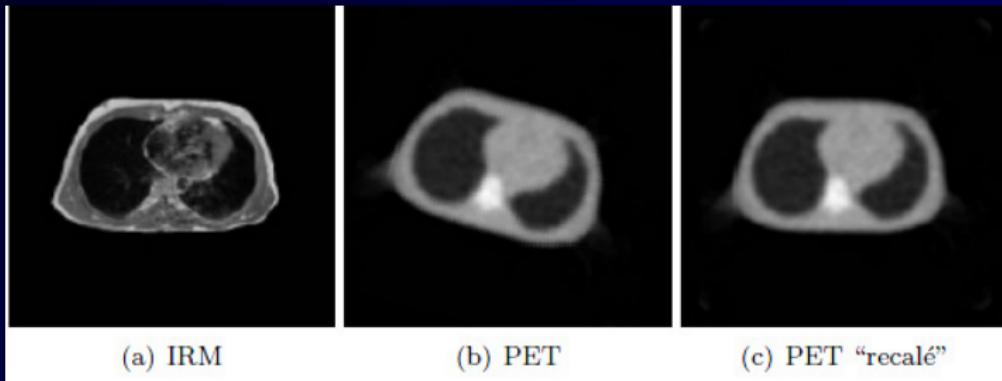
# Critère de similarité

- IM très utilisée en recalage multimodal



# Critère de similarité

- IM très utilisée en recalage multimodal



# Information mutuelle

- On peut la calculer directement à partir de l'histogramme conjoint  $H_{I,J} = p_{ij}$

$$p_{i,j} = \frac{1}{n} \operatorname{Card} \left\{ (x, y) \mid I(x, y) = i \text{ et } J(x, y) = j \right\}$$

$$IM = \sum_{i,j} p_{i,j} \log \frac{p_{i,j}}{p_i p_j} \quad \text{avec} \quad p_i = \sum_j p_{i,j} \text{ et } p_j = \sum_i p_{i,j}$$

# Information mutuelle : exemples

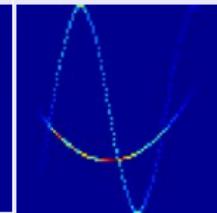
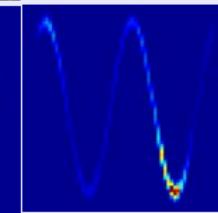
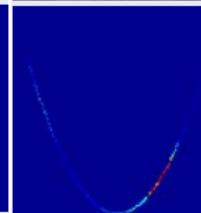
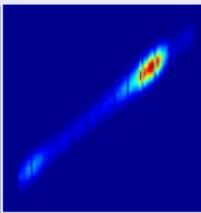
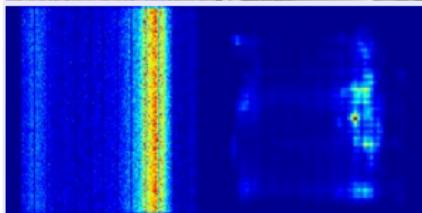
I =



J



$H_{I,J}$



$IM(I,J)$

0.03

0.09

1.22

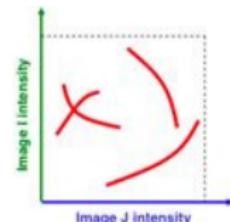
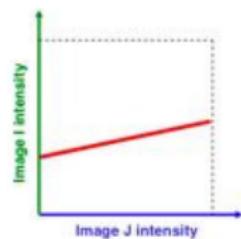
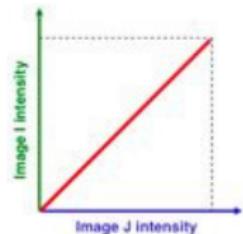
3.50

1.88

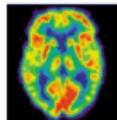
2.70

# Critère de similarité - sommaire

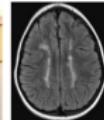
- Conservation des intensités :
  - **SSD** (à minimiser)
  - Adapté pour le recalage mono-modal intra-patient
- Dépendance affine :
  - **Coefficient de corrélation** (à maximiser)
  - Adapté pour le recalage mono-modal intra et inter-patient
- Dépendance statistique :
  - **Information mutuelle** (à maximiser)
  - Adapté pour le recalage multi-modal (TDM/TEP, TDM/IRM, ...)



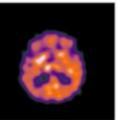
# Les transformations linéaires



TEP



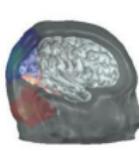
IRM



SPECT



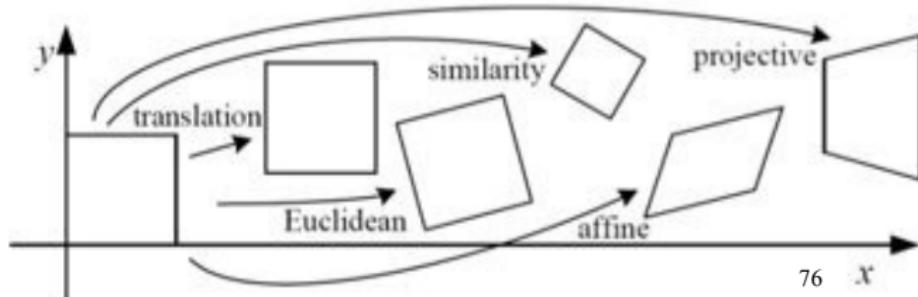
EEG



MEG

# Toutes les transformations 2D - sommaire

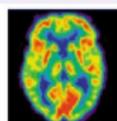
- **Translation** : 2 degrés de liberté
- **Rotation + translation** : 3 degrés de liberté
- **Similitude** : 4 degrés de liberté
- **Transformation affine** : 6 degrés de liberté
- **Transformation projective** : 8 degrés de liberté



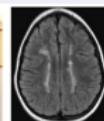
# Transformations linéaire - sommaire

- Peuvent s'écrire sous forme d'une seule matrice  $H$  (rigide, affine, projective) ... trans. "globale" ... une seule matrice
- Transformations rigides
  - Intra-sujet, même séance, mono-modalité (souvent)
- Transformations affines
  - Résolution spatiale des 2 images différentes
  - Intra-sujet, multi-modalité
- Transformations projectives
  - Recalages 3D/2D
  - e.g. recalage de radiographies sur des données TDM ou IRM

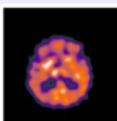
# Approches géométriques (points caractéristiques, features)



TEP



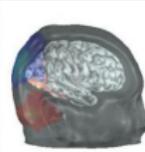
IRM



SPECT



EEG



MEG

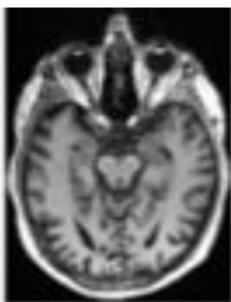
# Approches géométriques

- Sûrement les plus “naturelles” car analogue à l'esprit humain
- On commence par identifier dans les 2 images des caractéristiques géométriques communes
- Ces caractéristiques sont appelées “primitives” : points, lignes, surfaces, volumes, repères orientés
- On réduit les images à quelques primitives géométriquement pertinentes et on cherche la trans. spatiale qui apparie “au mieux” les différentes primitives

# Exemple : points caractéristiques



(a)



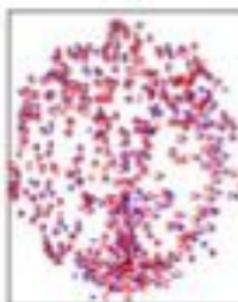
(b)



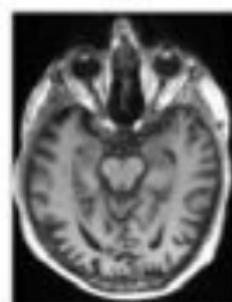
(c)



(d)



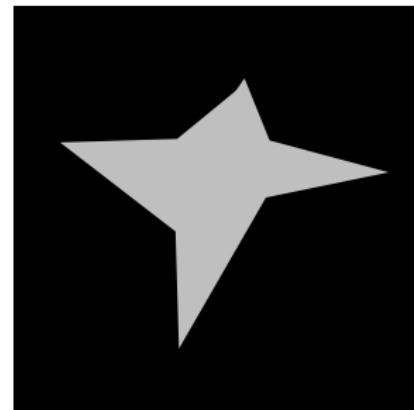
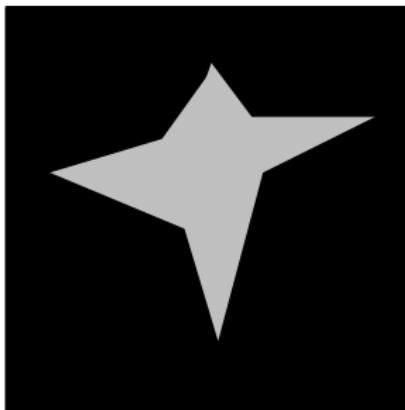
(e)



(f)

# Exemple intuitif

Comment recaler ces deux images ?

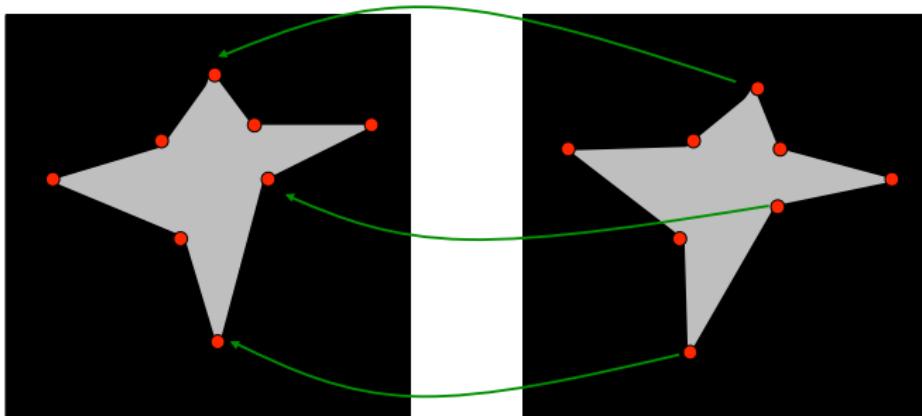


# Approches géométriques

Détection des primitives (ici, points de forte courbure)

Mesure: moindres carrés

$$S(T) = \sum_k \|T(\mathbf{x}_k) - \mathbf{y}_{CP(k)}\|^2$$

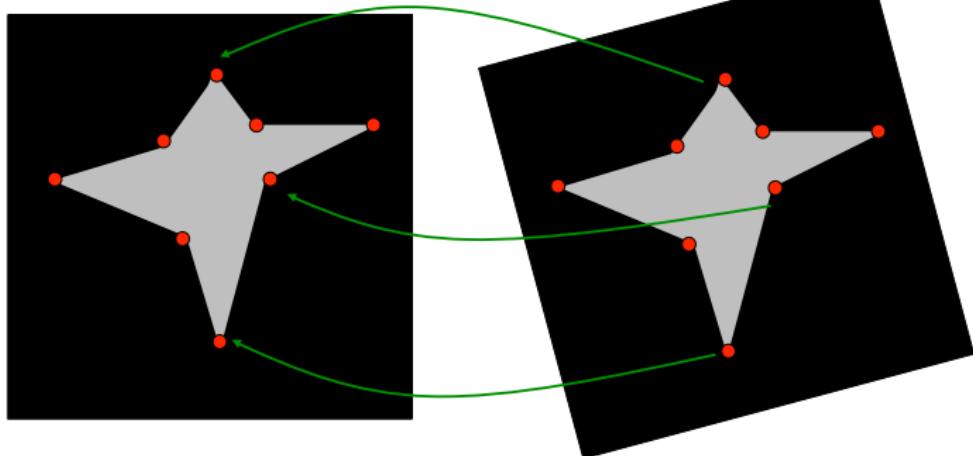


# Approches géométriques

Détection des primitives (ici, points de forte courbure)

Mesure: moindres carrés

$$S(T) = \sum_k \|T(\mathbf{x}_k) - \mathbf{y}_{CP(k)}\|^2$$



# Optimisation : approches géométriques

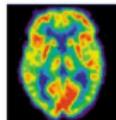
- Repose sur deux étapes bien distinctes
- Première étape : “segmentation”  
(souvent le plus dur, surtout si effectuée de façon automatique)
  - Extraire les primitives significatives.  
**Difficulté** : bruit (images ultrasonores ou autres)
  - Les primitives doivent correspondre aux **mêmes** réalités physiques dans les **2** images.  
Difficulté: recalage multi-modal (IRM T1 - IRM diffusion, TEP/IRM)
- Remarque: extraction automatique des primitives = idéal.  
Possible aussi:
  - manuel (médecin - expert)
  - stéréotaxiques (inclus dans les images)

# Repère stéréotaxique

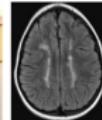
- Cadre stéréotaxique
- Contention



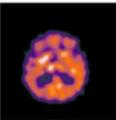
# Approches hybrides (géométrique et iconique)



TEP



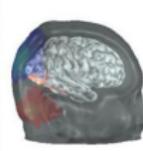
IRM



SPECT



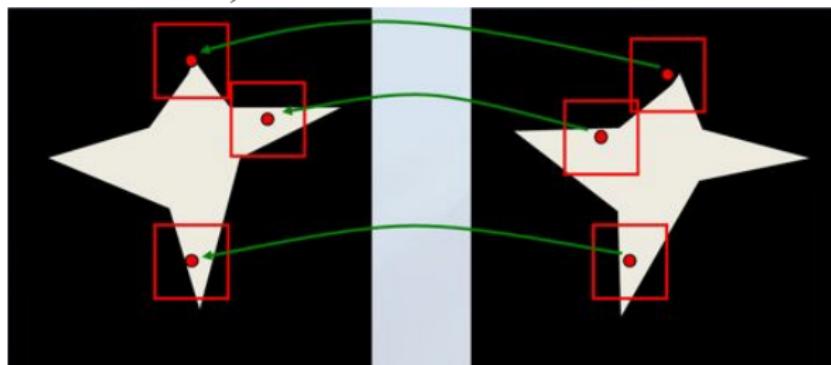
EEG



MEG

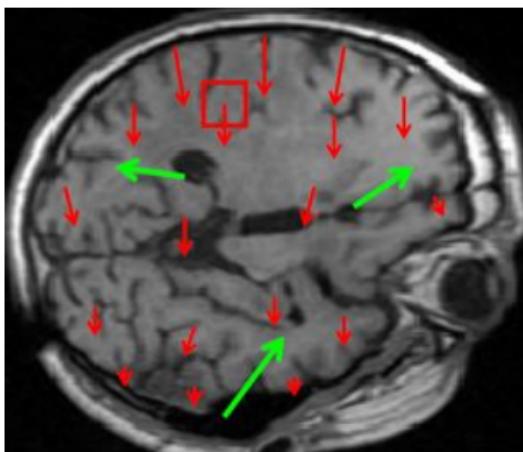
# Approches hybrides : bloc-matching

- On considère des sous-images (ou “blocs”) régulièrement échantillonnés
- On cherche dans l’autre image le bloc le “plus similaire”
- On obtient ainsi des appariements entre des images ou régions (et donc des points) avec éventuellement des outliers (des données aberrantes)



# Approches hybrides : block-matching

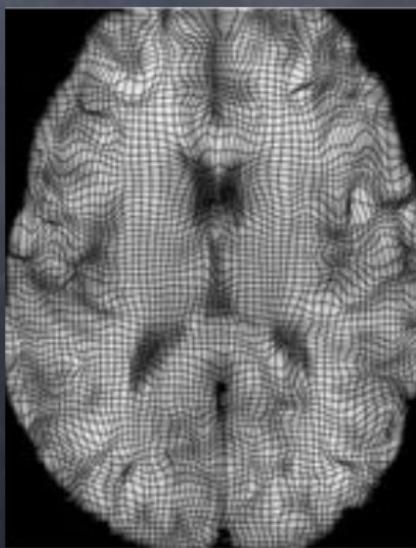
- Pour obtenir ce bloc le “plus similaire” on choisit un critère similarité (SSD souvent), coeff. de corr. ou info. mutuelle (approche iconique)
- On obtient ensuite un appariement entre les blocs:



# Approches hybrides : block-matching

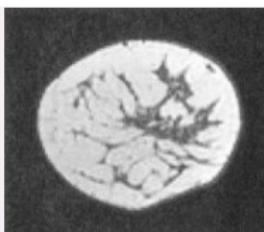
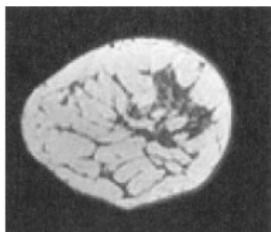
4. On cherche finalement la transformation qui apparie au mieux ces blocs : souvent par moindres carrés (approche géométrique)
5. On itère comme pour l'ICP ou autre méthode de type simplex

# Les transformations non-linéaires

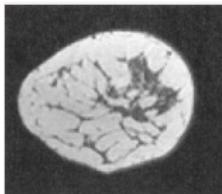


# Transformations non-linéaires

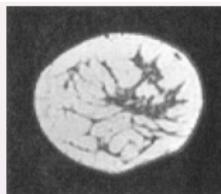
- Pourquoi?
- Intra-sujet multi-modalité
- Inter-patient
- Sujet - atlas
- Intra-patient dans le temps (changements anatomiques, évolution de la maladie, tumeur, autres)



# Recalage inter-patient de mammographies en IRM



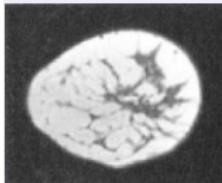
Source



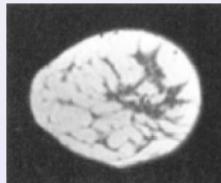
Cible



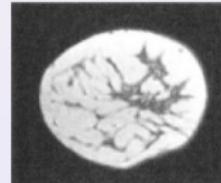
Source-Cible



Rigide



Affine



Non linéaire



# Techniques d'optimisation non linéaires

- Approche géométrique : plutôt en linéaire (moindre carré)
- Approche iconique avec petit nombre de paramètres : transformation rigide (descente du gradient à pas non-fixe)
- En non-linéaire (beaucoup d'inconnues), besoin de techniques d'optimisation plus complexes:
  - **Démons difféomorphes - ANTS. L'approche qui semble, en 2014, donner les meilleurs résultats**
  - Free form deformations
  - Recalage localement affine
  - ... Domaine de recherche actif

# Différents types de transformation

- Domaine de la transformation utilisée
- Globale
  - S'applique de manière identique à toute l'image
- Locale
  - Des sous-sections de l'image ont leurs propres transformations

# Différents types de transformation

- Rigide
  - Translation – rotation
  - Conservation des angles et des distances
  - + pour recalage intra-patient / intra modalité



# Différents types de transformation

- Affine
  - Des droites parallèles restent parallèles après transformation



Original



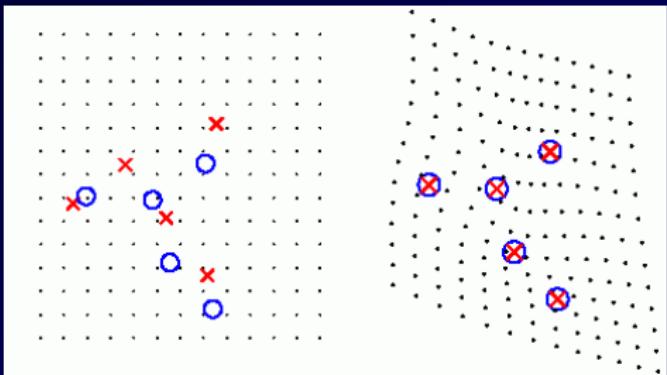
Transformation globale



Transformation locale

# Différents types de transformation

- Elastique
  - Toutes les déformations sont possibles



Original

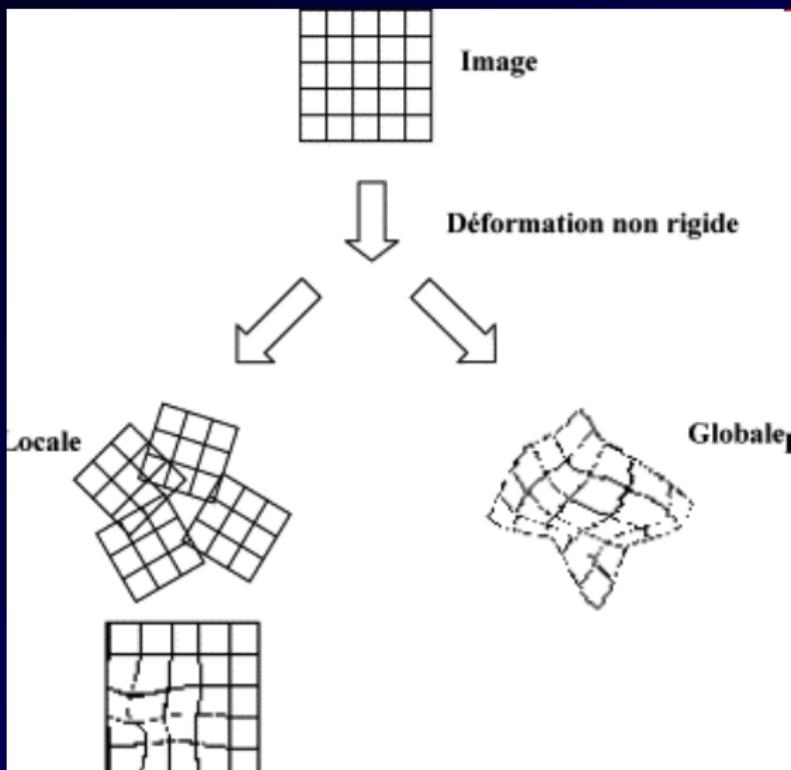


Transformation globale



Transformation locale

# Transformation élastique

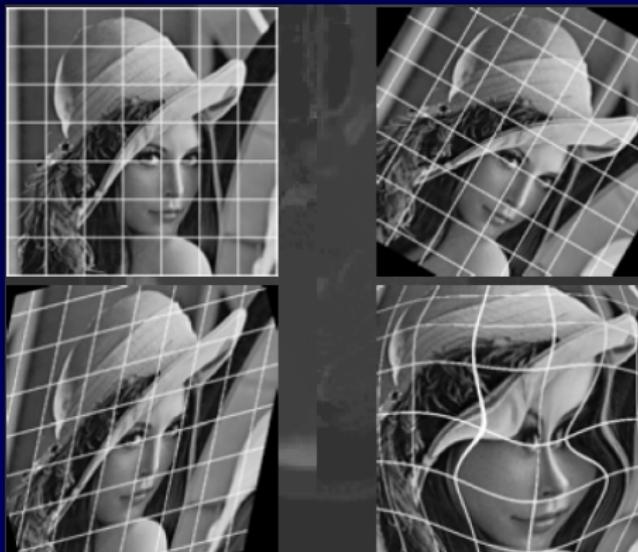


# Différents types de transformation

- Le recalage élastique
  - Quand les jeux de données à recaler ne correspondent pas au même substrat anatomique
    - Recalage inter sujet ou vers un atlas
  - Quand il existe un substrat anatomique commun mais déformé
    - Correction des déformations liées à l'acquisition
    - Structure anatomiques en mouvement

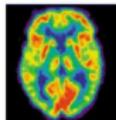
# Différents types de transformation : résumé

- Recalage rigide ou affine
  - Erreur de positionnement
  - Pas de déformations de tissus mous
- Recalage non-rigide ou élastique
  - Petites déformations locales

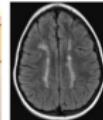


Source : <http://www.inf.u-szeged.hu/~ssip/2007/lectures/AttilaTanacs-Registration.pdf>

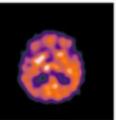
# Évaluation du recalage



TEP



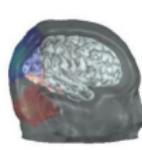
IRM



SPECT



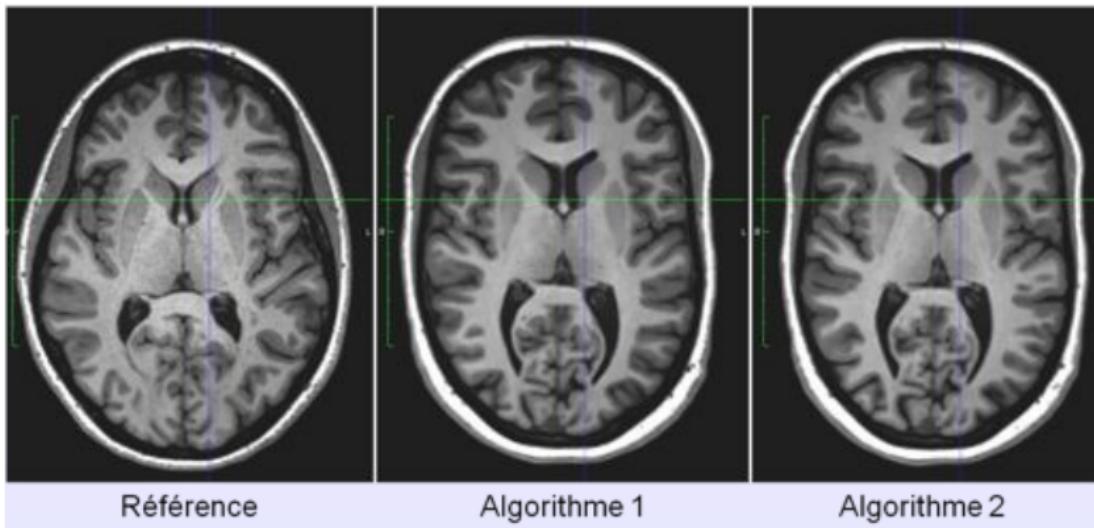
EEG



MEG

# Évaluation de recalage

- Comment évaluer quelle méthode fonctionne mieux?



# Différentes méthodes d'évaluation

- Visuelle (qualitatif)
- Semi-quantitatif
- Quantitative
- En fonction de l'application
  - Comparaison des images recalées
  - Comparaison des transformations (référence?)
  - Comparaison des segmentations obtenues (atlas)

# Évaluation qualitative

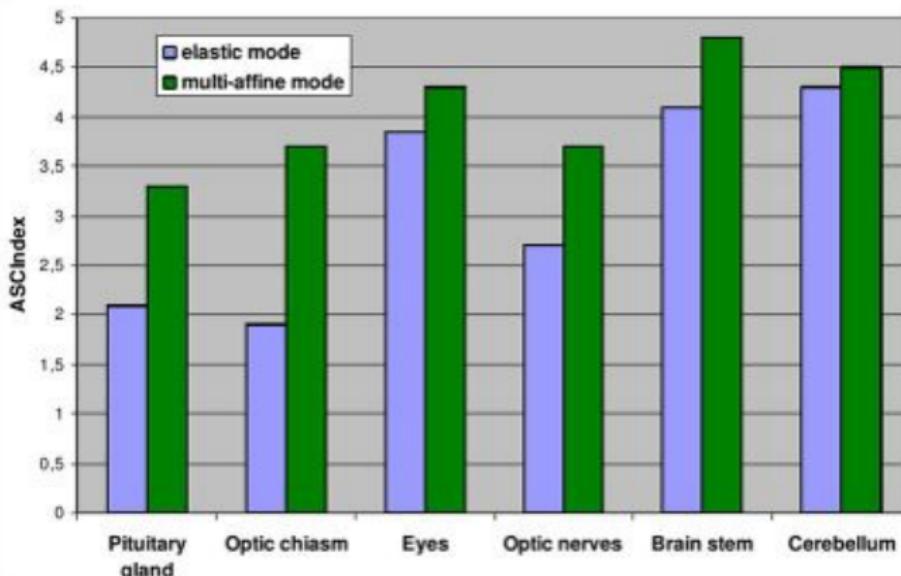
- Inspection visuelle par un clinicien ou un expert
- Souvent la première étape
- Avantages:
  - Inspection selon de multiples critères et connaissances *a priori*
  - Aucun développement nécessaire. Juste de la visu.
- Inconvénients:
  - Varie selon l'expert ou la personne (STAPLE)
  - Long: difficile à effectuer sur une grosse banque de données
  - Clinicien dure à attraper...

# Évaluation semi-quantitative

- Objectif: réduction de la subjectivité de l'évaluation qualitative
- Définition d'une échelle de notation
  - Basé sur des critères bien définis et identifiables  
(échelle CHIPS, European Task pour le vieillissement)
- Exemple
  - Évaluation de segmentation par recalage d'atlas
  - Score entre 0 et 5
  - 0 = aucun recouvrement
  - 5 = recouvrement parfait

# Évaluation semi-quantitative

- Comparaison entre deux méthodes de segmentation/recalage d'atlas



# Évaluation semi-quantitative

- Avantages:
  - Permet de prendre en compte des attentes précises
  - Moins subjectif, plus reproductible
- Inconvénients:
  - Reste subjectif
  - Difficulté d'une bonne définition de critères de notation
  - Difficile à utiliser pour des comparaisons de recalage pure

# Évaluation quantitative

- Objectif: produire des scores normalisés
- Avantages:
  - Critères objectifs, reproductibles, automatisés
- Inconvénients:
  - Critères plus simplistes
- Différents critères disponibles:
  - Comparaison d'intensité des images
  - Comparaison de transformations
  - Comparaison de landmarks
  - Comparaison de segmentations obtenues

# SEGMENTATION

D'après les cours de :

- Télécom Physique Strasbourg de l'iCube
- Christophe Portefaix

# Plan du chapitre

## 1. Définitions

- 1.1 Segmentation
- 1.2 Relations entre les pixels
- 1.3 Intérêt de la segmentation

## 2. Segmentation par seuillage

## 3. Méthodes basées région

## 4. Autres méthodes

## 5. Critères d'évaluation de la segmentation

# Qu'est-ce que la segmentation ?

## Définition

Une segmentation d'image est une partition de l'image en ensembles de pixels homogènes (selon un critère pré-défini).

# Qu'est-ce que la segmentation ?

## Définition

Une segmentation d'image est une partition de l'image en ensembles de pixels homogènes (selon un critère pré-défini).

## Propriétés :

- La segmentation n'est pas unique (algorithmes, critère d'homogénéité, initialisation, etc)
- Partition de l'image = ensemble de régions non vides, deux à deux disjointes qui recouvrent l'intégralité de l'image.

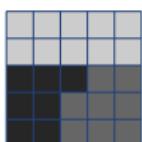
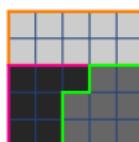
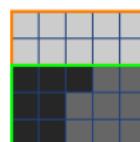


Image originale



Segmentation  
à 3 classes



Segmentation  
à 2 classes

# Qu'est-ce que la segmentation ?

## Définition

Une segmentation d'image est une partition de l'image en ensembles de pixels homogènes (selon un critère pré-défini).

## Propriétés :

- La segmentation n'est pas unique (algorithmes, critère d'homogénéité, initialisation, etc)
- Partition de l'image = ensemble de régions non vides, deux à deux disjointes qui recouvrent l'intégralité de l'image.

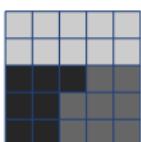
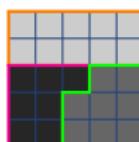
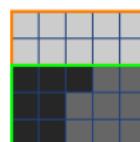


Image originale



Segmentation  
à 3 classes

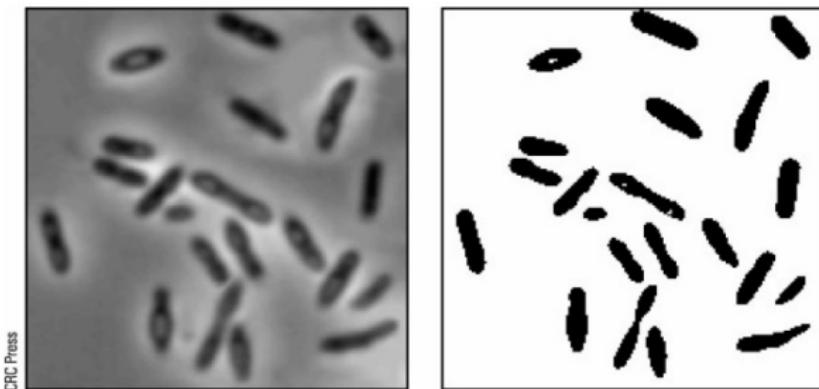


Segmentation  
à 2 classes

- Segmentation d'une image = représentation haut niveau.

## Critère d'homogénéité

Segmentation par niveaux de gris :



→ Utilisation de l'histogramme

## Critère d'homogénéité

#### Segmentation par couleurs :



→ Utilisation des informations des 3 images R, G, B.

## Critère d'homogénéité

Segmentation par texture :

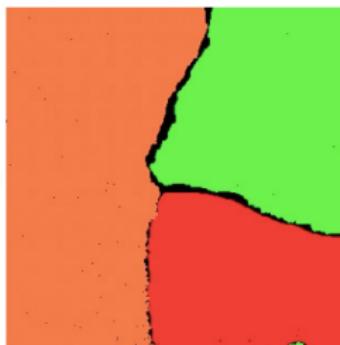
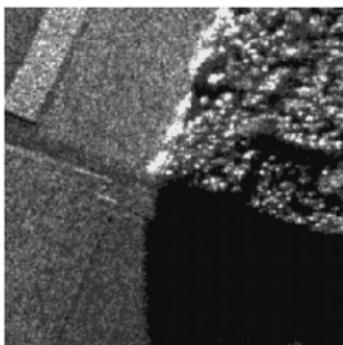
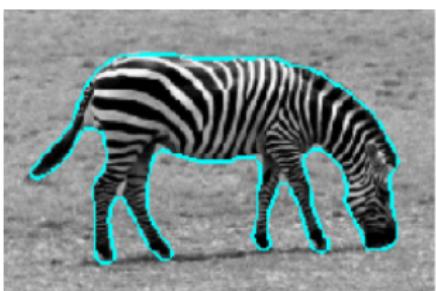


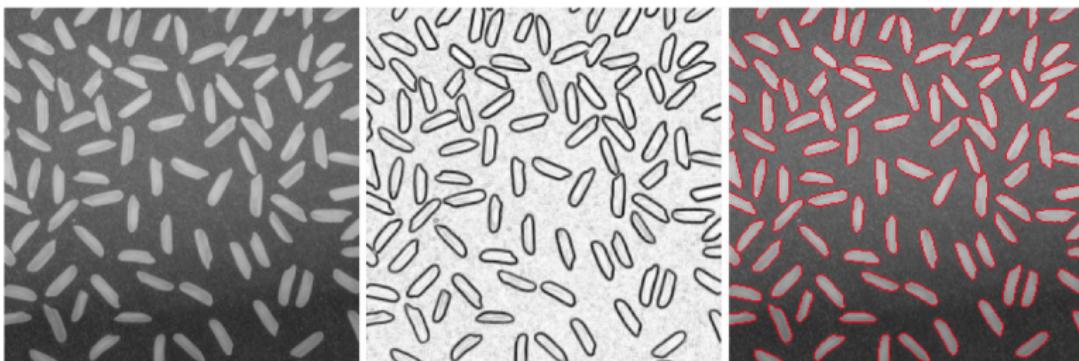
Image aérienne



→ Utilisation du contenu fréquentiel de l'image.

## Critère d'homogénéité

Segmentation par contours :



- Approche frontière : recherche des pixels dissemblables → contours entre les zones homogènes.

## Relations entre les pixels

### Voisinage

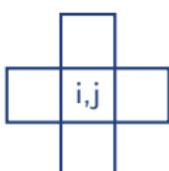
Le pixel  $p$  de coordonnées  $(i, j)$  a quatre voisins horizontaux et verticaux :

$$(i - 1, j), (i + 1, j), (i, j - 1), (i, j + 1)$$

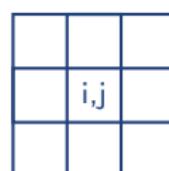
Cet ensemble est appelé le 4-voisinage de  $p$ .

On appelle 8-voisinage de  $p$  l'ensemble de pixels constitué du 4-voisinage et des pixels voisins dans la diagonale :

$$(i - 1, j - 1), (i - 1, j + 1), (i + 1, j - 1), (i + 1, j + 1)$$



4-voisinage



8-voisinage

# Relations entre les pixels

## Adjacence

Soit  $V$  un ensemble de valeurs d'intensité. Les pixels  $p$  et  $q$  à valeur dans  $V$  sont dits 4-adjacents (resp. 8-adjacent) si  $q$  appartient au 4-voisinage (resp. 8-voisinage) de  $p$ .

## Chemin

On appelle chemin un ensemble de pixels

$$(i_0, j_0), (i_1, j_1), \dots, (i_n, j_n)$$

tels que pour tout  $k = 1, \dots, n$ ,  $(i_{k-1}, j_{k-1})$  et  $(i_k, j_k)$  sont adjacents. On note  $n$  la longueur du chemin.

Si  $(i_0, j_0) = (i_n, j_n)$  on dira que le chemin est fermé.

## Application :

- quels pixels sont adjacents dans  $V = \{0\}$  (pixels noirs) ?
- quels chemins possibles dans  $V$  ?

p	q	r
s	t	u
v	w	x

# Relations entre les pixels

## Pixels connectés

Soit  $S$  un ensemble de pixels. Deux pixels  $p$  et  $q$  sont dit connectés dans  $S$  s'il existe un chemin les reliant constitué uniquement de pixels de  $S$ .

### Application :

→  $s$  et  $u$  sont-ils connectés ?

p	q	r
s	t	u
v	w	x

# Relations entre les pixels

## Pixels connectés

Soit  $S$  un ensemble de pixels. Deux pixels  $p$  et  $q$  sont dit connectés dans  $S$  s'il existe un chemin les reliant constitué uniquement de pixels de  $S$ .

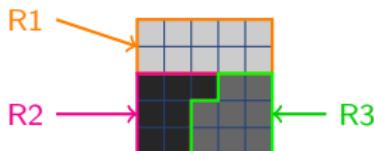
## Application :

→  $s$  et  $u$  sont-ils connectés ?

$p$	$q$	$r$
$s$	$t$	$u$
$v$	$w$	$x$

## Régions

On appelle région ou ensemble connecté tout sous-ensemble de pixels connectés dans l'image.



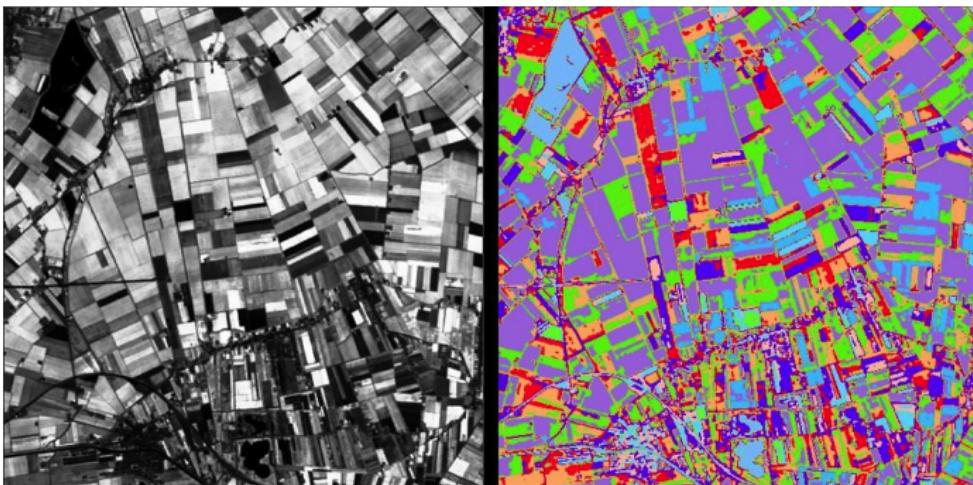
3 régions



4 régions  
(pas de connexion entre R4 et R2)

## Intérêt de la segmentation : classification

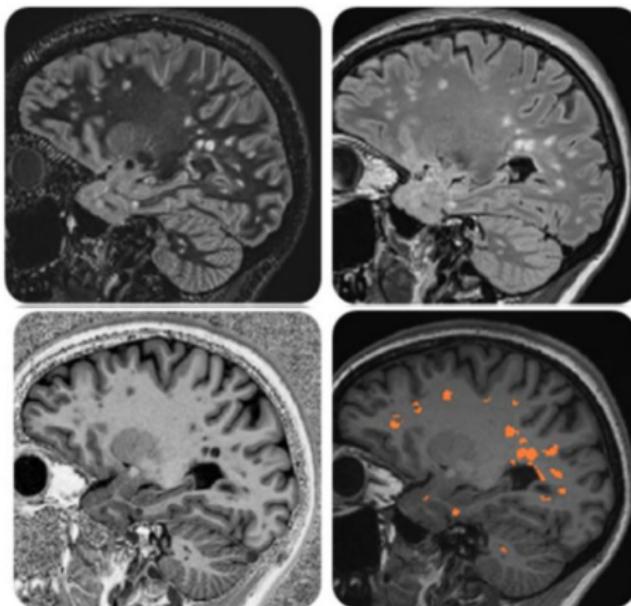
La segmentation sert de base à la classification des régions de l'image



Segmentation pour la classification d'une région agricole. © INRIA - Projet Ariana

## Intérêt de la segmentation : imagerie médicale

### Estimation de la taille des lésions dans le cerveau



## Intérêt de la segmentation : incrustation vidéo

Exemple basé sur la segmentation couleur (fond vert)



## Intérêt de la segmentation : incrustation vidéo

Importance de faire une bonne segmentation :



→ mauvaise segmentation de l'image sur fond vert = problème d'incrustation de la vidéo.

# Plan du chapitre

## 1. Définitions

## 2. Segmentation par seuillage

- 2.1 Binarisation
- 2.2 Choix du seuil
- 2.3 Seuillage automatique
- 2.4 Méthode de Otsu
- 2.5 Seuillage multiple
- 2.6 Cas problématiques et prétraitement des données
- 2.7 Méthodes de clustering

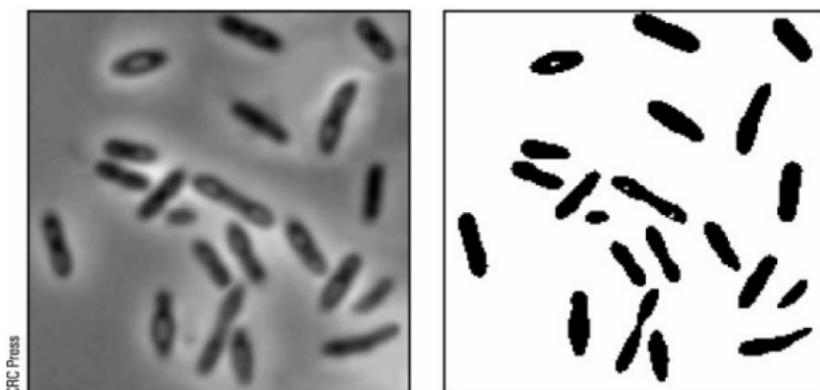
## 3. Méthodes basées région

## 4. Autres méthodes

## 5. Critères d'évaluation de la segmentation

## Segmentation à deux classes d'une image en niveaux de gris

Segmentation pixels clairs vs. pixels foncés → binarisation de l'image



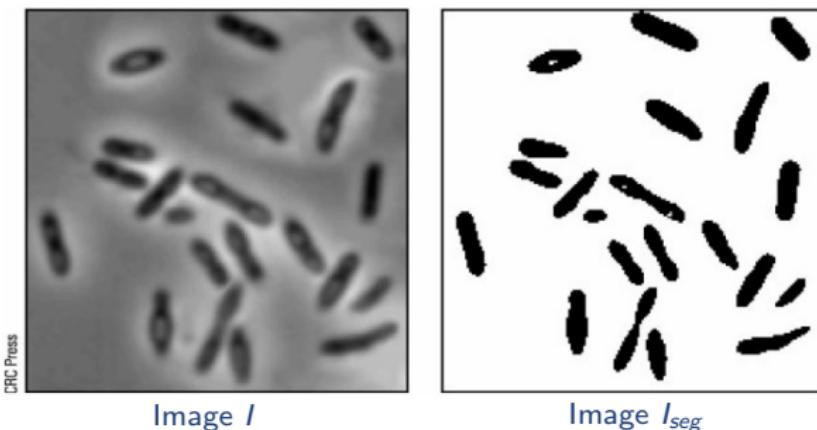
CRC Press

# Segmentation à deux classes d'une image en niveaux de gris

Segmentation par seuillage :

$$I_{seg}(i,j) = \begin{cases} 1 \text{ (blanc)} & \text{si } I(i,j) \geq S \\ 0 \text{ (noir)} & \text{si } I(i,j) < S \end{cases}$$

où  $S$  est le seuil (niveau de gris).

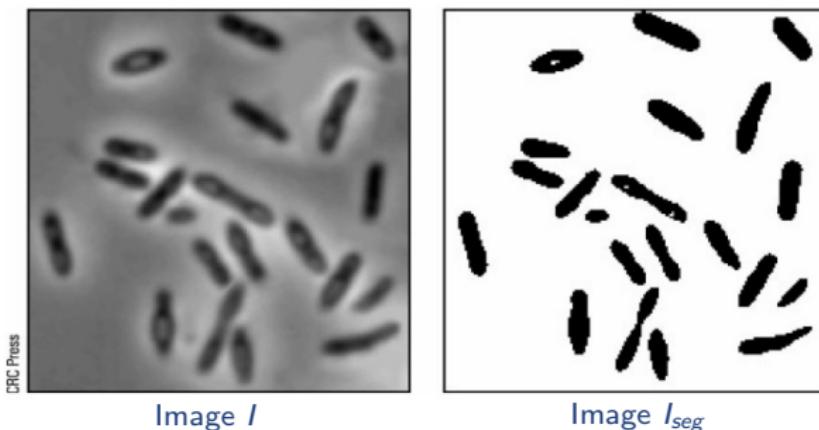


# Segmentation à deux classes d'une image en niveaux de gris

Segmentation par seuillage :

$$I_{\text{seg}}(i,j) = \begin{cases} 1 \text{ (blanc)} & \text{si } I(i,j) \geq S \\ 0 \text{ (noir)} & \text{si } I(i,j) < S \end{cases}$$

où  $S$  est le seuil (niveau de gris).



Comment choisir le seuil  $S$  ?

## Choix de seuil



Image originale (256 niveaux de gris)



Seuil à 150



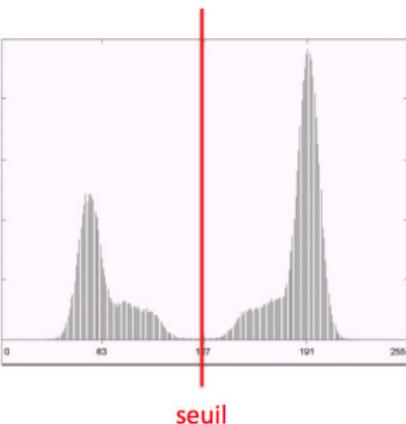
Seuil à 70



Seuil à 220

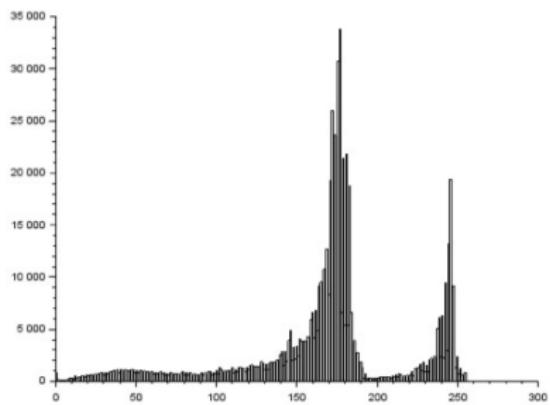
## Choix de seuil : analyse de l'histogramme

→ Dans certains cas, le choix du seuil est facile :



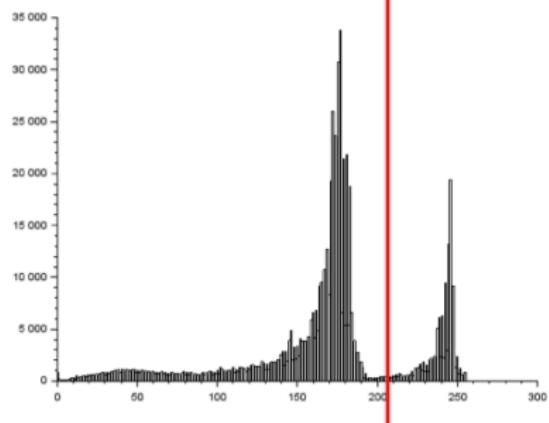
## Choix de seuil : analyse de l'histogramme

→ Dans d'autres cas, le choix du seuil est moins évident :



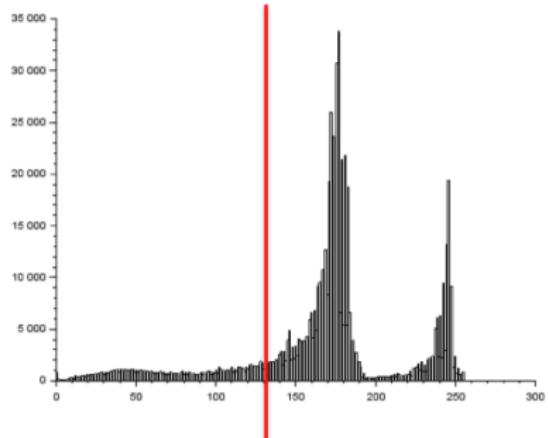
## Choix de seuil : analyse de l'histogramme

→ Dans d'autres cas, le choix du seuil est moins évident :



## Choix de seuil : analyse de l'histogramme

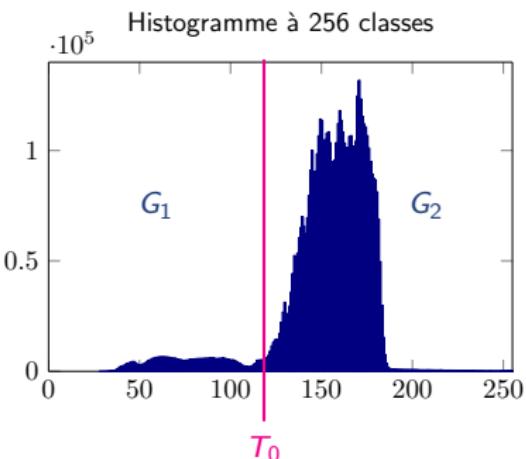
→ Dans d'autres cas, le choix du seuil est moins évident :



# Seuillage automatique

## Algorithm :

1. Calcul de l'histogramme de l'image.
2. Sélectionner un seuil initial  $T_0$ .
3. Calculer des intensités moyennes  $m_1$  et  $m_2$  des groupes  $G_1$  et  $G_2$ .
4. Calcul du nouveau seuil  $T = (m_1 + m_2)/2$ .
5. Continuer jusqu'à ce que les variations de  $T$  soient inférieures à  $\epsilon$  (défini par l'utilisateur).

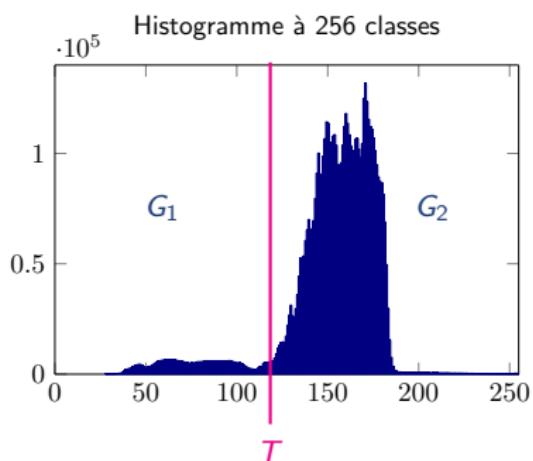


## Méthode de Otsu

**Principe :** Trouver le seuil qui minimise la variance intra-classe pondérée  $\sigma_w^2$  (raffinement de la méthode du seuillage automatique).

**Variance intra-classe :**

$$\sigma_w^2 = q_1(T)\sigma_1^2(T) + q_2(T)\sigma_2^2(T)$$



**Probabilité de chaque classe :**

$$q_1(T) = \sum_{r=0}^T p(r) \quad \text{et} \quad q_2(T) = \sum_{r=T+1}^{2^K - 1} p(r)$$

avec

$$p(r) = \frac{h(r)}{N \times M} \text{ la probabilité de } r$$

$h$  : l'histogramme de l'image

# Méthode de Otsu

**Moyennes :**

$$m_1(T) = \sum_{r=0}^T \frac{r \times p(r)}{q_1(T)} \quad \text{et} \quad m_2(T) = \sum_{r=T+1}^{2^K - 1} \frac{r \times p(r)}{q_2(T)}$$

**Variances :**

$$\sigma_1^2(T) = \sum_{r=0}^T (r - m_1(T))^2 \frac{p(r)}{q_1(T)} \quad \text{et} \quad \sigma_2^2(T) = \sum_{r=T+1}^{2^K - 1} (r - m_2(T))^2 \frac{p(r)}{q_2(T)}$$

**Implémentation de la méthode :** Calculer pour tous les seuils  $T$  possibles ( $T = 0, \dots, 2^K - 1$ ) la variance intra-classe pondérée  $\sigma_w^2$  et retenir le seuil  $T$  qui minimise  $\sigma_w^2$ .

## Méthode de Otsu

A noter : la variance de l'image  $\sigma^2$  s'écrit :

$$\sigma^2 = \sigma_w^2 + \sigma_{1,2}^2$$

où  $\sigma_{1,2}^2$  est la variance inter-classe.

## Méthode de Otsu

A noter : la variance de l'image  $\sigma^2$  s'écrit :

$$\sigma^2 = \sigma_w^2 + \sigma_{1,2}^2$$

où  $\sigma_{1,2}^2$  est la variance inter-classe.

On en déduit :

→ Le problème initial qui consiste à minimiser  $\sigma_w^2$  est équivalent à maximiser  $\sigma_{1,2}^2$ .

## Méthode de Otsu

A noter : la variance de l'image  $\sigma^2$  s'écrit :

$$\sigma^2 = \sigma_w^2 + \sigma_{1,2}^2$$

où  $\sigma_{1,2}^2$  est la variance inter-classe.

On en déduit :

- Le problème initial qui consiste à minimiser  $\sigma_w^2$  est équivalent à maximiser  $\sigma_{1,2}^2$ .
- C'est-à-dire que construire deux groupes de pixels qui se ressemblent ...

## Méthode de Otsu

A noter : la variance de l'image  $\sigma^2$  s'écrit :

$$\sigma^2 = \sigma_w^2 + \sigma_{1,2}^2$$

où  $\sigma_{1,2}^2$  est la variance inter-classe.

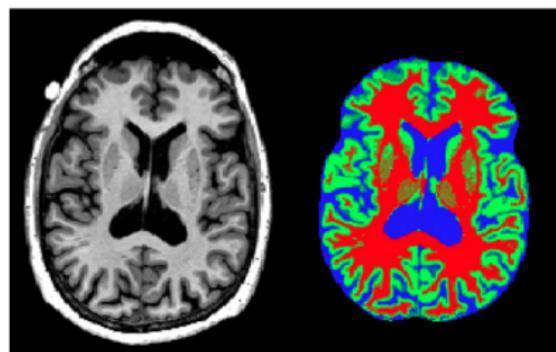
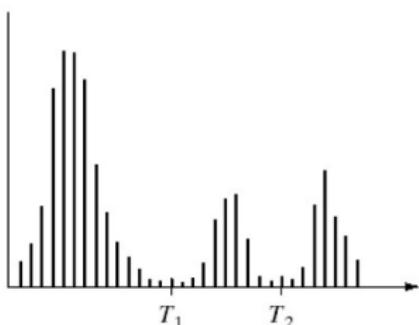
On en déduit :

- Le problème initial qui consiste à minimiser  $\sigma_w^2$  est équivalent à maximiser  $\sigma_{1,2}^2$ .
- C'est-à-dire que construire deux groupes de pixels qui se ressemblent ...
- ... revient à construire deux groupes très dissemblables de pixels.

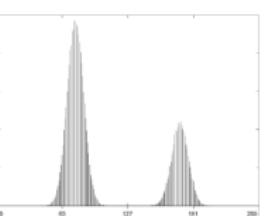
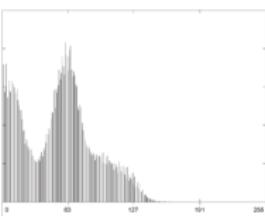
## Seuillage multiple

- Plusieurs modes visibles sur l'histogramme.
- Seuillage à plusieurs classes :

- $r \in [0, T_1]$
- $r \in ]T_1, T_2]$
- $r \in ]T_2, 2^K - 1]$



## Cas problématiques : défaut d'éclairage



La variation d'éclairage ne permet pas de seuiller correctement l'image. Plusieurs solutions sont possibles :

- Le défaut d'éclairage *G* est connu, on utilise un modèle paramétrique pour le décrire et on corrige l'image avant le seuillage :

$$\forall(i,j) : I(i,j) = J(i,j)/G(i,j)$$

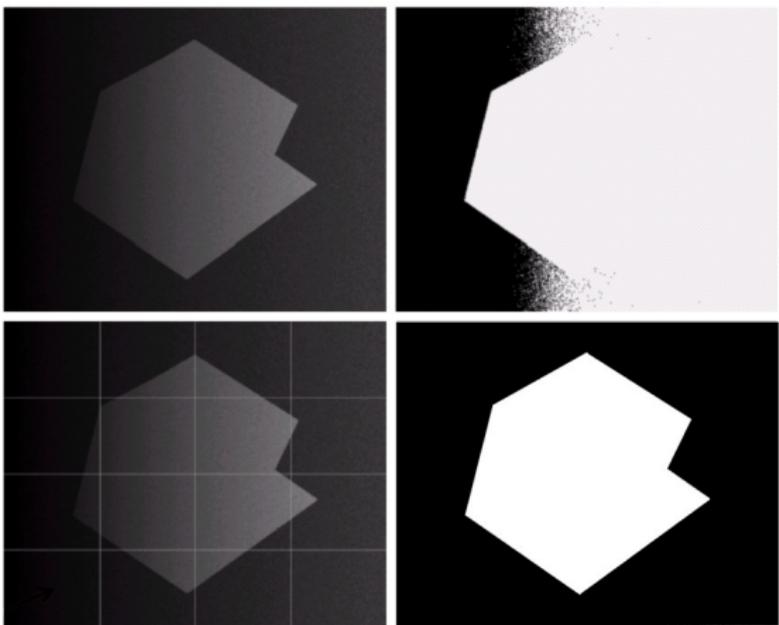
## Cas problématiques : défaut d'éclairage

→ Le défaut d'éclairage  $G$  est inconnu : on peut utiliser un seuillage local.

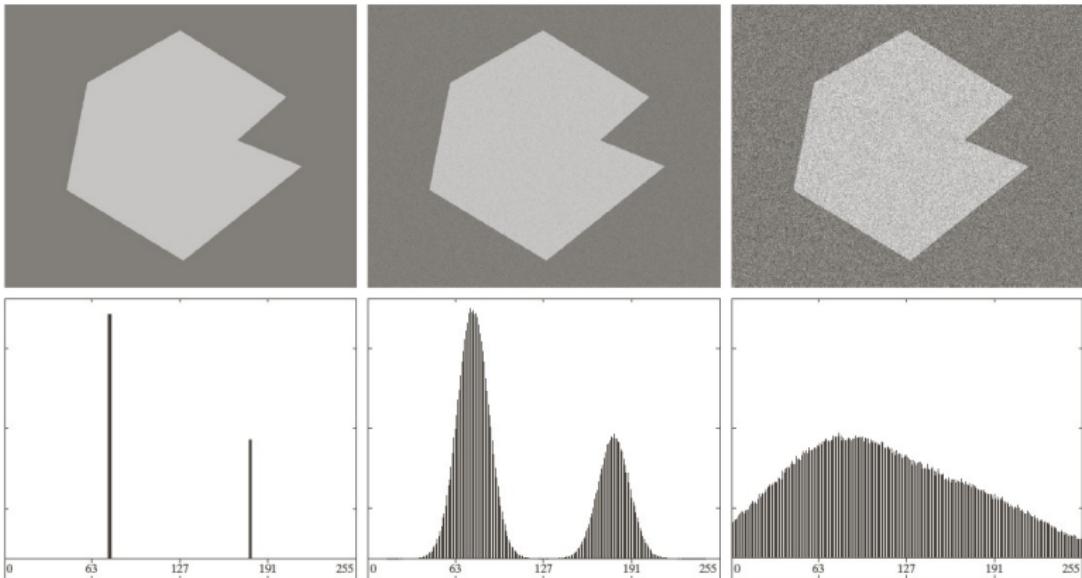
a b  
c d

**FIGURE 10.30**

- (a) Original image.
- (b) Result of global thresholding.
- (c) Image subdivided into individual subimages.
- (d) Result of adaptive thresholding.



## Cas problématiques : bruit



Ajout du bruit sur l'image  $\Rightarrow$  convolution de l'histogramme de l'image par une gaussienne (histogramme du bruit).

Soient  $X$  et  $n$  deux variables aléatoires indépendantes :

$$Y = X + n \quad \Rightarrow \quad f_Y(u) = (f_X * f_n)(u)$$

## Cas problématiques : effet du bruit sur l'histogramme

### Solutions possibles :

→ Filtrer l'image initiale :

- filtre gaussien,
- filtre médian,
- filtre moyenneur,
- méthode de débruitage



## Cas problématiques : effet du bruit sur l'histogramme

### Solutions possibles :

→ Filtrer l'image initiale :

- filtre gaussien,
- filtre médian,
- filtre moyenneur,
- méthode de débruitage

→ Filtrer l'image seuillée :

- opérateurs morphologiques (cf cours suivant),
- filtre médian



## Cas problématiques : effet du bruit sur l'histogramme

### Solutions possibles :

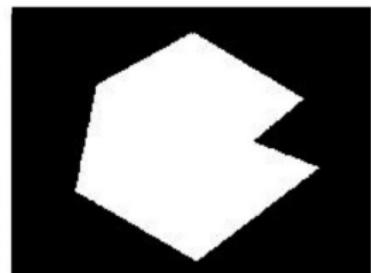
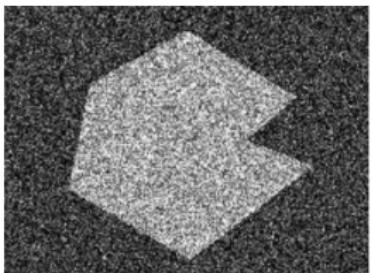
→ Filtrer l'image initiale :

- filtre gaussien,
- filtre médian,
- filtre moyenneur,
- méthode de débruitage

→ Filtrer l'image seuillée :

- opérateurs morphologiques (cf cours suivant),
- filtre médian

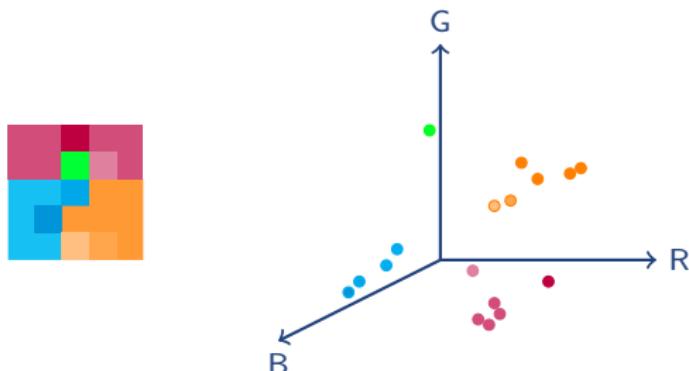
→ Incorporer de l'information spatiale dans la méthode de segmentation.



## Méthodes de clustering – K-moyennes

**Extension du seuillage d'histogramme aux images couleurs :**

- Un pixel est maintenant représenté par un vecteur (intensités R, G et B) contrairement aux images en niveaux de gris (un pixel = un scalaire).



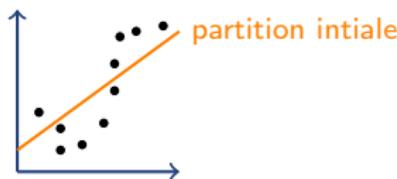
- La représentation de l'image par son histogramme n'est plus possible.
- Principe des méthodes de clustering : regrouper les vecteurs en groupes homogènes.

## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.

### Exemple :

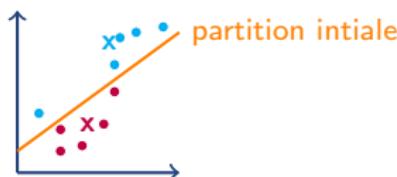


## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.

### Exemple :



## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.
- Pour chaque point :
  - Calcul de la distance du point au centroïde de chaque cluster.
  - Affectation du point au cluster le plus proche.

### Exemple :



## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.
- Pour chaque point :
  - Calcul de la distance du point au centroïde de chaque cluster.
  - Affectation du point au cluster le plus proche.
- Calcul des centroïdes des nouveaux clusters formés.

### Exemple :



## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.
- Pour chaque point :
  - Calcul de la distance du point au centroïde de chaque cluster.
  - Affectation du point au cluster le plus proche.
- Calcul des centroïdes des nouveaux clusters formés.
- Répéter les étapes 3 et 4 jusqu'à ce qu'il n'y ait plus de changement dans l'assignement des points (ou des centroïdes).

### Exemple :



## Méthodes de clustering – K-moyennes

### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.
- Pour chaque point :
  - Calcul de la distance du point au centroïde de chaque cluster.
  - Affectation du point au cluster le plus proche.
- Calcul des centroïdes des nouveaux clusters formés.
- Répéter les étapes 3 et 4 jusqu'à ce qu'il n'y ait plus de changement dans l'assignement des points (ou des centroïdes).

### Exemple :



## Méthodes de clustering – K-moyennes

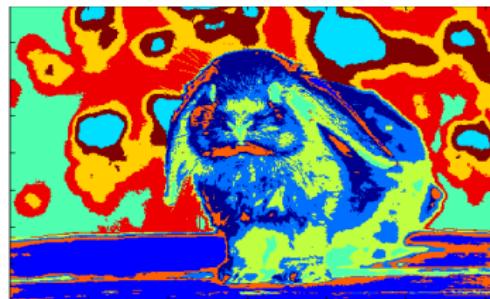
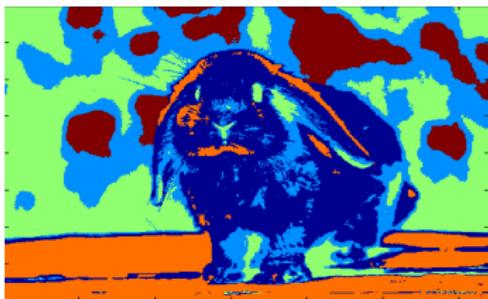
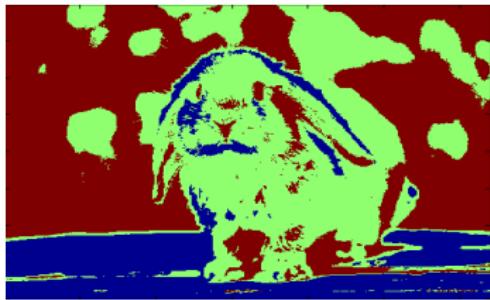
### Algorithme des K-moyennes :

- Partitionnement aléatoire des points en K clusters.
- Calcul du centroïde de chacun des clusters.
- Pour chaque point :
  - Calcul de la distance du point au centroïde de chaque cluster.
  - Affectation du point au cluster le plus proche.
- Calcul des centroïdes des nouveaux clusters formés.
- Répéter les étapes 3 et 4 jusqu'à ce qu'il n'y ait plus de changement dans l'assignement des points (ou des centroïdes).

### Exemple :



## Méthodes de clustering – K-moyennes



# Plan du chapitre

1. Définitions
2. Segmentation par seuillage
3. Méthodes basées région
  - 3.1 Croissance de région
  - 3.2 Segmentation par décomposition et regroupement
4. Autres méthodes
5. Critères d'évaluation de la segmentation

## Limitation des méthodes de seuillage

**Limite fondamentale des méthodes de seuillage :** pas de prise en compte l'information de voisinage, uniquement l'information de distribution des intensités (histogramme).

## Limitation des méthodes de seuillage

**Limite fondamentale des méthodes de seuillage :** pas de prise en compte l'information de voisinage, uniquement l'information de distribution des intensités (histogramme).

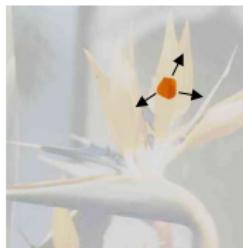
**Avantage des méthodes basées région :** agréger des pixels spatialement proches et ayant des intensités similaires.

## Croissance de région

**Principe des méthodes de croissance de région :** On part d'un point germe et on l'étend en ajoutant les pixels du voisinage satisfaisant le critère d'homogénéité.



*Point germe*



*croissance*



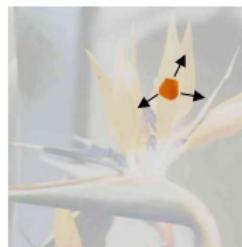
*région finale*

## Croissance de région

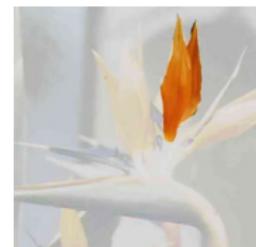
**Principe des méthodes de croissance de région :** On part d'un point germe et on l'étend en ajoutant les pixels du voisinage satisfaisant le critère d'homogénéité.



*Point germe*



*croissance*



*région finale*

### Choix du point germe :

- Manuellement (dans la zone d'intérêt)
- Automatiquement : en évitant les zones de fort contraste (fort gradient)

## Croissance de région

**Critère de similarité :** Si un pixel et une région, ou deux régions  $A$  et  $B$ , sont considérés comme suffisamment similaires, ils sont fusionnés, sinon une nouvelle région est créée.

**Exemple de critère pour l'ajout d'un pixel  $(i,j)$  dans la région  $A$  :**

$$|I(i,j) - \mu_A| < T\sigma_A$$

**Choix du seuil  $T$  :**

- Valeur de seuil élevé : facile pour de nouveaux pixels d'être acceptés dans la région.
- Valeur de seuil faible : difficile pour de nouveaux pixels d'être acceptés dans la région.

**Choix de la connexité :** 4-voisinage ou 8-voisinage.

## Croissance de région : mode d'emploi

Définition d'une zone R qui contient la région à extraire et une file FIFO (First In, First Out) S qui contient les points frontière de R.

### Initialisation :

- R contient le point germe.
- S contient le voisinage du point germe.

**Méthode :** On retire  $p$  de S

- Si  $p$  est homogène avec R :
  - on ajoute  $p$  à R,
  - on ajoute à S les points du voisinage de  $p$  qui ne sont pas dans R et qui ne sont pas incompatibles.
- sinon :
  - On marque  $p$  comme incompatible.

On recommence tant que S n'est pas vide.

Rq : en cas d'utilisation de statistique globale pour le test d'homogénéité, l'ordre de traitement des pixels peut influencer le résultat final.

## Croissance de région : exemple

Segmentation des éclairs :



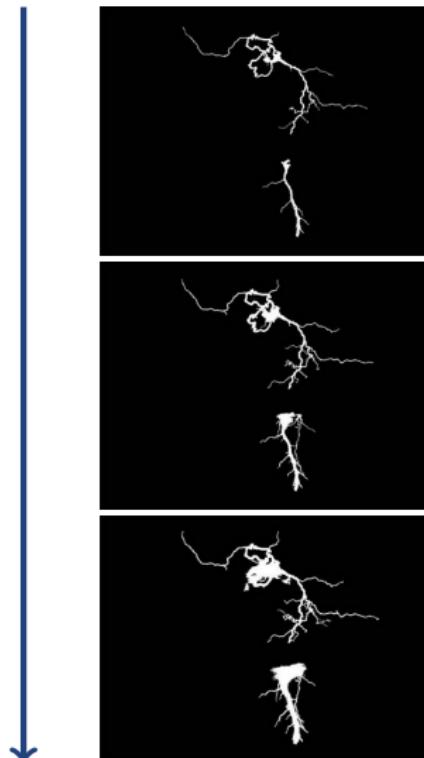
Au moins deux points germes sont nécessaires.

# Croissance de région : exemple

Influence du seuil :

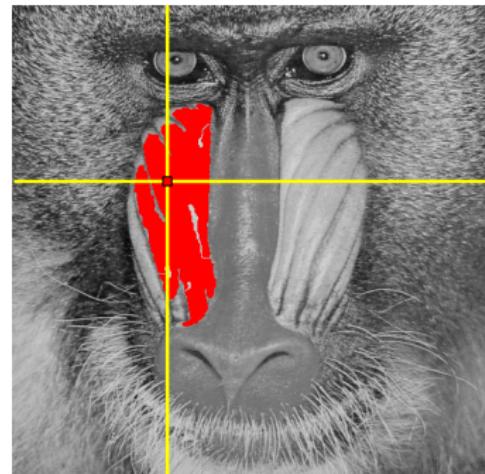
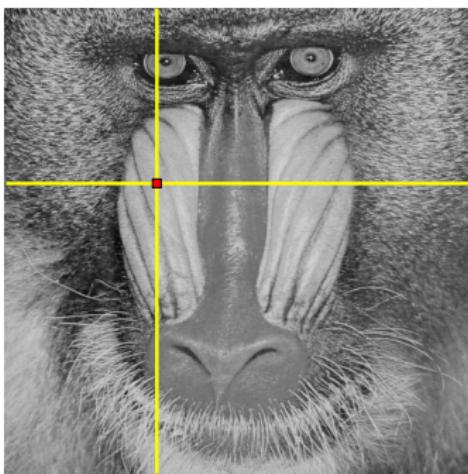


T ↘



## Croissance de région : exemple

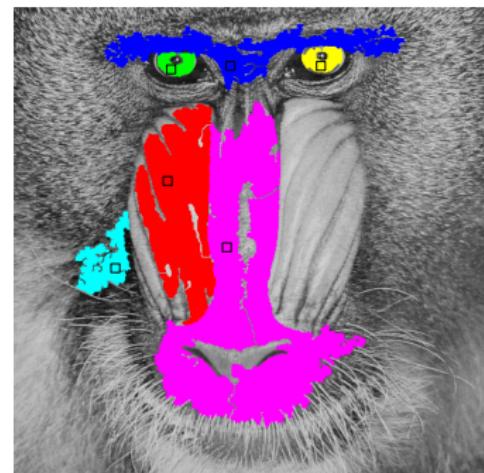
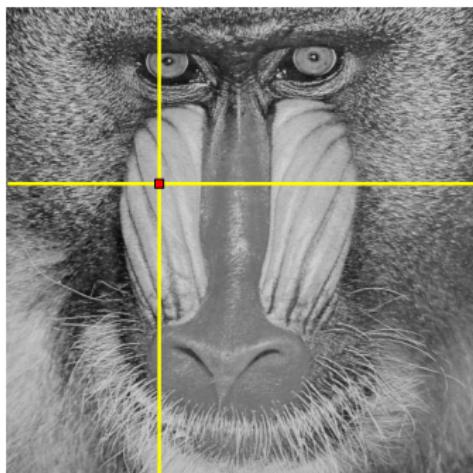
Influence du seuil :



La croissance de région ne fournit pas une partition de l'image, mais permet de segmenter une ou plusieurs structures d'intérêt via la sélection de points germes adaptés.

## Croissance de région : exemple

Influence du seuil :



La croissance de région ne fournit pas une partition de l'image, mais permet de segmenter une ou plusieurs structures d'intérêt via la sélection de points germes adaptés.

## Méthode split and merge

**Principe d'une méthode de décomposition/fusion :**

- Partition initiale par divisions successives de chaque région non-uniforme de l'image.
- Fusions successives des régions adjacentes satisfaisant un critère d'homogénéité.

## Méthode split and merge

**Principe d'une méthode de décomposition/fusion :**

- Partition initiale par divisions successives de chaque région non-uniforme de l'image.
- Fusions successives des régions adjacentes satisfaisant un critère d'homogénéité.

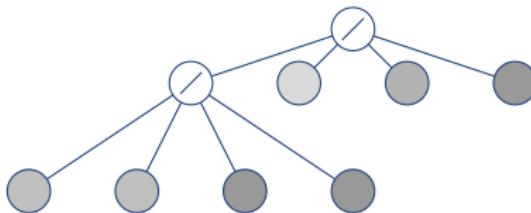
**Nécessité d'une représentation hiérarchique de l'image !**

- Construction de la représentation hiérarchique lors de l'étape de division (pendant ou après).
- Utilisation lors de l'étape de fusion.

## Représentation par arbre

Les représentations en arbre sont utilisées pour créer une représentation de haut niveau de l'image.

Les arbres définissent un ensemble de régions structurées hiérarchiquement.



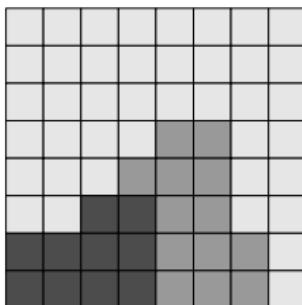
## Représentation par arbre : le quad-tree

Le **quad-tree** est une arborescence dont la racine est l'image entière et donc chaque noeud possède également quatre fils :

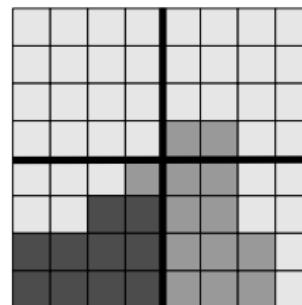
- l'image est partagée en quatre quadrants récursivement,
- un quadrant  $q$  est partagé en quatre s'il n'est pas décrété homogène :  $\sigma_q^2 > T$ .

# Décomposition par représentation quad-tree

Exemple :

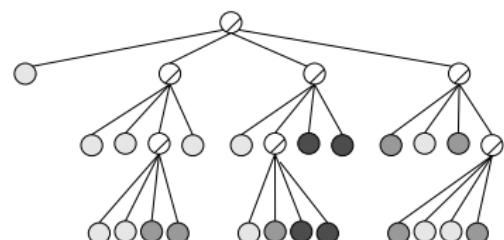
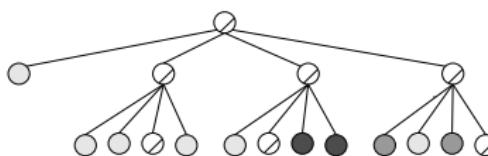
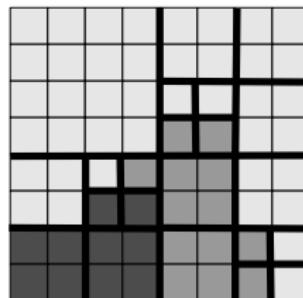
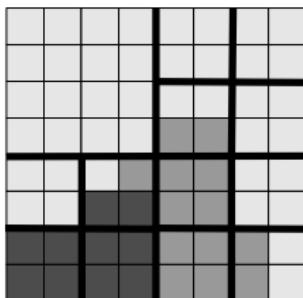


∅



# Décomposition par représentation quad-tree

Exemple :



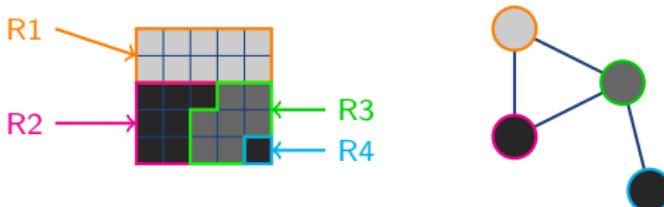
## Décomposition par représentation quad-tree

La méthode de décomposition par quad-tree fait apparaître des régions carrées sur l'image segmentée.

Le problème majeur de cette structure provient de la rigidité des divisions réalisées sur l'image, mais cela fournit une partition initiale de l'image.

## Représentation par graphe d'adjacence

Le **graphe d'adjacence** est une arborescence dont les noeuds sont les régions et les arcs définissent une relation d'adjacence (proximité spatiale).

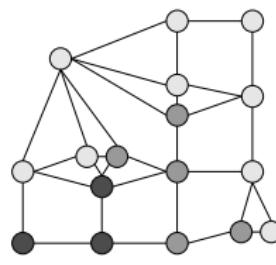
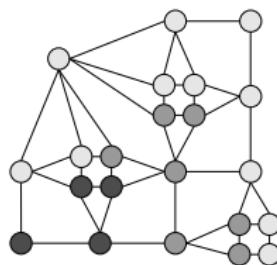
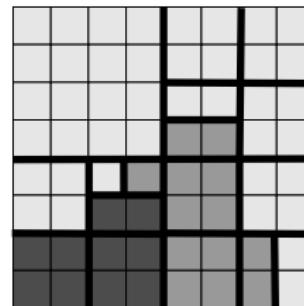
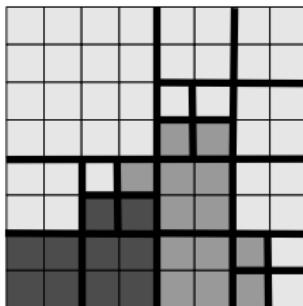


Utilisation pour l'étape de fusion :

- Initialisation : partition de l'image (par exemple avec le quad-tree) et graphe d'adjacence associé.
- Modification de la partition initiale en fusionnant les régions adjacentes : pour chaque sommet  $R$ , on cherche s'il existe un sommet  $R'$  voisin dans le graphe, de valeur suffisamment proche pour être fusionné avec  $R$  (par exemple si  $|\mu_R - \mu_{R'}| < \text{seuil}$ ).

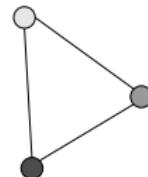
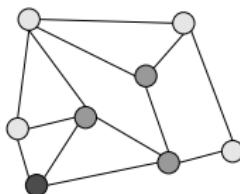
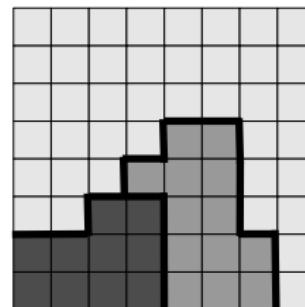
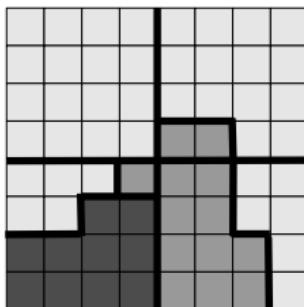
## Représentation par graphe d'adjacence

Exemple :



## Représentation par graphe d'adjacence

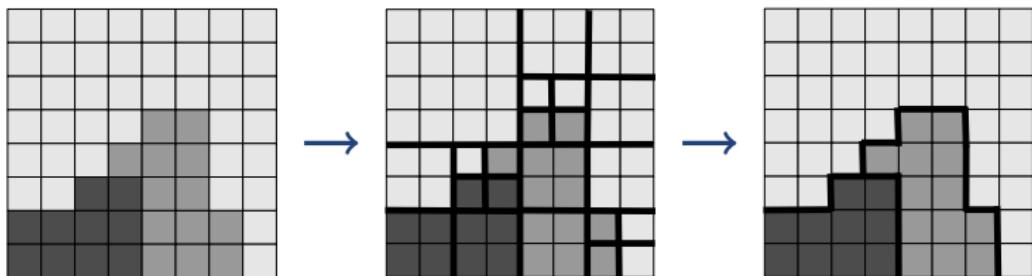
Exemple :



## Fusion des régions

Résumé de la segmentation par décomposition/fusion :

- Partition initiale par méthode des quad-tree par exemple.
- Représentation de l'image segmentée par un graphe d'adjacence.
- Fusion des zones segmentées adjacentes en fonction d'un critère d'homogénéité.



# Plan du chapitre

1. Définitions

2. Segmentation par seuillage

3. Méthodes basées région

## 4. Autres méthodes

- 4.1 Quelques méthodes de l'état de l'art
- 4.2 Ligne de partage des eaux
- 4.3 Segmentation par contour déformable

5. Critères d'évaluation de la segmentation

## Méthodes basées contour

- Segmentation par ligne de partage des eaux.
- Segmentation par contour déformable.
- Les méthodes de détection de contours peuvent être utilisées → détection de caractéristiques.

## Segmentation par ligne de partage des eaux

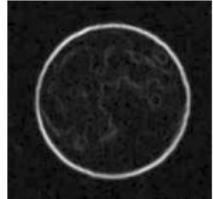
L'idée est de transformer l'image à segmenter par une carte d'élévation (terrain en 3D) où les frontières entre deux régions à segmenter seraient les crêtes et les régions, les bassins.

→ On utilise en général la norme du gradient de l'image pour la carte d'élévation.

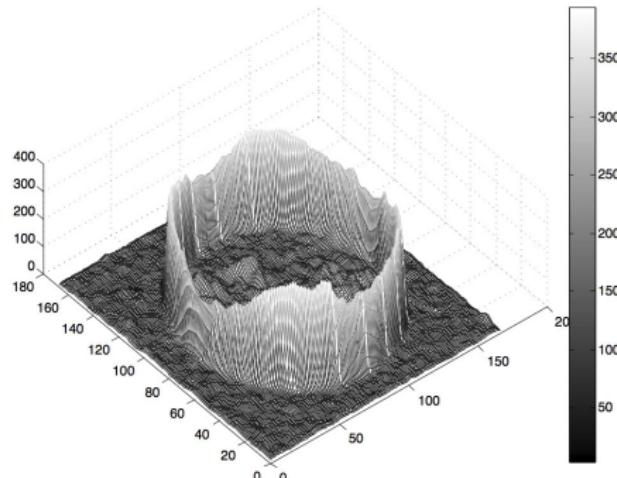
Représentation 3D du gradient



Image originale



Gradient de l'image



## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :

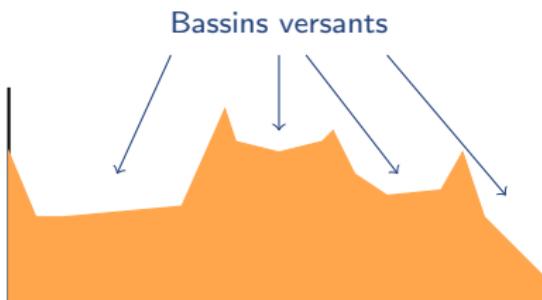


## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :



## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :



## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :



## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :

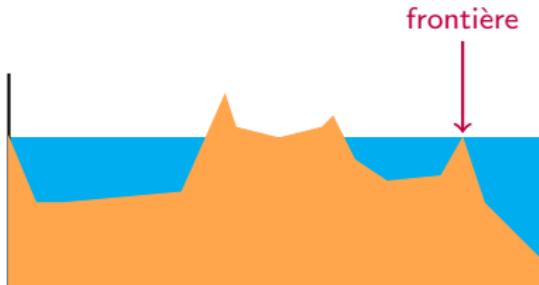


## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :

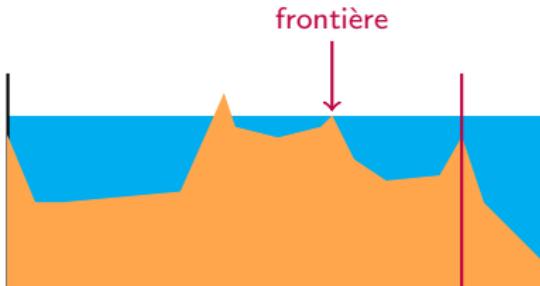


## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :

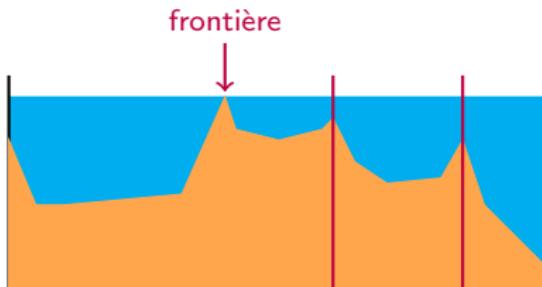


## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :



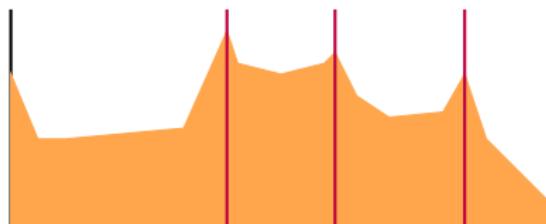
## Segmentation par ligne de partage des eaux

### Principe de la méthode :

- Construire la carte d'élévation.
- Remplir progressivement d'eau chaque *bassin versant*.
- Lorsque l'eau monte et que deux bassins se rejoignent, la ligne de partage des eaux est marquée comme frontière.

### Illustration sur un signal 1D :

Segmentation finale



## Segmentation par ligne de partage des eaux

### Implémentation :

- Calculer le gradient (ou le Laplacien) de l'image.
- Commencer avec tous les pixels ayant la valeur la faible possible : ceux-ci forment l'ensemble des bassins versants initiaux.
- Pour chaque niveau d'intensité  $r$  :
  - Pour chaque groupe de pixels d'intensité  $r$  :
    - Si adjacent à exactement une région existante, ajouter ces pixels dans cette région.
    - Sinon, si adjacent à plusieurs régions simultanément, marquer comme ligne de partage des eaux.
    - Sinon, commencer une nouvelle région.

## Segmentation par ligne de partage des eaux

### Implémentation :

- Calculer le gradient (ou le Laplacien) de l'image.
- Commencer avec tous les pixels ayant la valeur la faible possible : ceux-ci forment l'ensemble des bassins versants initiaux.
- Pour chaque niveau d'intensité  $r$  :
  - Pour chaque groupe de pixels d'intensité  $r$  :
    - Si adjacents à exactement une région existante, ajouter ces pixels dans cette région.
    - Sinon, si adjacents à plusieurs régions simultanément, marquer comme ligne de partage des eaux.
    - Sinon, commencer une nouvelle région.

**Limitation :** s'il y a beaucoup de minima locaux dans le gradient, cela donne une sur-segmentation → lissage du gradient avant d'appliquer l'algorithme.

- Possibilité de choisir manuellement les bassins versants d'intérêt avec des marqueurs.

# Segmentation par contour déformable

**Autres terminologies :** Snake, contour actif, etc.

**Principe des contours déformables :**

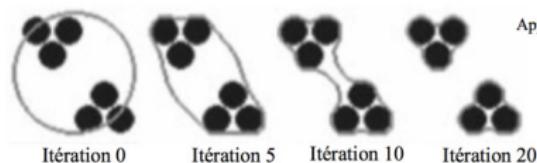
- On se donne un contour initial (modèle) près de l'objet à segmenter.
- Le but est de faire évoluer le contour pour qu'il adhère au bord de l'objet.
- La modification du contour se fait de manière itérative de façon à ce qu'il converge vers les zones de fort gradient (=contour) sous certaines contraintes (forme, longueur, etc).

**Outils utilisés :**

- Contour = chemin fermé = représentation discrète.
- Définition de fonctions d'énergies interne et externe.
- Minimisation de la fonction d'énergie.

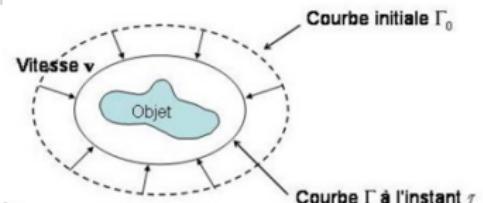
# Segmentation Contour

Contour actif



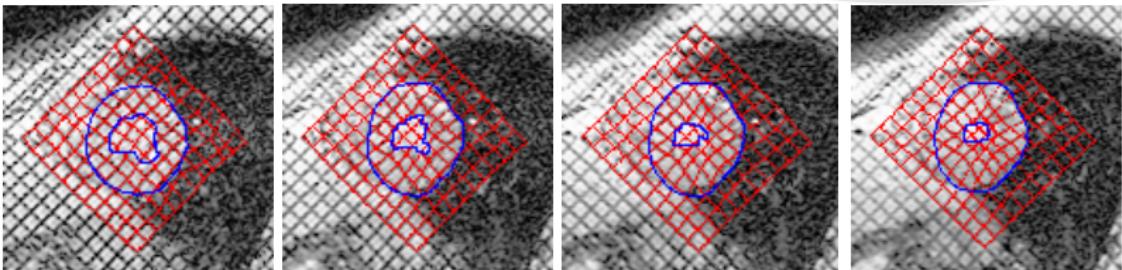
Approche « region-based »

[Chan-Vese 97]



# Segmentation Contour Snake

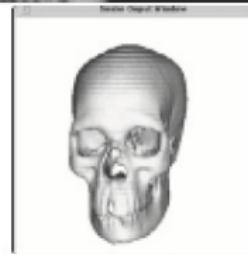
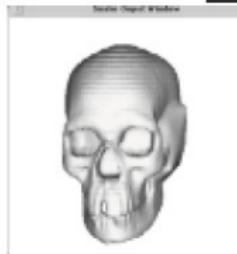
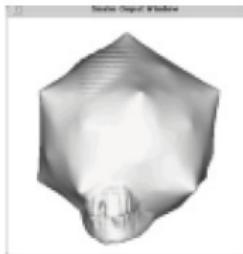
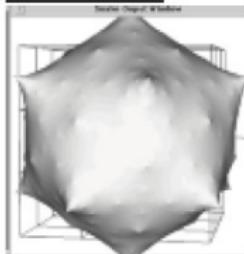
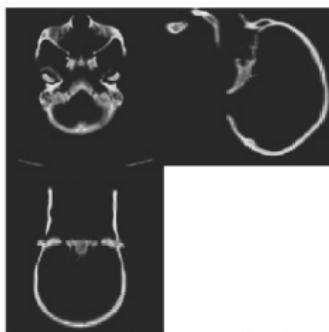
- Snake (Kass 1988)
  - ↳ Exemple des IRM cardiaques marquées



# Segmentation Contour

*Snake*

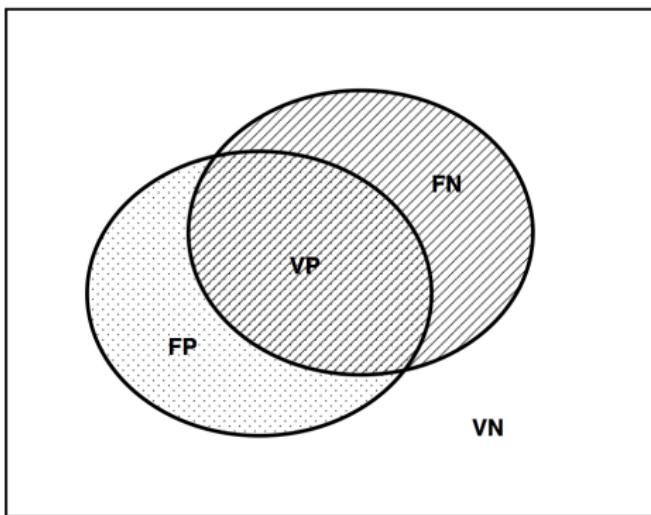
- Snake 3D



## Plan du chapitre

1. Définitions
2. Segmentation par seuillage
3. Méthodes basées région
4. Autres méthodes
5. Critères d'évaluation de la segmentation

## Critères d'évaluation de la segmentation



$$\text{sensibilité} = \frac{VP}{VP + FN}$$

$$\text{spécificité} = \frac{VN}{VN + FP}$$

$$\text{Jaccard} = \frac{VP}{VP + FP + FN}$$

$$\text{Dice} = \frac{2 VP}{2 VP + FP + FN}$$

VP : Vrai Positif

FP : Faux Positif

Vérité terrain (VT)

VN : Vrai Négatif

FP : Faux Négatif

Segmentation (Seg)