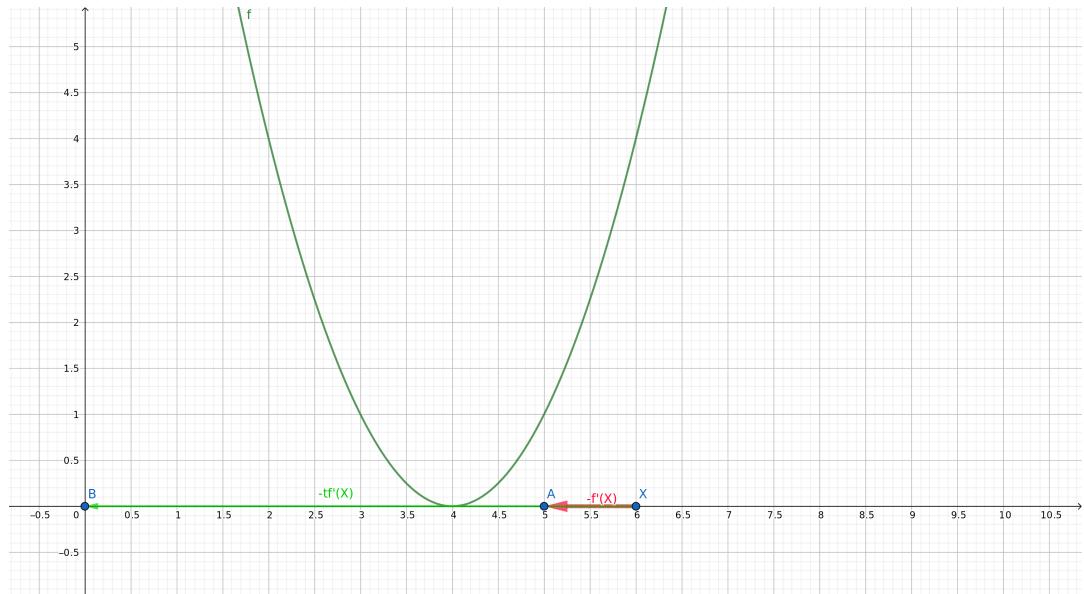


# Optimisation convexe 2

Graphe de  $f : \mathbb{R} \rightarrow \mathbb{R}$



## Calculer le pas

### Calcul du pas optimal

trouver  $t^*$  par la minimisation de  $f(x + t\Delta x)$

la tangente au graphe de  $t \xrightarrow{\psi} f(x + t\Delta x)$  en 0 est donnée par

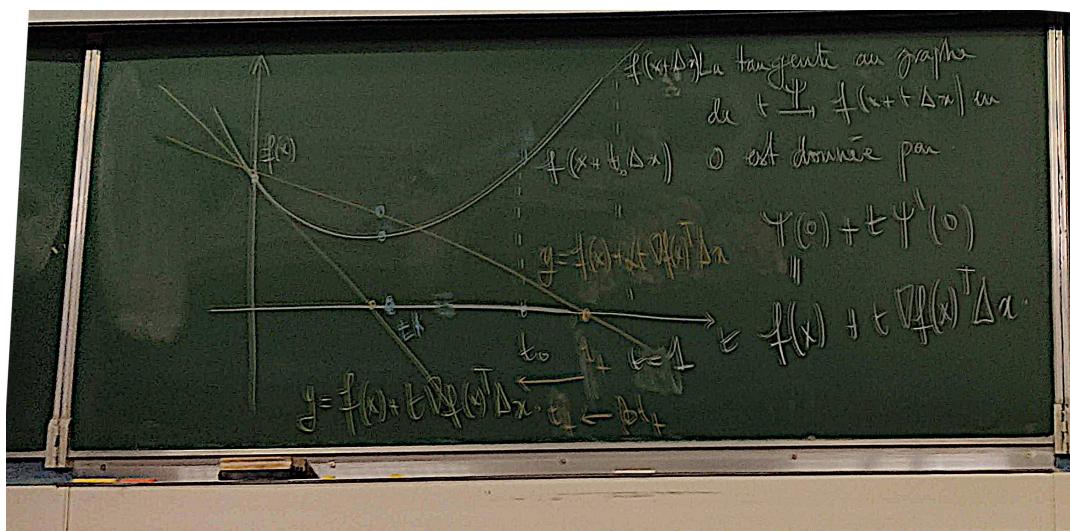
$$\psi(0) + t\psi'(0) = f(x) + t$$

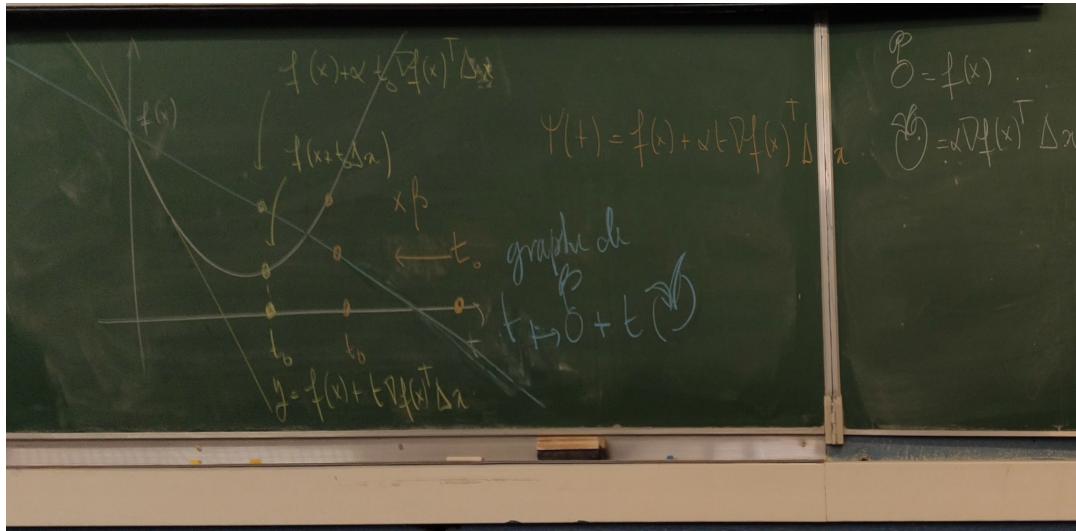
$$= f(x) + t\nabla f(x)^T \Delta x$$

On s'arrête dès qu'on trouve:

$t^*$  tq

$$f(x + t^* \Delta x) \leq f(x) + \alpha t^* \nabla f(x)^T \Delta x$$





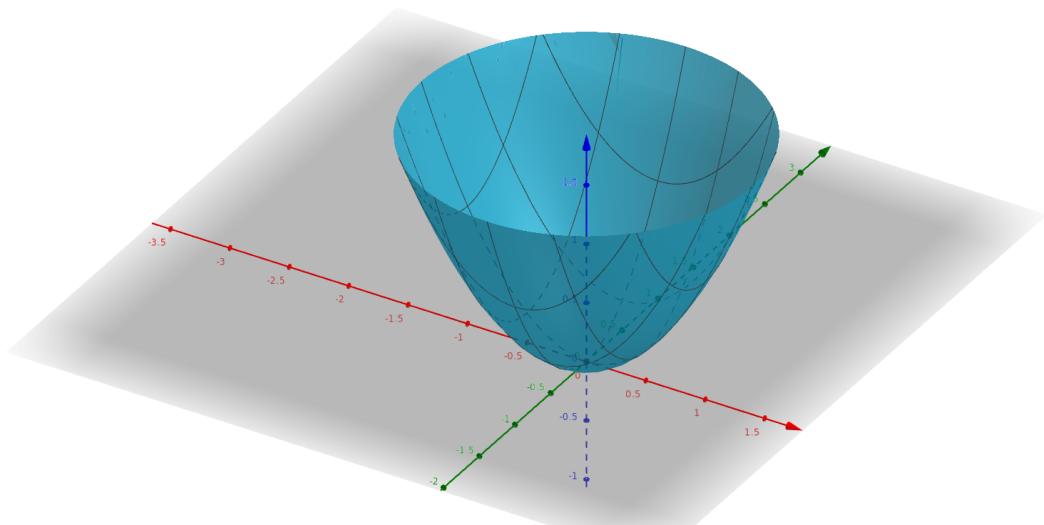
La hessienne d'une fonction  $f$  en un point definit une fonction quadratique.

$$X \mapsto X^T \underbrace{\nabla^2 f(a)}_{\text{matrice carre (hessienne de } f \text{ en a)}} X$$

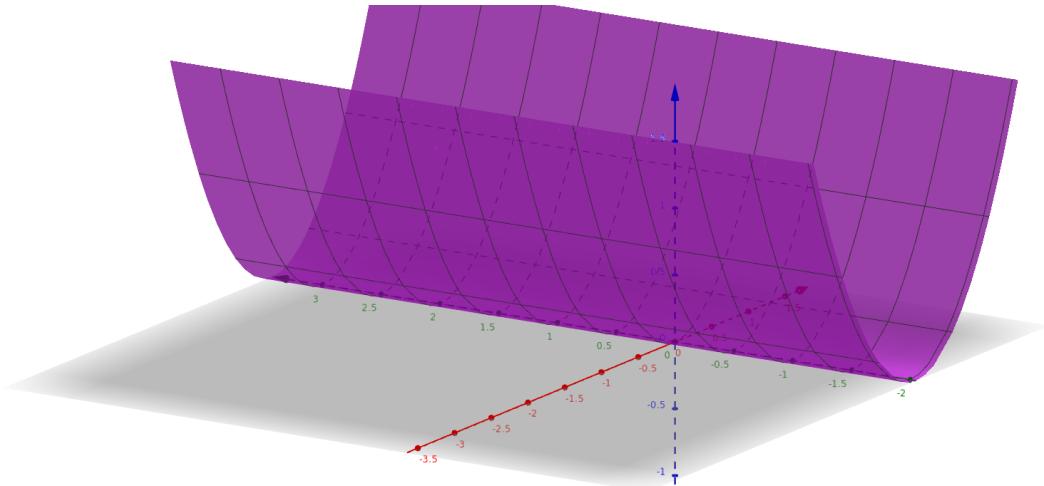
Dire que  $a \mapsto \nabla^2 f(a)$  est majorée sur un lieu  $S$  de son domaine de définition est équivalent au fait de dire que les valeurs propres (fonctions en  $a$ ) de la hessienne sont des fonctions majorées.

2.  $\forall a \in S$  on a que les valeurs propres de la hessienne de  $f$  sont minorées par une même constante  $m > 0$ .

### Strictement convexe:



### Non Strictement convexe:



## Generaliser la descente classique

$$f(x + v) = f(x) + \nabla f(x)^T v + o(v)$$

- On remplace  $f(x + v)$  par son approximation au 1er ordre; cad  $f(x) + \nabla f(x)^T v$
- On cherche la direction (cad les vecteurs de norme 1 ( $\|\cdot\|_2$ )) tq  $f(x) + \nabla f(x)^T v$  est minimal. On cherche donc a calculer  $v^* = \operatorname{argmin}\{\nabla f(x)^T v | \|v\|_2 = 1\}$

Rq: Si  $v^*$  minimise  $\nabla f(x)^T v$  ssi  $-v^*$  maximise  $\nabla f(x)^T v$  pour  $\|v\|_2 = 1$

Rappel: Cauchy Schwarz :  $|\nabla f(x)^T v| \leq \|\nabla f(x)\|_2 \|v\|_2$

$$|\nabla f(x)^T v| \leq \|\nabla f(x)\|_2$$

En prenant  $v = \frac{\nabla f(x)}{\|\nabla f(x)\|_2}$  (hyp denominateur != 0)

$$\nabla f(x)^T v^* = (\nabla f(x)^T \nabla f(x)) x \frac{1}{\|\nabla f(x)\|_2} = \frac{\|\nabla f(x)\|_2^2}{\|\nabla f(x)\|_2} = \|\nabla f(x)\|_2$$

Donc pour que  $v^*$  maximise  $\nabla f(x)^T v^*$  pour  $\|v\|_2 = 1$

Ainsi  $\frac{-\nabla f(x)}{\|\nabla f(x)\|_2}$  minimise  $\nabla f(x)^T v$  pour  $\|v\|_2 = 1$

Au lieu d'utiliser une direction normalisee, pour la mise a jour, on regarde plutot

$$\Delta_{x_{sd}} = \|\nabla f(x)\|_2$$

nsd => normalized steepest descent

Pour la norme 1 on s'interesse au calcul de:

$$\operatorname{argmin}\{\nabla f(x)^T v \mid \|v\|_1 = 1\}$$

$$\operatorname{argmin}\{\nabla f(x)^T v \mid \|v\|_1 \leq 1\}$$

Ceci est un programme lineaire, ces points optimaux sont des points extremaux du lieu

admissible

Ces points extremaux sont les points:

$\mathcal{F}_{e_i}$  pour  $i \in \{1, \dots, n\}$

$$\operatorname{argmin}\{\nabla f(x)^T v \mid \|v\|_1 \leq 1\} = Ie_i \text{ pour un certain } i \in \{1, \dots, n\}$$

$\nabla f(x)^T e_i$  est la projection de  $\nabla f(x)$  sur  $e_i$  cad  $\frac{\partial f(x)}{\partial x_i}$  Le  $e_i$  qui realise l'argmin.

$\Delta x_{sd}$  = la projection de  $\nabla f(x)$  le long de  $\Delta x_{nsd}$

$$\Rightarrow \Delta x_{sd} = -\frac{\partial f(x)}{\partial x_i} e_i$$

$$\Delta x_N = -(\nabla^2 f(x))^{-1}(\nabla f(x))$$

$$f(x) + \nabla f(x)^T v + \frac{1}{2} v^T \nabla^2 f(x) v = \Psi(v)$$

$\Psi$  est minimum ssi  $\nabla \Psi(v) = 0$

$$\nabla \Psi(v) = \nabla f(x) + \nabla^2 f(x)v \Rightarrow \nabla \Psi(v) = 0 \Leftrightarrow \nabla^2 f(x)v = -\nabla f(x)$$