

Precedent ici (https://hackmd.io/fRTgWAKsS_qS9kEqcYpnw)

Traitement du signal avance 2

13/01

On observe x_1, \dots, x_n

x_i réalisations particulières de X_1, \dots, X_n

$X_i \stackrel{iid}{\sim} f_X(x, \theta)$

iid = indépendant et identiquement distribué

On construit $\hat{\Theta} = g(X_1, \dots, X_n)$ de manière à ce que $\hat{\theta} = g(x_1, \dots, x_n)$ soit le plus proche possible de θ

Exemple

$$f_x(x, \theta) = \frac{1}{\sigma\sqrt{2\pi}} e^{(\frac{x-\mu}{\sigma})^2}$$

On a observé (x_1, \dots, x_n) réalisations particulières de (X_1, \dots, X_n)

$$\mathcal{L}(x_1, \dots, x_n, \theta) = \prod_{i=1}^n f_X(x_i, \theta)$$

Fonction de vraisemblance :

$$\theta \rightarrow \mathcal{L}(x_1, \dots, x_n, \theta)$$

C'est la proba d'observer x_1, \dots, x_n étant donnée la valeur de θ

x_1, \dots, x_n ce qu'on a effectivement observé.

On cherche donc la valeur de θ qui maximise la proba d'observation de $x, \dots, x_n \rightarrow$ estimateur du maximum de vraisemblance.

Ex: On observe (x_1, \dots, x_n) avec $X_i \stackrel{iid}{\sim} \mathcal{R}(\alpha)$

On écrit donc la vraisemblance :

$$\begin{aligned} \mathcal{L}(x_1, \dots, x_n, \alpha) &= \prod_{i=1}^n f_X(x_i, \alpha) \\ &= \prod_{i=1}^n \left(\frac{x_i}{\alpha^2} e^{-\frac{x_i^2}{2\alpha^2}} \right) \\ &= \frac{\prod x_i}{\alpha^{2n}} e^{-\frac{1}{2\alpha^2} \sum_{i=1}^n x_i^2} \end{aligned}$$

On maximise $\ln(\mathcal{L}(x_1, \dots, x_n))$ à la place :

$$\ln \mathcal{L}(x_1, \dots, x_n, \alpha) = -2n \ln \alpha + \sum_{i=1}^n \ln(x_i) - \frac{1}{2\alpha^2} \sum_{i=1}^n x_i^2$$

On cherche α tq

$$\frac{\partial \ln \mathcal{L}}{\partial \alpha} |_{\hat{\alpha}} = 0$$

et

$$\frac{\partial^2 \ln \mathcal{L}}{\partial \alpha^2} |_{\hat{\alpha}} = 0$$

Performance d'un estimateur

\rightarrow biais $E[\hat{\Theta}] - \theta = b(\hat{\Theta})$

\rightarrow variance $\text{var}(\hat{\Theta})$ doit être petite

$$E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X] = \mu$$

$$X_i \sim f_X \text{ tq } E[X] = \mu$$

$$X_i \stackrel{iid}{\sim} \mathcal{R}(x, \alpha) = \frac{x}{\alpha^2} e^{-\frac{x^2}{2\alpha^2}}$$

$$\hat{\alpha}_{EMV} = \left(\frac{1}{2n} \sum_{i=1}^n X_i^2\right)^{\frac{1}{2}}$$

Soit (X_1, \dots, X_n) avec $X_i \stackrel{iid}{\sim} f_X(x, \theta)$

On appelle quantité d'information / information de Fisher de l'échantillon aléatoire X_1, \dots, X_n pour θ la quantité.

$$I_n(\theta) = \underbrace{\text{var}\left(\frac{\partial \ln \mathcal{L}(X_1, \dots, X_n, \theta)}{\partial \theta}\right)}_{\text{fonction score}}$$

$$\text{Prop } I_n(\theta) = -E\left[\frac{\partial^2 \ln \mathcal{L}(X_1, \dots, X_n, \theta)}{\partial \theta^2}\right]$$

Borne inférieure de Cramér-Rao

Quelque soit l'estimateur $\hat{\Theta}$ utilisé pour estimer θ

$$\text{var}(\hat{\Theta}) \geq \frac{\left(1 + \frac{\partial b(\hat{\Theta})}{\partial \theta}\right)^2}{I_n(\theta)}$$

En particulier: si $\hat{\Theta}$ non biaisé

$$\text{var}(\hat{\Theta}) \geq \frac{1}{I_n(\theta)}$$

En particulier, si

- $\hat{\Theta}$ est non biaisé. $b(\hat{\Theta}) = 0$

- $\text{var}(\hat{\Theta}) = \frac{1}{I_n(\theta)}$

alors on dit que l'estimateur est efficace.

Exemple :

$$\begin{aligned}
 \ln \mathcal{L}(X_1, \dots, X_n, \alpha) &= -2n \ln(\alpha) + \sum_{i=1}^n \ln(X_i) - \frac{1}{2\alpha^2} \sum_{i=1}^n X_i^2 \\
 \frac{\partial \ln \mathcal{L}}{\partial \alpha} &= -\frac{2n}{\alpha} + \frac{1}{\alpha^3} \sum_{i=1}^n X_i^2 \\
 I_n(\alpha) &= \text{var}\left(-\frac{2n}{\alpha} + \frac{1}{\alpha^3} \sum_{i=1}^n X_i^2\right) \\
 \frac{\partial^2 \ln \mathcal{L}}{\partial \alpha^2} &= \frac{2n}{\alpha^2} - \frac{3}{\alpha^4} \sum_{i=3}^n X_i^2 \\
 I_n(\alpha) &= -E\left[\frac{2n}{\alpha^2} - \frac{3}{\alpha^4} \sum_{i=1}^n X_i^2\right] \\
 &= \frac{3}{\alpha^4} \sum_{i=1}^n E[X_i^2] - \frac{2n}{\alpha^2}
 \end{aligned}$$

$$\begin{aligned}
 E[X_i] &= \alpha \sqrt{\frac{\pi}{2}} \\
 \text{var}(X_i) &= \left(\frac{4-\pi}{2}\right) \alpha^2
 \end{aligned}$$

Th de Koenig

$$\text{var}(X_i) = E[X_i^2] - (E[X_i])^2$$

$$\begin{aligned}
 E[X_i^2] &= \text{var}(X_i) + (E[X_i])^2 \\
 &= \left(\frac{4-\pi}{2}\right) \alpha^2 + \frac{\pi}{2} \alpha^2 \\
 &= 2\alpha^2
 \end{aligned}$$

Tests d'hypothèses

On repart de l'exemple du signal bruité x .

Objectif :

Est ce que $x = 0$ ou $x = 1$?

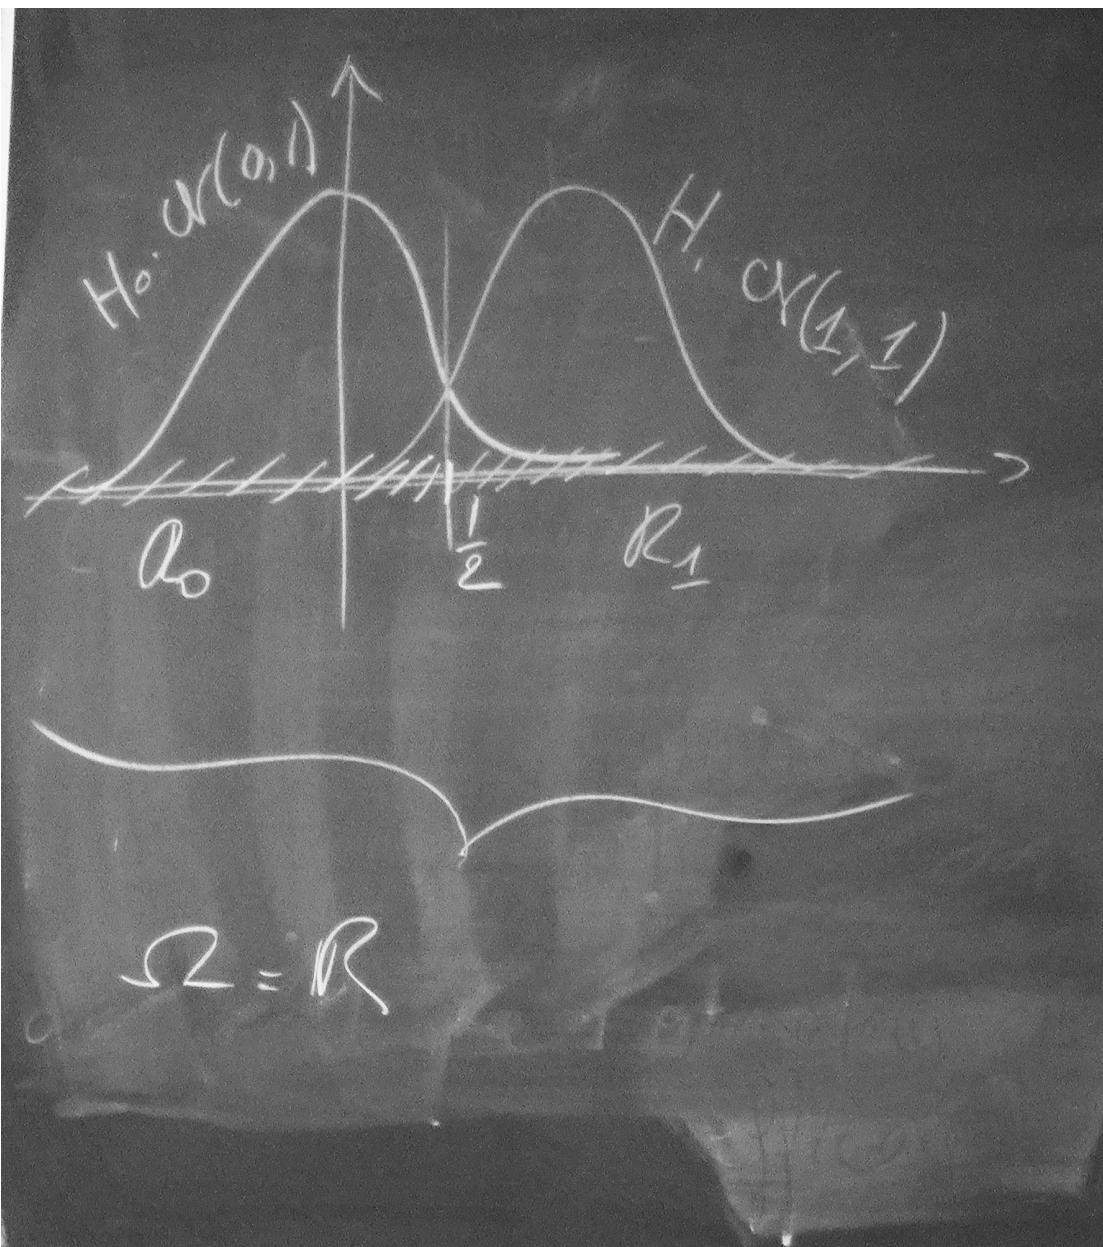
On modélise chaque hypothèse par une loi de probabilité (H_0 loi sous jacente $p_0(x)$ et H_1 loi sous jacante $p_1(x)$) et on cherche à déterminer lequel de ces deux modèles est le plus probable :

- $H_0 : x$ tiré de $X \sim p_0(x)$
- $H_1 : x$ tiré de $X \sim p_1(x)$

On se place dans le cas d'un test dit "simple" → les paramètres de p_0 et p_1 sont connus.

On va supposer que le **domaine de définition** de la variable aléatoire X est le même sous H_0 et H_1 $\Omega = \mathbb{R}_0 \cup \mathbb{R}_1$ tel que :

$x \in \mathbb{R}_0 \rightarrow$ décide de \mathbb{H}_0
 $x \in \overline{\mathbb{R}_0} \rightarrow$ décide de \mathbb{H}_1



Il y a 4 cas de figure :

- On décide H_0 , H_0 vraie (0,0)
- On décide H_0 , H_1 vraie (0,1)
- On décide H_1 , H_1 vraie (1,1)
- On décide H_1 , H_0 vraie (1,0)

On va affecter des poids $c_{i,j}$ avec $i, j \in \{0, 1\}$ aux différents cas de figure :

$$c_{i,j} \geq 0 \quad \text{et} \quad c_{01}, c_{10} \geq c_{00}, c_{11}$$

On va appeler coût de Bayes pour les régions \mathbb{R}_0 et \mathbb{R}_1 :

$$C = \sum_{i,j=0}^1 c_{ij} \Pi_j \mathbb{P}(\text{décider } H_i | H_j \text{ vraie})$$

avec $\Pi_j = \mathbb{P}(H_j \text{ vraie})$ = proba à priori de H_j

On cherche à designer \mathbb{R}_0 (et donc $\mathbb{R}_1 = \overline{\mathbb{R}_0}$) de manière à minimiser le coût de Bayes.

$$\begin{aligned} C &= \sum_{i,j=0}^1 c_{ij} \Pi_j \mathbb{P}(x \in \mathbb{R}_i | H_j \text{ vraie}) \\ C &= c_{00} \Pi_0 \mathbb{P}(x \in \mathbb{R}_0 | H_0 \text{ vraie}) + c_{01} \Pi_1 \mathbb{P}(x \in \mathbb{R}_0 | H_1 \text{ vraie}) + c_{10} \Pi_0 \mathbb{P}(x \in \mathbb{R}_1 | H_0 \text{ vraie}) \\ &\quad + c_{11} \Pi_1 \mathbb{P}(x \in \mathbb{R}_1 | H_1 \text{ vraie}) \\ C &= c_{00} \Pi_0 \int_{\mathbb{R}_0} p_0(x) dx + c_{01} \Pi_1 \int_{\mathbb{R}_0} p_1(x) dx + c_{10} \Pi_0 \int_{\mathbb{R}_1} p_0(x) dx + c_{11} \Pi_1 \int_{\mathbb{R}_1} p_1(x) dx \\ C &= \int_{\mathbb{R}_0} (c_{00} \Pi_0 p_0(x) + c_{01} \Pi_1 p_1(x)) dx + \int_{\mathbb{R}_1 = \overline{\mathbb{R}_0}} (c_{11} \Pi_1 p_1(x) + c_{10} \Pi_0 p_0(x)) dx \end{aligned}$$

Pour minimiser C , il faut que R_0 soit tel que :

$$R_0 = \{x \in \Omega | c_{00} \Pi_0 p_0(x) + c_{01} \Pi_1 p_1(x) < c_{11} \Pi_1 p_1(x) + c_{10} \Pi_0 p_0(x)\}$$

$$R_0 = \{x | (c_{01} \Pi_1 - c_{11} \Pi_1) p_1(x) < (c_{10} \Pi_0 - c_{00} \Pi_0) p_0(x)\}$$

$$R_0 = \{x | \frac{p_1(x)}{p_0(x)} < \frac{\Pi_0(c_{10} - c_{00})}{\Pi_1(c_{01} - c_{11})}\} \text{ et } R_1 = \bar{R}_0 = \{x | \frac{p_1(x)}{p_0(x)} > \frac{\Pi_0(c_{10} - c_{00})}{\Pi_1(c_{01} - c_{11})}\}$$

Donc à la fin on a :

Test du rapport de vraisemblance / Likelihood ratio test

$$\frac{p_1(x)}{p_0(x)} \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{\Pi_0(c_{10} - c_{00})}{\Pi_1(c_{01} - c_{11})}$$

$$\frac{p_1(x)}{p_0(x)} \stackrel{H_1}{\underset{H_0}{\gtrless}} \gamma$$

Exemple :

$$\begin{cases} H_0 : \mathcal{N}(0, 1) \\ H_1 : \mathcal{N}(1, 1) \end{cases}$$

Avec :

- $\Pi_0 = \Pi_1 = \frac{1}{2}$
- $c_{00} = c_{11} = 0$
- $c_{10} = c_{01} = 1$

Test du rapport de vraisemblance :

$$\frac{p_1(x)}{p_0(x)} \stackrel{H_1}{\underset{H_0}{\gtrless}} 1$$

$$\frac{\frac{1}{\sqrt{2\pi}} \exp(-(x-1)^2)}{\frac{1}{\sqrt{2\pi}} \exp(-x^2)} \stackrel{H_1}{\underset{H_0}{\gtrless}} 1$$

$$\exp(-(x-1)^2 + x^2) \stackrel{H_1}{\underset{H_0}{\gtrless}} 1$$

$$-(x-1)^2 + x^2 \stackrel{H_1}{\underset{H_0}{\gtrless}} 0$$

$$2x \stackrel{H_1}{\underset{H_0}{\gtrless}} 1$$

$$x \stackrel{H_1}{\underset{H_0}{\gtrless}} \frac{1}{2}$$

En théorie, on a besoin de connaître Π_0, Π_1, c_{01} et c_{10} .

En pratique, on va s'autoriser un certain pourcentage d'erreurs, et on va chercher le test qui va maximiser le pourcentage de bonnes décisions.

- H_0 correspond à un comportement standard : hypothèse nulle.
- H_1 correspond à un comportement déviant : hypothèse alternative.

$\mathbb{P}(\text{decider } H_1 | H_0 \text{ est vrai})$ = probabilité de fausse alarme

$\mathbb{P}(\text{decider } H_1 | H_1 \text{ est vrai})$ = probabilité de détection

$\mathbb{P}(\text{decider } H_0 | H_1 \text{ est vrai})$ = probabilité de non détection

Étant donné un test T (fonction des observations)

$\mathbb{P}(T \text{ rejette } H_0 | H_1 \text{ vraie})$ s'appelle la puissance du test T .

On va se donner une certaine proba de fausse alarme $P_{FA} = \alpha$

On va chercher le test qui maximise la proba de détection P_D sous contrainte que $P_{FA} \leq \alpha$

Cours du 21 janvier

On prend un test quelconque $T(x)$

R_T = région où le test décide H_1

$$P_{FA} = \int_{R_T} p_0(x) dx = p_0(R_T)$$

$$P_D = \int_{R_T} p_1(x) dx$$

Si on prend le test du rapport de vraisemblance $\frac{p_1(x)}{p_0(x)} \stackrel{H_1}{\underset{H_0}{\gtrless}} \lambda$

$R_{RV}(\lambda)$ = région où le RV décide H_1

$$= \{x \text{ tq } \frac{p_1(x)}{p_0(x)} > \lambda\}$$

$$= \{x \text{ tq } p_1(x) > p_0(x)\lambda\}$$

$$P_D = \int_{R_{RV}(\lambda)} P_1(x) dx = P_1(R_{RV}(\lambda))$$

Si λ augmente alors P_D diminue

Si λ diminue alors P_D augmente

Lemme de Neyman-Pearson

parmi tous les tests possibles, le test ayant une proba de détection maximale pour une $P_{FA} = \alpha$ fixée est le test du rapport de vraisemblance

De même, la $P_{FA} = \int_{R_{RV}(\lambda)} p_0(x)dx = P_0(R_{RV}(\lambda))$ dépend de la valeur du seuil

Si λ augmente alors P_{FA} diminue

Si λ diminue alors P_{FA} augmente

On veut $P_{FA} \leq \alpha$ ($P_{FA} = \alpha$)

on règle λ de manière à ce que $P_{FA} = \alpha$

Exemple : on observe x_1, \dots, x_n

bruit $\rightarrow H_0 : X_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$ σ^2 connu

signal + bruit $\rightarrow H_1 : X_i \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ μ connu

On cherche à répondre à cette question sous contrainte que $P_{FA} = \alpha$

\rightarrow test du rapport de vraisemblance

$$\Lambda(x_1, \dots, x_n) = \frac{p_1(x_1, \dots, x_n)}{p_0(x_1, \dots, x_n)} = \frac{\prod_{i=1}^n p_1(x_i)}{\prod_{i=1}^n p_0(x_i)}$$

$$= \frac{\prod_{i=1}^n \left(\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right) \right)}{\prod_{i=0}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2} \frac{x_i^2}{\sigma^2}\right)}$$

$$\Lambda(x_1, \dots, x_n) = H_1 \text{ Si } \frac{\exp\left(\frac{-1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma}\right)\right)}{\exp\left(\frac{-1}{2} \sum_{i=1}^n \left(\frac{x_i}{\sigma}\right)^2\right)} > \lambda, \text{ sinon } H_0$$

$$\begin{aligned}
 \Lambda(x_1, \dots, x_n) &= \frac{\exp\left(-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma}\right)^2\right)}{\exp\left(-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i}{\sigma}\right)^2\right)} \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} \\
 &= \exp\left(-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (x_i - \mu)^2 - \sum_{i=1}^n x_i^2 \right)\right) \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} \lambda \\
 \text{On prend le log: } &-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (x_i - \mu)^2 - \sum_{i=1}^n x_i^2 \right) \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} \log \lambda \\
 &- \underbrace{\sum_{i=1}^n (x_i - \mu)^2}_{n} + \underbrace{\sum_{i=1}^n x_i^2}_{H_0} \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} 2\sigma^2 \log \lambda \\
 &- \underbrace{\sum_{i=1}^n x_i^2}_{H_0} - 2\mu \underbrace{\sum_{i=1}^n x_i}_{H_1} + n\mu^2 \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} 2\sigma^2 \log \lambda \\
 &- \underbrace{\sum_{i=1}^n x_i^2}_{H_0} + 2\mu \underbrace{\sum_{i=1}^n x_i}_{H_1} - n\mu^2 + \underbrace{\sum_{i=1}^n x_i^2}_{H_0} \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix} 2\sigma^2 \log \lambda \\
 &2\mu \underbrace{\sum_{i=1}^n x_i}_{H_1} \gtrless 2\sigma^2 \log \lambda + n\mu^2 \\
 \Lambda(x_1, \dots, x_n) &= \underbrace{\sum_{i=1}^n x_i}_{H_1} \gtrless \underbrace{\frac{1}{2\mu} (2\sigma^2 \log \lambda + n\mu^2)}_{\gamma} \begin{matrix} H_1 \\ \gtrless \\ H_0 \end{matrix}
 \end{aligned}$$

$$\alpha \equiv P_{FA} = \mathbb{P}(\text{décider } H_1 | H_0 \text{ vraie}) = \mathbb{P}(\sum_{i=1}^n X_i > \gamma | X_i \sim \mathcal{N}(0, \sigma^2))$$

$$\Lambda(x_1, \dots, x_n) = \sum_{i=1}^n x_i \equiv \text{test scalaire}$$

$$\Lambda(X_1, \dots, X_n) = \sum_{i=1}^n X_i \equiv \text{statistique du test}$$

$$\sum_{i=1}^n X_i \sim \mathcal{N}(0, n\sigma^2)$$

$$\alpha = P_{FA} = \mathbb{P}(\mathcal{N}(0, n\sigma^2) > \gamma)$$

$$\int_{\gamma}^{+\infty} \mathcal{N}(0, n\sigma^2)(x) dx$$

$$\int_{\gamma}^{+\infty} \frac{1}{\sqrt{2\pi n\sigma^2}} e^{-\frac{1}{2}\frac{x^2}{n\sigma^2}} dx = \alpha = P_{FA}$$

$$Q(x) = \int_x^{+\infty} \mathcal{N}(0, 1)(x) dx$$

$$\text{on va poser } u = \frac{x}{\sigma\sqrt{n}} \quad x = \sigma\sqrt{n}u \quad dx = \sigma\sqrt{n}du$$

$$= \int_{\frac{\gamma}{\sigma\sqrt{n}}}^{+\infty} \frac{1}{\sigma\sqrt{n}\sqrt{2\pi}} e^{-\frac{1}{2}\frac{u^2}{n\sigma^2}} \sigma\sqrt{n}du$$

$$= \int_{\frac{\gamma}{\sigma\sqrt{n}}}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}u^2} du$$

$$P_{FA} = \alpha = Q\left(\frac{\gamma}{\sigma\sqrt{n}}\right)$$

$$\frac{\gamma}{\sigma\sqrt{n}} = Q^{-1}(\alpha)$$

$$\gamma = \sigma\sqrt{n}Q^{-1}(\alpha)$$

$$\text{AN: } \sigma = 1, n = 100, \alpha = P_{FA} = 0.05$$

$$\text{Table de Gauss: } Q^{-1}(0.05) = 1.65$$

$$\gamma = \sigma\sqrt{n}Q^{-1}(\alpha) = 1 \times 10 \times 1.65 = 16.5$$

$$\text{Sous } H_0 : \sum_{i=1}^n X_i \sim \mathcal{N}(0, n\sigma^2) = \mathcal{N}(0, 100)$$

On peut calculer la proba de détection

$$P_D = \mathbb{P}(\text{décider } H_1 | H_1 \text{ vraie}) = \mathbb{P}(\sum_{i=1}^n X_i > \gamma | X_i \sim \mathcal{N}(\mu, \sigma^2))$$

$$\text{Sous } H_1 : X_i \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$$

$$\sum_{i=1}^n X_i \sim \mathcal{N}(n\mu, n\sigma^2)$$

$$P_D = \mathbb{P}(\mathcal{N}(n\mu, n\sigma^2) > \gamma) = \int_{\gamma}^{+\infty} \frac{1}{\sqrt{2\pi n\sigma^2}} e^{-\frac{1}{2}\frac{(x-n\mu)^2}{n\sigma^2}} dx$$

$$u = \frac{x-n\mu}{\sigma\sqrt{n}} \quad du = \frac{dx}{\sigma\sqrt{n}}$$

$$P_D = \int_{\frac{\gamma-n\mu}{\sigma\sqrt{n}}}^{+\infty} \frac{1}{\sqrt{2\pi}\sqrt{n}\sigma} \exp\left(-\frac{1}{2}u^2\right) \sigma\sqrt{n}du$$

$$\int_{\frac{\gamma-n\mu}{\sigma\sqrt{n}}}^{+\infty} \mathcal{N}(0, 1)(u) du = Q\left(\frac{\gamma-n\mu}{\sigma\sqrt{n}}\right)$$

$$\gamma = \sigma\sqrt{n}Q^{-1}(\alpha)$$

$$P_D = Q\left(\frac{\sigma\sqrt{n}Q^{-1}(\alpha)-n\mu}{\sigma\sqrt{n}}\right) = Q\left(Q^{-1}\alpha - \sqrt{n}\frac{\mu}{\sigma}\right) \rightarrow \text{dépend de } \mu \text{ (rapport signal sur bruit)}$$

si μ augmente, P_D augmente

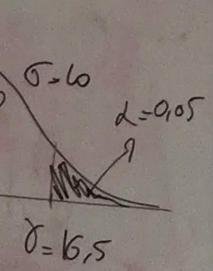
si $\mu \rightarrow +\infty$, $Q^{-1}\alpha - \sqrt{n}\frac{\mu}{\sigma} \rightarrow -\infty$

$$Q(x) = \int_x^{+\infty} \mathcal{N}(0, 1)(u) du \xrightarrow[x \rightarrow -\infty]{} 1$$

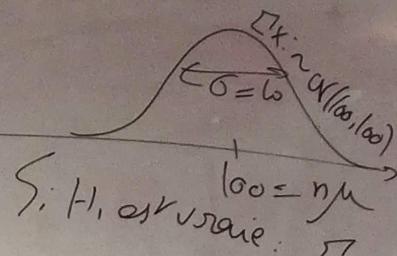
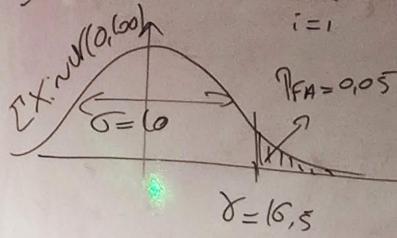
$$\begin{aligned}\mathtt{AN}: & n=100, \sigma=1, \alpha=0,05, Q^{-1}(\alpha)=1,65 \\ & \mu=1P_D=Q(1,65-10)=Q(=8,35)=1-3,4*10^{-17} \\ & \mu=0,1P_D=Q(1,65-1)=Q(=0,65)\end{aligned}$$

$$\alpha = P_{FA} = P(\mathcal{N}(0, \sigma^2) > \delta)$$

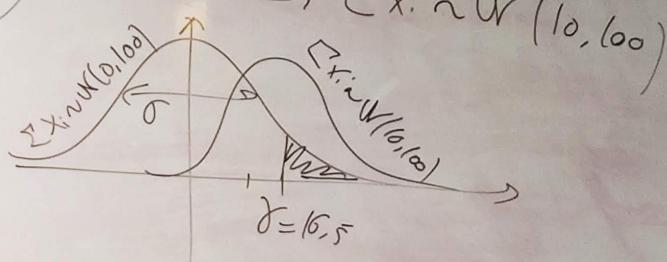
Sei $H_1: \sum_{i=1}^n X_i \sim \mathcal{N}(\eta\mu, \sigma^2)$



$$\mu = 1 \rightarrow \sum_{i=1}^n X_i \sim \mathcal{N}(100, 100)$$



$\therefore H_1$ ist vertretbar:



$$P_D = Q(Q^{-1}(P_{FA}) - \sqrt{n} \frac{\mu}{\sigma})$$

$$P_D = f(P_{FA})$$

Si on fixe tous les autres paramètres et qu'on trace $P_D = f(P_{FA})$ = courbe ROC (Receiving operator characteristic)

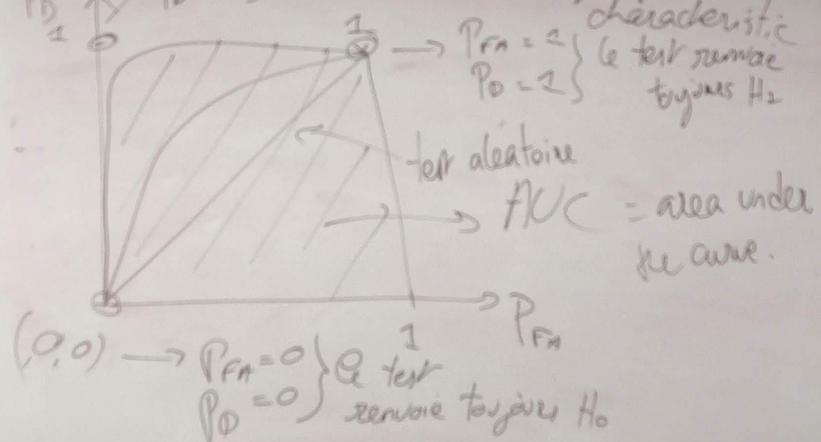
$$P_D = \int_{\frac{\delta - \eta \mu}{\sigma \sqrt{n}}}^{+\infty} \phi(a_1)(u) du = Q\left(\frac{\delta - \eta \mu}{\sigma \sqrt{n}}\right)$$

$$P_D = Q\left(Q^{-1}(P_{FA}) - \sqrt{n} \frac{\mu}{\sigma}\right)$$

$$P_D = f(P_{FA})$$

Si on fixe tous les autres paramètres et qu'on trace $P_D = f(P_{FA})$ = courbe RO (receiving operator)

$P_{FA} = 0 \rightarrow P_D = 1$ test parfait
 $P_{FA} = 1 \rightarrow P_D = 0$



PARTIEL

pouvoir expliquer avec des mots son cours (estimateur de vraisemblance, borne...)

Kramera o (je sais pas comment on écrit)

seul calcul qu'il est susceptible de demander : maximum de vraisemblance

faire le calcul du maximum de vraisemblance

Heisenberg A SAVOIR ABSOLUMENT

une feuille A5 de note manuscrite recto verso

Cours du 22/01 (guillaume terrasse)

$$\int <\Psi, x> \Psi$$

$$x = \sum_{\sigma \in \mathbb{Z}} D_J = A_J + \sum_{j=-\infty}^J D_j$$